Università Politecnica delle Marche

Ingegneria Informatica e dell'Automazione

Tecniche di Data Science per l'Analisi della Qualità dell'aria in Campania



Corso di

DATA SCIENCE

Anno accademico 2026-2027

Studenti:

TOYEM TEZEM RYAN PARFAIT

SIMONE MURAZZO

ANDREA SCALZI

MAICOL LANNI

Professore:

DOMENICO URSINO

Dottorando:

BURATTI CHRISTOPHER

Dipartimento di Ingegneria dell'Informazione

Indice

1 Introduzione e dataset **2**
- 1.1 Contesto e obiettivi del progetto . . . 2
- 1.2 Il dataset . . . 3
- 1.3 Struttura dei dati . . . 3
  - 1.3.1 Gli inquinanti . . . 4
  - 1.3.2 I valori limite . . . 4
- 1.4 Pre-processing . . . 5
  - 1.4.1 Colonne eliminate . . . 5
  - 1.4.2 Conversione delle date . . . 5
  - 1.4.3 Valori mancanti codificati . . . 6
  - 1.4.4 Esclusione delle stazioni . . . 6
  - 1.4.5 Valori anomali . . . 7
  - 1.4.6 Il particolato su base giornaliera . . . 8
  - 1.4.7 Dataset finale . . . 8
- 1.5 Qualità e continuità dei dati . . . 8

2 Analisi descrittiva **10**
- 2.1 Introduzione . . . 10
  - 2.1.1 Librerie utilizzate . . . 10
  - 2.1.2 Scala temporale . . . 10
- 2.2 Statistiche descrittive per inquinante . . . 11
- 2.3 Distribuzione dei valori . . . 12
- 2.4 Andamento temporale . . . 13
  - 2.4.1 Andamento complessivo 2023–2026 . . . 13
  - 2.4.2 Stagionalità . . . 14
  - 2.4.3 Ciclo settimanale . . . 15
  - 2.4.4 Ciclo giornaliero . . . 16
- 2.5 Confronto tra stazioni . . . 17
- 2.6 Eventi particolari . . . 18
  - 2.6.1 La notte di Capodanno . . . 18
  - 2.6.2 L'episodio del 31 marzo – 1 aprile 2024 . . . 19
- 2.7 Correlazioni tra inquinanti . . . 19
- 2.8 Conclusioni . . . 21

3 CLASSIFICAZIONE **22**

4 CLUSTERING **23**

5 FORECASTING **24**

6 CONCLUSIONI **25**

1 Introduzione e dataset

1.1 Contesto e obiettivi del progetto

L'inquinamento atmosferico è uno dei principali rischi ambientali per la salute umana. Le particelle sospese e i gas inquinanti, come il biossido di azoto NO_2 e l'ozono (O_3), sono associati a malattie respiratorie e cardiovascolari, e la loro concentrazione nell'aria è per questo regolata da limiti di legge a livello europeo. L'Italia è uno dei Paesi in cui questi limiti vengono superati con maggiore frequenza: nel 2020 la Corte di giustizia dell'Unione europea l'ha condannata per il superamento sistematico e continuato dei valori limite del PM10 in diverse zone del territorio [1]. Il monitoraggio della qualità dell'aria è affidato alle Agenzie regionali per la protezione ambientale (ARPA), che gestiscono reti di stazioni di misura distribuite sul territorio.

In questo progetto analizziamo le misure orarie della rete di monitoraggio della Regione Campania, gestita da ARPA Campania (ARPAC), con l'obiettivo di estrarre conoscenza da dati reali e recenti attraverso le tecniche viste nel corso. Il lavoro si articola in quattro parti:

- **Analisi descrittiva:** esplorare le distribuzioni degli inquinanti, il loro andamento nel tempo, le differenze tra stazioni e le relazioni tra inquinanti;
- **Classificazione:** DA FARE;
- **Clustering:** DA FARE;
- **Forecasting:** DA FARE.

Questo primo capitolo presenta il dataset, la sua struttura e le operazioni di pre-processing che hanno permesso di ottenere i dati puliti utilizzati in tutti i capitoli successivi.



Figura 1.1: *Esempio di stazione di monitoraggio.*

1.2 Il dataset

I dati provengono dal portale Open Data di ARPA Campania [2], che pubblica mensilmente le misure orarie di tutte le stazioni della rete regionale di monitoraggio della qualità dell'aria. Abbiamo scelto questa fonte perché offre dati reali, recenti e pubblicati da un ente istituzionale, con una frequenza di misura (oraria) e una durata (oltre tre anni) adatte sia all'analisi delle serie temporali sia alle tecniche di classificazione e di clustering.

Il portale mette a disposizione due versioni dei dati: i dati *grezzi* (*near real time*), pubblicati quasi in tempo reale, e i dati *validati*, sottoposti ai controlli di qualità dell'agenzia. Abbiamo scelto i dati validati, più affidabili, tenendo conto di qualche lacune nella valutazione della continuità dei dati (Sezione 1.5).

I 44 file mensili, da marzo 2023 a ottobre 2026, sono stati scaricati il 29/10/2026 e concatenati in un unico file. La Tabella 1.1 ne riassume le caratteristiche.

Tabella 1.1: *Caratteristiche del dataset utilizzato.*

Fonte	Portale Open Data ARPA Campania [2]
Dataset	*Dati RQA Orari Validati*
Licenza	CC BY 4.0
Periodo	20/03/2023 – 26/10/2026
File	44 file mensili CSV, concatenati in un unico file (395 MB)
Data del download	29/10/2026
Righe	4.905.168
Codici di stazione	57
Inquinanti	7

1.3 Struttura dei dati

I dati sono organizzati in formato *lungo*: ogni riga corrisponde alla misura di un inquinante, in una stazione, in una determinata ora. La Tabella 1.2 descrive le sette colonne del file.

Tabella 1.2: *Colonne del dataset originale.*

Colonna	**Tipo**	**Descrizione**	**Esempio**
`_id`	intero	numero di riga interno al file mensile	1
`Stazione`	testo	codice europeo (EEA) della stazione	IT2211A
`Descrizione`	testo	nome della stazione	Acerra Zona Industriale
`Inquinante`	testo	inquinante misurato	PM10
`Data_ora`	testo	data, ora e fuso orario	01-09-2023 00:00:00 +01:00
`Valore`	testo	concentrazione misurata	27.1
`Um`	testo	unità di misura	$\mu g/m^3$

Il codice della stazione segue la nomenclatura dell'Agenzia europea dell'ambiente (EEA): le stazioni fisse della rete hanno codici della forma `IT`, seguito da quattro cifre e dalla lettera `A`. Il nome della stazione indica in genere il comune e il luogo di installazione (una scuola, un parco, una zona industriale).

1.3.1 Gli inquinanti

Il dataset contiene le misure di sette inquinanti:

- **PM10 e PM2,5**: particelle sospese con diametro inferiore rispettivamente a 10 µm e a 2,5 µm. **Derivano dal traffico** (gas di scarico, ma anche usura di freni, pneumatici e asfalto), dal riscaldamento domestico, dall'industria e da fonti naturali come la sabbia sahariana. Le PM2,5, più fini, penetrano più in profondità nell'apparato respiratorio;
- **NO_2** (biossido di azoto): gas prodotto dai processi di combustione, in ambito urbano soprattutto dal traffico veicolare;
- **O_3** (ozono): inquinante *secondario*, non emesso direttamente ma formato in atmosfera per effetto della radiazione solare a partire da altri inquinanti; raggiunge per questo i valori più alti in estate;
- **CO** (monossido di carbonio): gas prodotto dalla combustione incompleta, in particolare dei motori dei veicoli;
- **SO_2** (biossido di zolfo): gas legato alla combustione di combustibili contenenti zolfo, in ambito industriale e portuale;
- **C_6H_6** (benzene): composto organico cancerogeno, emesso principalmente dai carburanti e dal traffico.

1.3.2 I valori limite

La Direttiva 2008/50/CE [3], recepita in Italia dal D.Lgs. 155/2010, fissa per ogni inquinante dei *valori limite*: una concentrazione da non superare, calcolata come media su un determinato *periodo di mediazione* (un'ora, un giorno, otto ore o un anno). Per alcuni limiti è consentito un numero massimo di superamenti per anno civile: ad esempio, la media giornaliera del PM10 può superare 50 µg/m^3 al massimo 35 volte all'anno. Per l'ozono la norma fissa invece un *valore obiettivo*, cioè un livello da raggiungere, meno vincolante di un valore limite. La Tabella 1.3 riporta, per ogni inquinante, l'unità di misura, il numero di misure presenti nel dataset e i principali limiti di legge. Questi valori costituiscono un riferimento per interpretare le concentrazioni misurate e definiscono la variabile da prevedere nel capitolo di classificazione. La nuova Direttiva (UE) 2024/2881 prevede limiti più stringenti a partire dal 2030 [4].

Tabella 1.3: *Inquinanti presenti nel dataset e principali valori limite (Direttiva 2008/50/CE).*

Inquinante	Unità	Misure	Periodo di mediazione	Limite	Superamenti/anno
NO_2	µg/m^3	995.793	1 ora	200	18
			anno civile	40	–
PM10	µg/m^3	894.611	24 ore	50	35
			anno civile	40	–
PM2,5	µg/m^3	890.014	anno civile	25	–
C_6H_6	µg/m^3	627.446	anno civile	5	–
O_3	µg/m^3	562.616	massima media mobile su 8 ore	120*	25**
CO	mg/m^3	558.442	massima media mobile su 8 ore	10	–
SO_2	µg/m^3	376.246	1 ora	350	24
			24 ore	125	3

* Valore obiettivo. ** Media su tre anni.

1.4 Pre-processing

L'obiettivo del pre-processing è fornire ai capitoli successivi dati puliti e affidabili, documentando ogni scelta effettuata. Le operazioni sono state svolte in Python con la libreria pandas, in un notebook Jupyter dedicato.

1.4.1 Colonne eliminate

La colonna `_id` è stata eliminata: non identifica le misure, ma è un numero di riga interno a ciascun file mensile, che riparte da 1 ogni mese. Nel file concatenato assume infatti solo 140.415 valori distinti su 4.905.168 righe, esattamente il numero di righe del file più grande, quello di luglio 2026.

La colonna `Um` è costante per ogni inquinante: tutte le concentrazioni sono espresse in µg/m^3, **tranne quelle del CO, espresse in** mg/m^3**(un milligrammo equivale a mille microgrammi)**. La colonna è stata mantenuta per completezza. Questa differenza va considerata quando si confrontano gli inquinanti tra loro: i valori del CO risultano numericamente molto più piccoli degli altri.

1.4.2 Conversione delle date

Il controllo della colonna `Data_ora` ha rivelato la presenza di due formati diversi (Tabella 1.4), il secondo formato riguarda solo le misure dal 7 al 10 ottobre 2025, probabilmente a causa di un cambiamento temporaneo nel sistema di pubblicazione dell'agenzia.

Tabella 1.4: *Formati della colonna* `Data_ora`.

Formato	Esempio	Righe
`gg-mm-aaaa hh:mm:ss +01:00`	26-10-2026 23:00:00 +01:00	4.881.186
`aaaa-mm-gg hh:mm:ss+01`	2025-10-07 01:00:00+01	23.982

Lasciare che pandas riconosca automaticamente il formato avrebbe portato a convertire correttamente solo una parte delle date. Abbiamo quindi letto i due formati in modo esplicito, indicando a pandas la struttura di ciascuno, e unito i risultati, tutte le date sono state convertite in datetime.

Tutte le misure riportano lo stesso fuso orario (UTC+1), le date sono state quindi espresse in ora fissa UTC+1, senza passaggio all'ora legale dunque abbiamo deciso che l'indicazione del fuso doveva essere rimossa. Il periodo coperto va **dal 20/03/2023 alle 00:00 al 26/10/2026 alle 23:00**.

NOTA : La documentazione di ARPAC non specifica se l'orario indichi l'inizio o la fine dell'intervallo di misura. Poiché ogni file mensile inizia alle 00:00 del primo giorno del mese, abbiamo assunto che l'orario indichi l'inizio dell'intervallo, senza applicare correzioni. Segnaliamo tuttavia che il 31/03/2024, giorno del passaggio all'ora legale, alcune stazioni presentano solo 23 ore di misure: ciò suggerisce che gli orari possano seguire in realtà l'ora locale italiana, nonostante l'indicazione UTC+1.

1.4.3 Valori mancanti codificati

Il dataset non contiene celle vuote, ma questo non significa che sia completo, per due motivi.

In primo luogo, le ore in cui una stazione non ha misurato un inquinante non compaiono affatto nel file, l'assenza di una misura corrisponde all'assenza di una riga.

In secondo luogo, una volta convertiti in numeri, i valori della colonna `Valore` hanno rivelato misure non valide codificate con valori negativi:

- 202.303 valori pari a -9999 (circa il 4% delle righe), codice convenzionale di valore mancante;
- 224 altri valori negativi, fisicamente impossibili per una concentrazione: in parte piccoli valori vicini allo zero, dovuti al rumore degli strumenti, in parte valori chiaramente errati (fino a $-104{,}1\ \mu g/m^3$ per l'O_3).

Lasciati nel dataset, questi valori avrebbero falsato qualsiasi media, **un solo -9999 in una giornata basterebbe a rendere fortemente negativa la media giornaliera**. I 202.527 valori negativi sono stati quindi sostituiti con `NaN`, il valore mancante di pandas, che viene ignorato automaticamente nel calcolo delle medie. Le righe sono state invece conservate, per non interrompere la struttura delle serie temporali.

1.4.4 Esclusione delle stazioni

Dei 57 codici di stazione presenti, 21 non sono adatti alle analisi del progetto (Tabella 1.5).

Tabella 1.5: *Stazioni escluse dall'analisi.*

Stazioni	Motivo
Laboratori mobili (LM01, LM03, MMA61, MMB62), impianti STIR, EDI01, EDI02	stazioni non fisse, presenti solo dal 7 al 18 ottobre 2025
IT2220A, IT2222A, IT2224A, IT2225A, IT2342A	installate a marzo 2026: circa 7 mesi di dati, senza un inverno completo
IT2269A (Salerno Parco Mercatello)	dismessa ad agosto 2023, meno di 5 mesi di dati

Le stazioni installate nel 2026 meritano una precisione. Le loro misure non sono errate e, nel periodo marzo-ottobre 2026, sono confrontabili con quelle delle altre stazioni. Tuttavia, poiché gli inquinanti hanno un forte andamento stagionale (il particolato e l'NO_2 raggiungono i valori massimi in inverno, l'ozono in estate), stazioni prive di dati invernali avrebbero medie non confrontabili con quelle delle stazioni attive per più anni. Abbiamo escluso anche la stazione IT2269A, dismessa dopo pochi mesi, e mantenuto invece la stazione IT2272A (Pozzuoli), attiva da giugno 2024: la scelta di includerla o meno è lasciata ai singoli capitoli, in base al periodo analizzato.

L'esclusione ha eliminato 134.842 righe; restano **36 stazioni**.

1.4.5 Valori anomali

I valori massimi di alcuni inquinanti sono risultati del tutto irrealistici: fino a 1.437.008 µg/m^{3}per il PM10, mentre anche gli episodi di inquinamento più intensi raramente superano poche centinaia di µg/m^3. Non abbiamo però applicato una soglia automatica, perché alcuni valori estremi corrispondono a fenomeni reali. Per ogni valore sospetto abbiamo invece osservato il contesto, cioè le misure delle ore precedenti e successive nella stessa stazione:

- un valore *isolato*, circondato da valori normali o mancanti, è stato considerato un errore di misura;
- un picco con una salita e una discesa graduali, distribuite su più ore, è stato considerato un episodio reale di inquinamento.

I quattro valori della Tabella 1.6 sono stati sostituiti con `NaN`. In tutti i casi il valore anomalo compare isolato, tra ore senza misure o con valori normali, ad esempio il valore di 1.437.008 µg/m^{3}della stazione IT1504A è l'unica misura di una mattinata in cui lo strumento registra solo -9999, mentre il PM2,5 della stazione IT0934A passa da circa 20 µg/m^3 a 17.792,5 e poi a 101.090 µg/m^3, per tornare a valori normali nel pomeriggio.

Tabella 1.6: *Valori anomali sostituiti con `NaN`.*

Stazione	Inquinante	Data e ora	Valore (µg/m^3)
IT1504A	PM10	01/09/2023 09:00	1.437.008
IT1493A	NO_2	22/11/2024 23:00	4.992,6
IT0934A	PM2,5	13/06/2025 10:00	17.792,5
IT0934A	PM2,5	13/06/2025 12:00	101.090

Al contrario, il picco di PM10 registrato a Napoli nella notte di Capodanno (stazione IT0898A) è stato conservato, la concentrazione sale nel corso della serata, raggiunge 2.721,9 µg/m^3 all'01:00 del 01/01/2025 e torna gradualmente ai valori abituali nel corso della mattinata. Si tratta dell'effetto dei fuochi d'artificio. Anche i valori elevati del PM10 alla stazione IT2226A intorno a mezzogiorno del 01/01/2026 sono stati conservati.

NOTA : Segnaliamo infine la stazione IT1486A, che tra agosto e settembre 2024 registra per alcune giornate intere un valore di PM10 costante e molto elevato (tra 1.596 e 2.453 µg/m^3). **Questi valori non sono stati modificati, ma vanno considerati con cautela nelle analisi**.

1.4.6 Il particolato su base giornaliera

Cercando eventuali strumenti bloccati, abbiamo contato le giornate in cui una stazione registra lo stesso valore per tutte le ore disponibili (almeno 18). Il risultato varia molto da un inquinante all'altro: 5.965 giornate per il PM10 e 6.164 per il PM2,5, contro 2 per l'NO_2 e 2 per l'O_3 (e alcune centinaia per CO, SO_2 e benzene, i cui valori sono spesso bassi e misurati con una precisione limitata). Se si trattasse di guasti, colpirebbero tutti gli inquinanti in modo simile. **La spiegazione più probabile è invece il metodo di misura, sicuramente in molte stazioni il particolato viene misurato su base giornaliera, raccogliendo le particelle su un filtro per 24 ore, e il valore giornaliero viene poi ripetuto per tutte le ore della giornata**.

Queste giornate costanti sono quindi misure valide e sono state conservate. Ne segue però che, per queste stazioni, il PM10 e il PM2,5 non hanno un vero profilo orario: **il particolato verrà analizzato a scala giornaliera**.

1.4.7 Dataset finale

Il dataset pulito è stato salvato in formato Parquet, più compatto e veloce da leggere di un file CSV, che conserva inoltre i tipi delle colonne (date e numeri). Le sue caratteristiche sono:

- file `data/processed/aria_campania_orario.parquet`, in formato lungo e a frequenza oraria;
- 4.770.326 righe, 36 stazioni, 7 inquinanti;
- colonne `Stazione`, `Descrizione`, `Inquinante`, `Data_ora`, `Valore`, `Um`;
- periodo dal 20/03/2023 al 26/10/2026.

Per identificare le stazioni va usato il codice (`Stazione`) e non il nome, la colonna `Descrizione` riporta infatti nomi diversi per la stessa stazione a seconda del mese (ad esempio "Casoria Scuola Palizzi" e "Casoria Scuola Palizzi (CAM)").

1.5 Qualità e continuità dei dati

La Figura 1.2 mostra, per ogni stazione e ogni mese, la quota di giorni in cui è disponibile almeno una misura di PM10. La figura è stata prodotta prima dell'esclusione delle stazioni e include quindi anche le stazioni escluse, visibili come righe quasi interamente rosse.

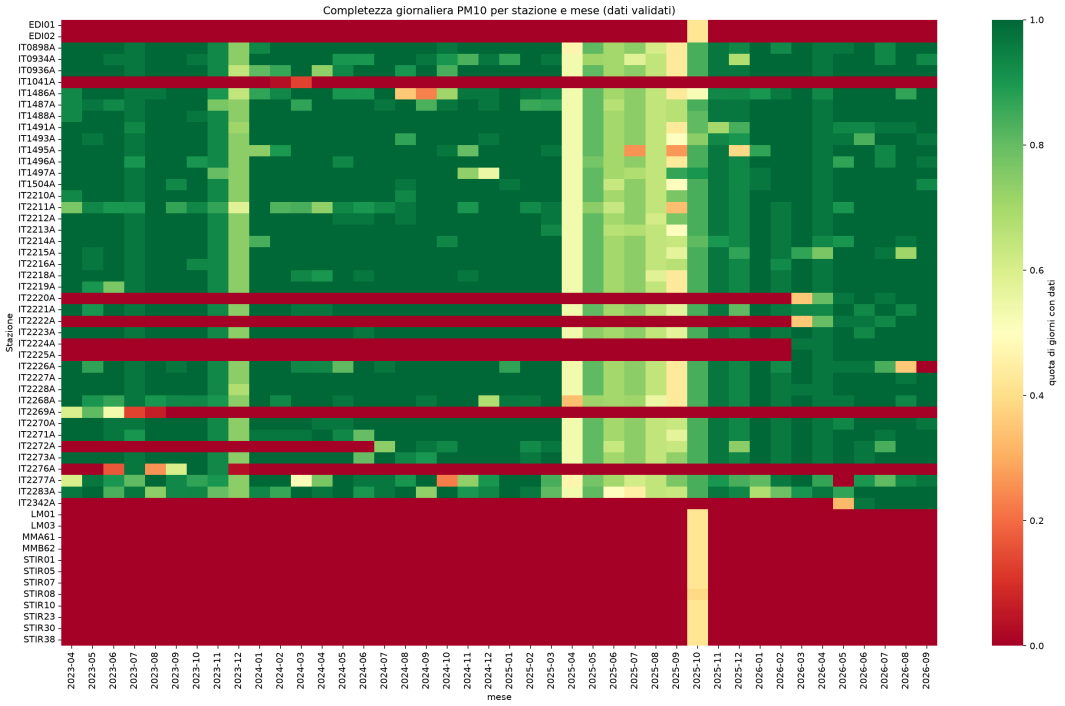


Figura 1.2: *Completezza giornaliera del PM10 per stazione e mese.*

Per la maggior parte delle stazioni la copertura è molto buona, 31 stazioni hanno dati di PM10 per l'86-94% dei giorni. Le lacune più evidenti (dicembre 2023, aprile 2025 e il periodo maggio-ottobre 2025) colpiscono tutte le stazioni contemporaneamente, non sono quindi dovute a guasti dei singoli strumenti, ma alla pubblicazione o alla validazione dei dati da parte dell'agenzia. Per questo motivo non possono essere colmate con le misure delle stazioni vicine.

IMPORTANTE : Non tutte le stazioni misurano tutti gli inquinanti. La Tabella 1.7 riporta, per ogni inquinante, il numero di stazioni con dati disponibili per almeno l'80% dei giorni: il NO_2 e i particolati PM sono misurati in quasi tutte le stazioni, mentre l'ozono e soprattutto il biossido di zolfo solo in una parte della rete.

Tabella 1.7: *Stazioni con almeno l'80% dei giorni con dati (aprile 2023 – settembre 2026).*

	NO_2	PM10	PM2,5	C_6H_6	CO	O_3	SO_2
Stazioni	35	32	32	23	20	19	13

Per l'analisi delle serie temporali, la continuità del periodo aprile 2023 – marzo 2025 è buona, mancano solo 11 giorni su 731 (1,5%) in cui nessuna stazione ha misurato il PM10, con al massimo 3 giorni consecutivi (21–23 dicembre 2023). Si tratta di lacune brevi, che possono essere colmate per interpolazione.

2 Analisi descrittiva

2.1 Introduzione

Questo capitolo esplora i dati puliti ottenuti con il pre-processing (Capitolo 1), con l'obiettivo di descrivere le distribuzioni degli inquinanti, il loro andamento nel tempo, le differenze tra le stazioni e le relazioni tra inquinanti.

2.1.1 Librerie utilizzate

L'analisi è stata svolta in Python, in un notebook Jupyter dedicato, con le seguenti librerie:

- **pandas**: lettura del dataset in formato Parquet, filtri, raggruppamenti e calcolo delle medie giornaliere, mensili e orarie;
- **NumPy**: operazioni numeriche e gestione dei valori mancanti;
- **Matplotlib** e **Seaborn**: realizzazione dei grafici (boxplot, serie temporali, grafici a barre e mappe di calore);
- **SciPy**: utilizzata da pandas per il calcolo della correlazione di Spearman.

2.1.2 Scala temporale

La maggior parte delle analisi utilizza le *medie giornaliere* di ciascun inquinante in ciascuna stazione. Questa è la scala dei valori limite giornalieri ed è l'unica significativa per il particolato, il cui valore in molte stazioni è giornaliero e ripetuto su tutte le ore (Sezione 1.4). Seguendo il criterio adottato dalla normativa europea, una media giornaliera è considerata valida solo se calcolata su almeno 18 ore di misure (75% della giornata). Solo il profilo orario (Sezione 2.4) utilizza i dati orari, e solo per i gas.

Nei grafici che mostrano l'andamento complessivo della regione si utilizza la *media di rete*, cioè la media delle medie giornaliere di tutte le stazioni disponibili in un determinato giorno. Poiché il numero di stazioni attive varia leggermente nel tempo (guasti, attivazione della stazione IT2272A a giugno 2024), la media di rete non è calcolata ogni giorno esattamente sulle stesse stazioni; ciò non altera tuttavia la lettura degli andamenti generali.

2.2 Statistiche descrittive per inquinante

Tabella 2.1: *Statistiche descrittive delle medie giornaliere per inquinante (*µg/m^3*, CO in* mg/m^3*).*

Inquinante	N	Media	Dev. std.	Min	25%	Mediana	75%	Max
PM10	35.057	26,1	30,2	0,0	14,8	21,8	31,4	2.453,0
PM2,5	35.186	13,9	12,0	0,0	7,5	11,4	16,8	345,0
NO_2	38.913	23,0	14,8	0,0	12,1	20,3	31,0	212,9
O_3	21.635	56,1	23,0	0,0	39,7	56,5	71,6	529,0
CO	21.678	0,5	0,3	0,0	0,3	0,4	0,6	18,4
SO_2	14.392	2,8	3,5	0,0	1,0	2,2	3,7	289,5
C_6H_6	24.309	1,0	1,0	0,0	0,4	0,7	1,2	22,2

Le colonne della Tabella 2.1 hanno il seguente significato:

- **N**: numero di medie giornaliere valide (coppie stazione-giorno);
- **Media**: media aritmetica delle medie giornaliere;
- **Dev. std.**: deviazione standard, che misura quanto i valori si discostano in media dalla media: più è alta, più le concentrazioni sono variabili;
- **Min** e **Max**: valore minimo e massimo osservati;
- **25%**: primo quartile, cioè il valore al di sotto del quale si trova il 25% delle giornate;
- **Mediana**: valore che divide le giornate in due metà uguali (il 50% delle giornate ha un valore inferiore, il 50% superiore); a differenza della media, non è influenzata dai valori estremi;
- **75%**: terzo quartile, cioè il valore al di sotto del quale si trova il 75% delle giornate.

Quando la media è nettamente superiore alla mediana, la distribuzione è asimmetrica a destra: la maggior parte delle giornate presenta valori bassi, ma alcune giornate con valori molto elevati alzano la media.

Il numero di medie giornaliere varia molto tra gli inquinanti, poiché non tutte le stazioni li misurano tutti: da 38.913 per l'NO_2, misurato in quasi tutta la rete, a 14.392 per l'SO_2. Per tutti gli inquinanti la media è superiore alla mediana, segno di distribuzioni asimmetriche a destra. Il caso più evidente è il PM10: la media (26,1 µg/m^3) supera la mediana (21,8 µg/m^3) e la deviazione standard (30,2) è superiore alla media stessa, per effetto di pochi valori estremi, come le giornate anomale della stazione IT1486A, che determinano il massimo di 2.453 µg/m^3. Al contrario, l'intervallo tra primo e terzo quartile, da 14,8 a 31,4 µg/m^3, descrive bene le giornate abituali.

Alcuni valori massimi appaiono poco plausibili anche come medie giornaliere, **in particolare** 529 µg/m^3 **per l'ozono e** 289,5 µg/m^3 **per l'SO_2**. Questi valori, non individuati durante il pre-processing, riguardano un numero molto limitato di giornate e non modificano mediane e quartili, ma vanno tenuti presenti nei capitoli successivi.

2.3 Distribuzione dei valori

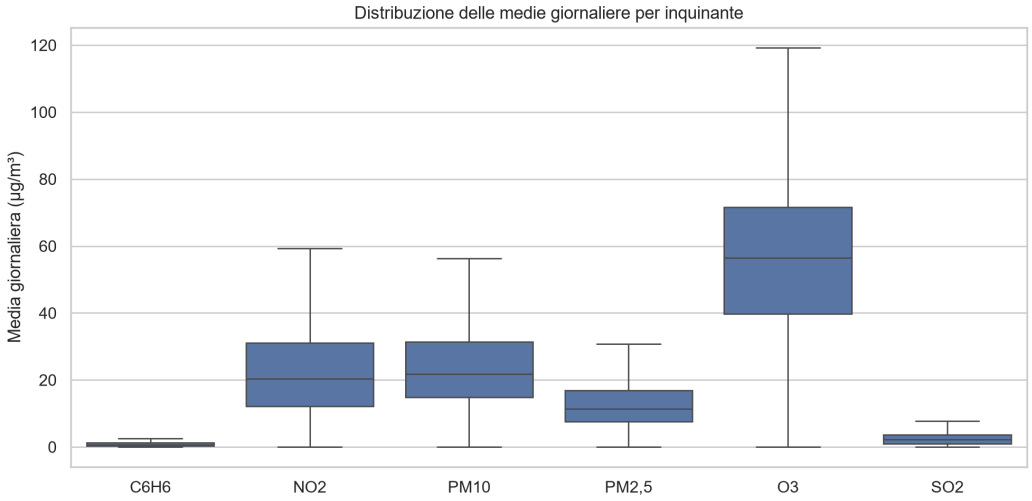


Figura 2.1: *Distribuzione delle medie giornaliere per inquinante (CO escluso, perché misurato in* $\mathrm{mg/m^3}$*; valori estremi non rappresentati).*

La Figura 2.1 confronta le distribuzioni delle medie giornaliere tramite boxplot: la linea interna a ciascun rettangolo indica la mediana, **il rettangolo contiene il 50% centrale delle giornate (dal primo al terzo quartile)** e i segmenti si estendono fino ai valori più lontani non considerati estremi. Per leggibilità, i valori estremi non sono rappresentati; il CO è escluso perché misurato in un'unità diversa ($\mathrm{mg/m^3}$).

L'ozono presenta le concentrazioni più elevate (mediana di circa $56\,\mu\mathrm{g/m^3}$, con metà delle giornate tra 40 e $72\,\mu\mathrm{g/m^3}$) e la dispersione maggiore, coerente con la sua forte stagionalità (Sezione 2.4). L'NO_2 e il PM10 hanno livelli simili, con mediane intorno a 20–$22\,\mu\mathrm{g/m^3}$; il segmento superiore del PM10 supera il limite giornaliero di $50\,\mu\mathrm{g/m^3}$, ma oltre il terzo quartile (circa $31\,\mu\mathrm{g/m^3}$), i superamenti riguardano quindi una minoranza di giornate. Questa informazione è rilevante per la classificazione, perché le due classi (superamento e non superamento) risulteranno sbilanciate. Il PM2,5 vale circa la metà del PM10 (mediana di circa $11\,\mu\mathrm{g/m^3}$), mentre l'SO_2 e il benzene restano su valori molto bassi, lontani dai rispettivi limiti.

2.4 Andamento temporale

2.4.1 Andamento complessivo 2023–2026

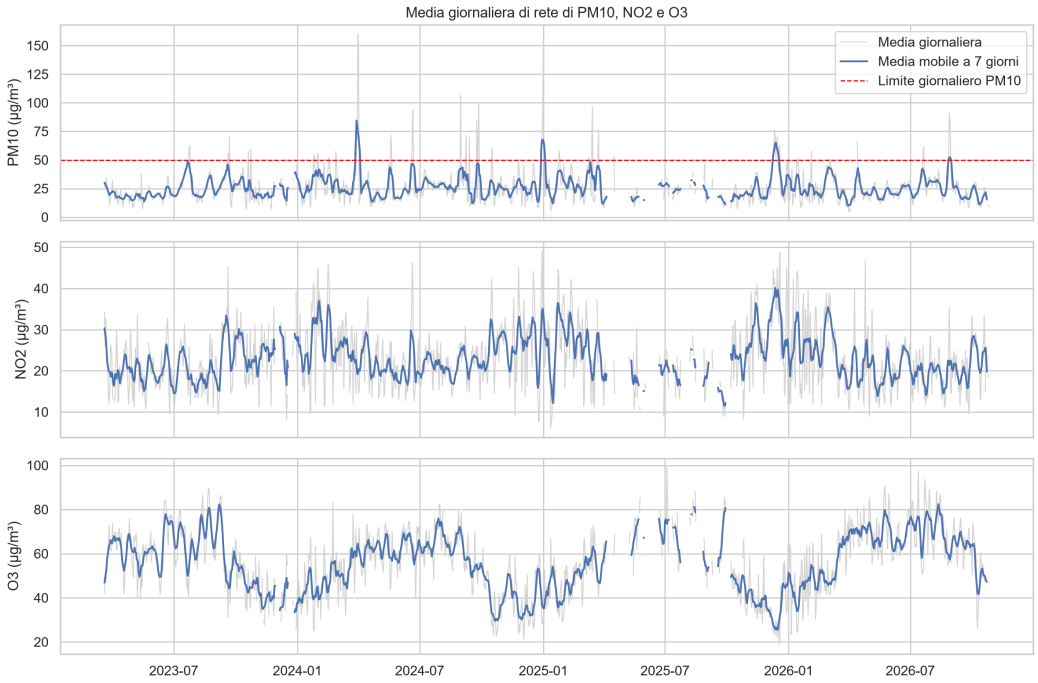


Figura 2.2: *Media giornaliera di rete di PM10, NO_2 e O_3 (in grigio) e media mobile centrata a 7 giorni.*

La Figura 2.2 mostra la media giornaliera di rete di PM10, NO_2 e O_3. Per rendere leggibile l'andamento di lungo periodo, ai valori giornalieri (in grigio) è sovrapposta la media mobile centrata a 7 giorni, in cui ogni giorno è sostituito dalla media dei sette giorni che lo circondano, questa attenua le fluttuazioni giornaliere e il ciclo settimanale, **mettendo in evidenza le variazioni stagionali. I giorni mancanti non sono interpolati, così che le lacune dei dati restino visibili**.

L'ozono (Troposfera: l'ozono "inquinante") presenta una stagionalità molto marcata e regolare, raggiunge 70–80 µg/m^3 in estate e scende intorno a 30 µg/m^3 in inverno, per effetto della radiazione solare che ne favorisce la formazione. L'NO_2 segue l'andamento opposto, con valori massimi in inverno (35–40 µg/m^3) e minimi in estate.

Il PM10 mostra una stagionalità meno evidente, i valori abituali restano tra 15 e 35 µg/m^3, ma emergono alcuni episodi intensi, tra cui l'evento dell'inizio di aprile 2024 e le notti di Capodanno del 2025 e del 2026 (Sezione 2.6). La media di rete supera il limite giornaliero di 50 µg/m^3 solo durante questi episodi, mentre singole stazioni possono superarlo anche quando la media di rete resta inferiore.

Il grafico rende visibili anche le lacune della rete descritte nella Sezione 1.5, in particolare il periodo frammentato tra aprile e ottobre 2025. Il periodo aprile 2023 – marzo 2025 si conferma il più continuo.

2.4.2 Stagionalità

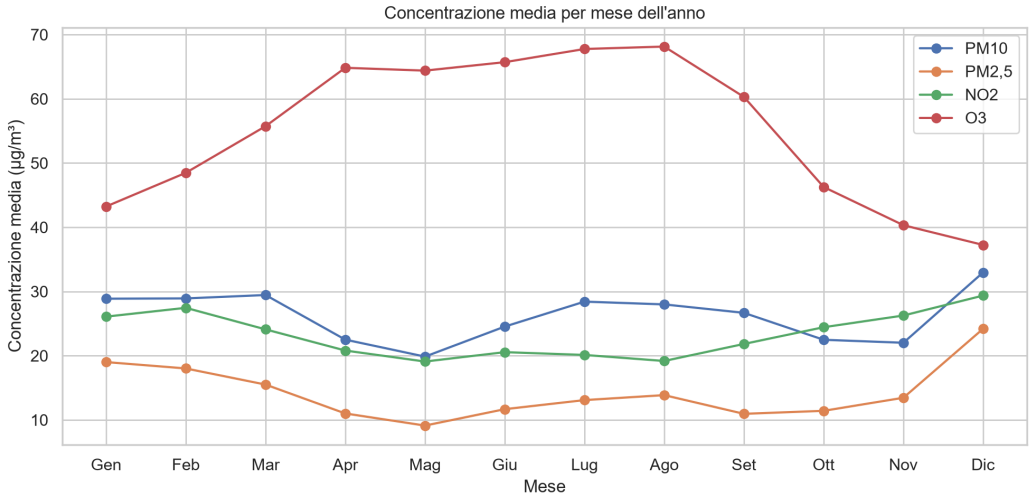


Figura 2.3: *Concentrazione media di PM10, PM2,5, NO_2 e O_3 per mese dell'anno.*

La Figura 2.3 riporta la concentrazione media di ciascun inquinante per mese dell'anno, raggruppando gli stessi mesi di anni diversi. L'ozono raggiunge i valori massimi in luglio e agosto (circa 68 µg/m^3) e i minimi in dicembre (circa 37 µg/m^3), quasi dimezzandosi. L'NO_2 segue l'andamento opposto, con il massimo in dicembre (circa 29 µg/m^3) e i minimi in maggio e agosto (circa 19 µg/m^3), in inverno la maggiore stabilità dell'atmosfera, con frequenti inversioni termiche, ostacola la dispersione degli inquinanti, mentre in estate parte dell'NO_2 è consumata nella formazione dell'ozono.

Il PM2,5 è nettamente più elevato in inverno (circa 24 µg/m^3 in dicembre, contro 9 µg/m^3 in maggio), **in coerenza con il contributo della combustione e del riscaldamento domestico**. Il PM10 presenta invece due massimi: uno invernale, analogo a quello del PM2,5, e uno estivo, in luglio e agosto, assente nel PM2,5. Il rapporto PM2,5/PM10 scende infatti da circa 0,7 in dicembre a circa 0,5 nei mesi estivi, in estate prevalgono le particelle più grossolane, tra 2,5 e 10 µm, riconducibili **ad esempio alle polveri sahariane, alla risospensione del suolo secco e al sale marino**.

Va osservato che i mesi non sono rappresentati in modo uniforme: i dati iniziano a marzo 2023, terminano a ottobre 2026 e presentano ampie lacune tra aprile e ottobre 2025. Alcuni mesi, come dicembre, sono quindi rappresentati da un numero limitato di anni, e un singolo episodio intenso può influenzarne sensibilmente la media.

2.4.3 Ciclo settimanale

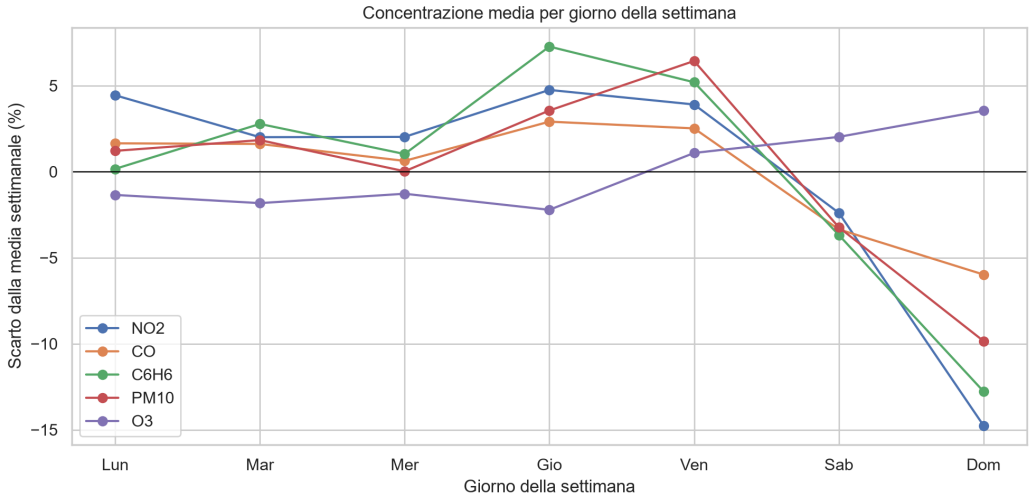


Figura 2.4: *Scarto percentuale della concentrazione media di ciascun giorno della settimana rispetto alla media settimanale.*

La Figura 2.4 riporta, per ogni inquinante, lo scarto percentuale della concentrazione media di ciascun giorno della settimana rispetto alla media settimanale; questa rappresentazione permette di confrontare inquinanti con livelli e unità di misura diversi. Gli inquinanti legati al traffico mostrano un netto calo nel fine settimana, la domenica l'NO_2 è inferiore alla media di circa il 15%, il benzene di circa il 13% e il CO di circa il 6%, mentre nei giorni feriali restano al di sopra della media, con i valori più alti tra giovedì e venerdì. Anche il PM10 diminuisce la domenica (circa -10%), a **conferma del contributo del traffico al particolato (emissioni dei veicoli, usura di freni e pneumatici, risospensione delle polveri stradali)**.

L'ozono segue l'andamento opposto, con valori inferiori alla media nei giorni feriali e superiori nel fine settimana (circa +3,5% la domenica). con meno traffico.

In ambito urbano viene consumato meno ozono dalle emissioni dei veicoli ("effetto weekend").

2.4.4 Ciclo giornaliero

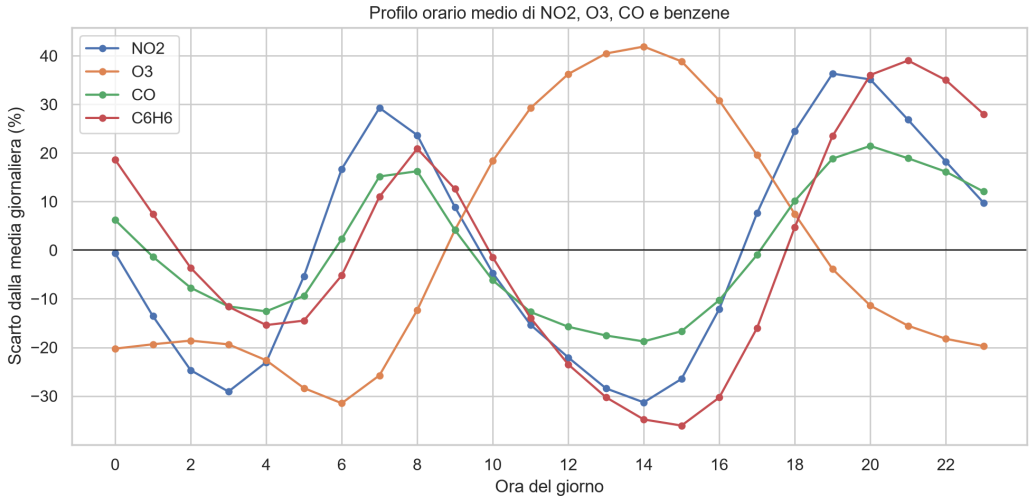


Figura 2.5: *Profilo orario medio di NO_2, O_3, CO e benzene, espresso come scarto percentuale dalla media giornaliera.*

La Figura 2.5 mostra il profilo orario medio dei gas, espresso come scarto percentuale dalla media giornaliera. Il particolato è escluso da questa analisi, poiché in molte stazioni il suo valore è giornaliero e ripetuto su tutte le ore.

L'NO_2, il CO e il benzene presentano due massimi, in corrispondenza delle ore di punta del traffico, il primo al mattino, intorno alle 7–8 (circa +29% per l'NO_2), il secondo, più intenso, in serata, tra le 19 e le 21 (circa +36% per l'NO_2 e +39% per il benzene).

L'ozono segue un andamento opposto: è minimo all'alba (circa −31%) e raggiunge il massimo nel primo pomeriggio (circa +42% intorno alle 14), quando la radiazione solare è più intensa; in serata diminuisce rapidamente, consumato dalle emissioni del traffico.

Poiché la documentazione ARPAC non chiarisce se l'orario indichi l'inizio o la fine dell'intervallo di misura, né se tenga conto dell'ora legale, gli orari dei massimi e dei minimi vanno letti con un'incertezza di circa un'ora.

2.5 Confronto tra stazioni

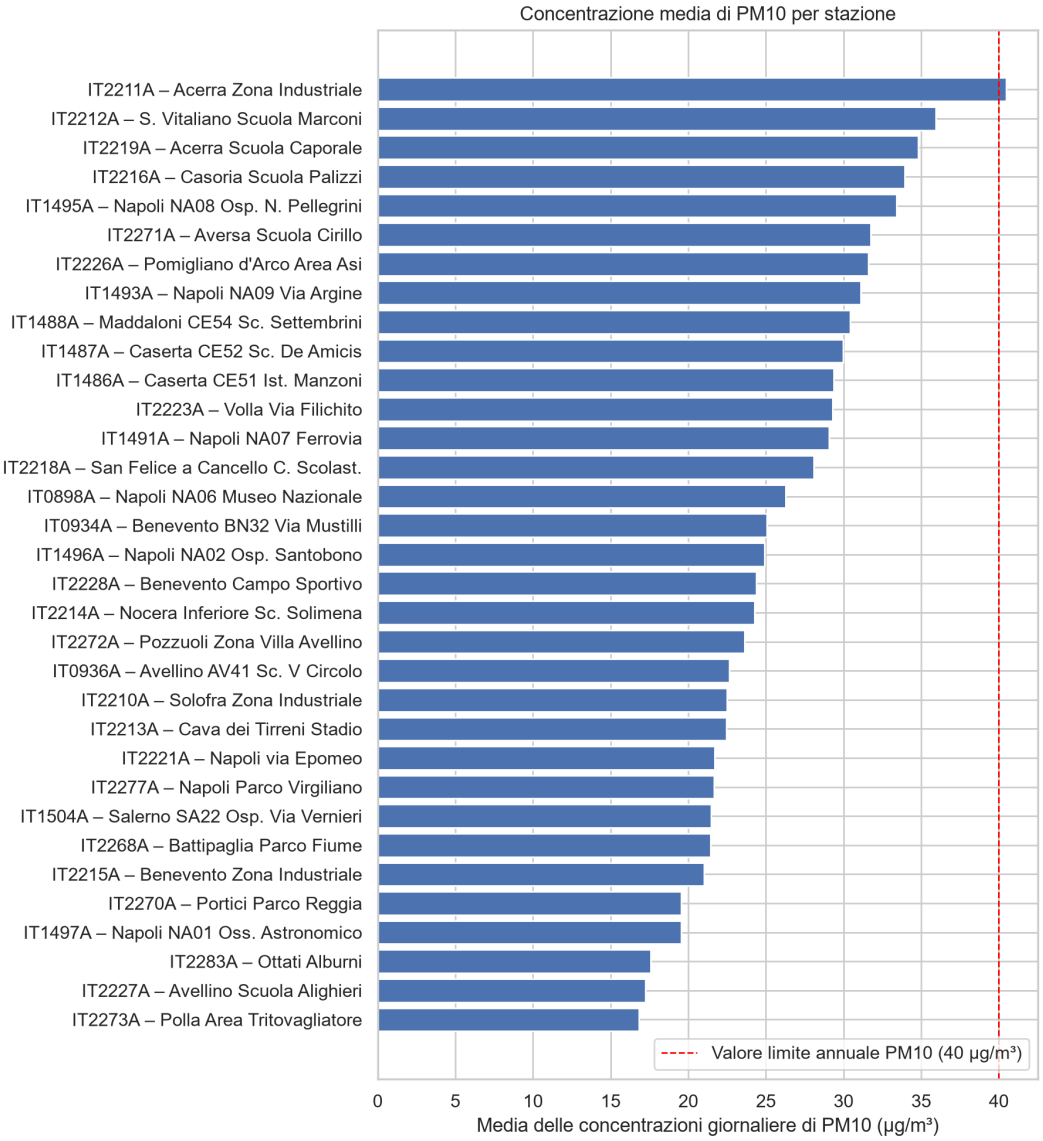


Figura 2.6: *Media delle concentrazioni giornaliere di PM10 per stazione (stazioni con almeno 365 giorni di dati).*

La Figura 2.6 confronta la media delle concentrazioni giornaliere di PM10 delle stazioni con almeno un anno di dati. La linea tratteggiata indica il valore limite annuale di $40\,\mu g/m^3$, riportato come riferimento.

Le differenze tra le stazioni sono marcate, le medie vanno da circa $17\,\mu g/m^3$ a circa $40\,\mu g/m^3$. Le stazioni più inquinate **si concentrano nell'area densamente urbanizzata e industriale a nord-est di Napoli, verso la provincia di Caserta** (Acerra Zona

Industriale) che raggiunge il valore di riferimento di 40 µg/m^3 : San Vitaliano, Acerra Scuola Caporale, Casoria, Aversa e Pomigliano d'Arco.

Le meno inquinate sono le stazioni dell'interno e delle aree rurali (Polla, Ottati Alburni, Avellino Scuola Alighieri) e quelle situate in parchi o in collina (Portici Parco Reggia, Napoli Osservatorio Astronomico).

La presenza di una zona industriale non comporta necessariamente valori elevati: le stazioni di Solofra e Benevento Zona Industriale si collocano nella parte bassa della classifica.

IMPORTANTE: La media della stazione IT1486A (Caserta CE51) è influenzata da alcune giornate dell'agosto–settembre 2024 con valori di PM10 costanti e anomali (tra 1.596 e 2.453 µg/m^3, Sezione 1.4), conservati nel dataset: senza di esse, la sua media scenderebbe a circa 18,9 µg/m^3. La media della stazione IT2272A (Pozzuoli) si riferisce invece a un periodo più breve, a partire da giugno 2024.

2.6 Eventi particolari

2.6.1 La notte di Capodanno

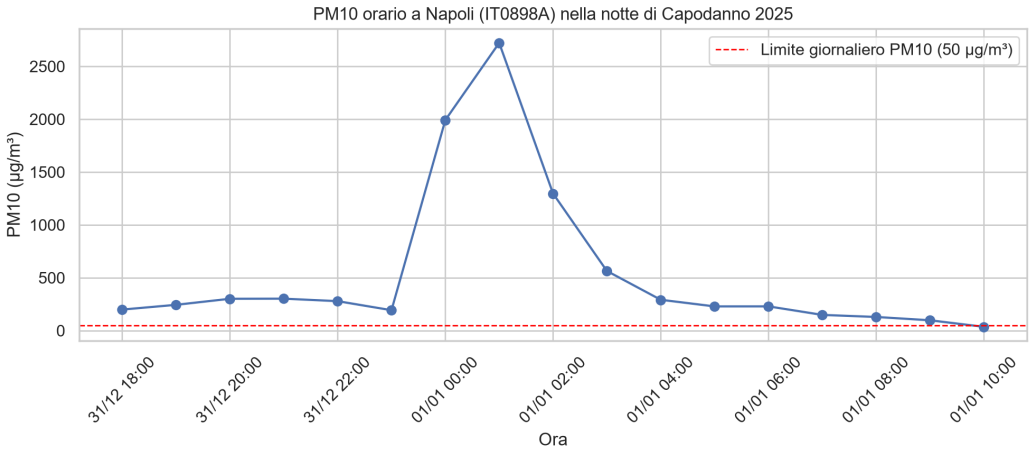


Figura 2.7: *PM10 orario alla stazione IT0898A (Napoli) nella notte di Capodanno 2025. La linea tratteggiata indica il limite giornaliero, riportato come riferimento.*

La Figura 2.7 mostra il PM10 orario alla stazione IT0898A (Napoli, Museo Nazionale) nella notte tra il 31 dicembre 2024 e il 1° gennaio 2025. Già dalle 18:00 del 31 dicembre il PM10 si attesta tra 200 e 300 µg/m^3; sale poi a 1.992 µg/m^3 alle 00:00 e a 2.721,9 µg/m^3 alle 01:00, per tornare gradualmente ai valori abituali, occorrono oltre nove ore perché scenda sotto 50 µg/m^3 (35,8 µg/m^3 alle 10:00). **L'andamento, con una salita e una discesa graduali, è quello tipico di un episodio reale di inquinamento, dovuto ai fuochi d'artificio.** Un episodio analogo, meno intenso, si osserva a Capodanno 2026 alla stazione IT2226A (Pomigliano d'Arco), con un massimo di 793,9 µg/m^3 alle 02:00.

2.6.2 L'episodio del 31 marzo – 1 aprile 2024

Tra il 31 marzo e il 1 aprile 2024 diverse stazioni, anche lontane tra loro, registrano valori giornalieri elevati di PM10 (da 136 a 260 $\mu g/m^3$), che producono il picco più alto della media di rete nell'intero periodo (Figura 2.2). La contemporaneità tra stazioni distanti suggerisce un evento su scala regionale, come un'intrusione di polveri sahariane, frequente in primavera nell'Italia meridionale; **questa ipotesi richiederebbe una verifica con fonti esterne.**

2.7 Correlazioni tra inquinanti

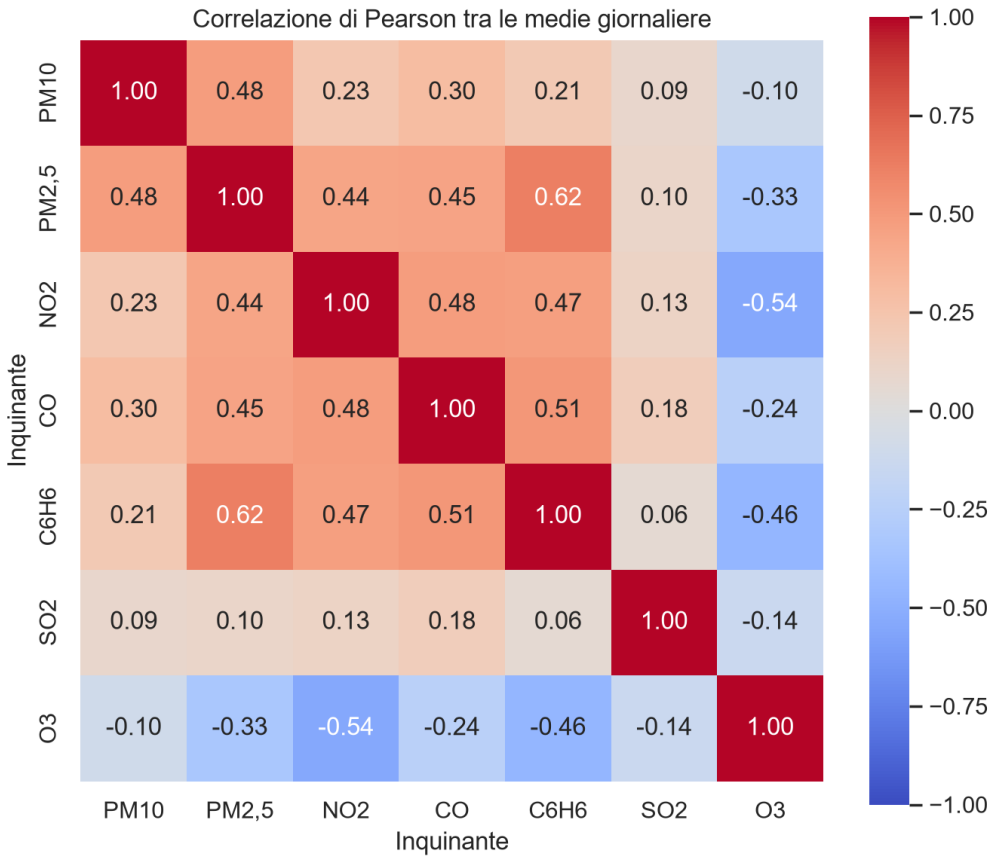


Figura 2.8: *Matrice di correlazione di Pearson tra le medie giornaliere degli inquinanti.*

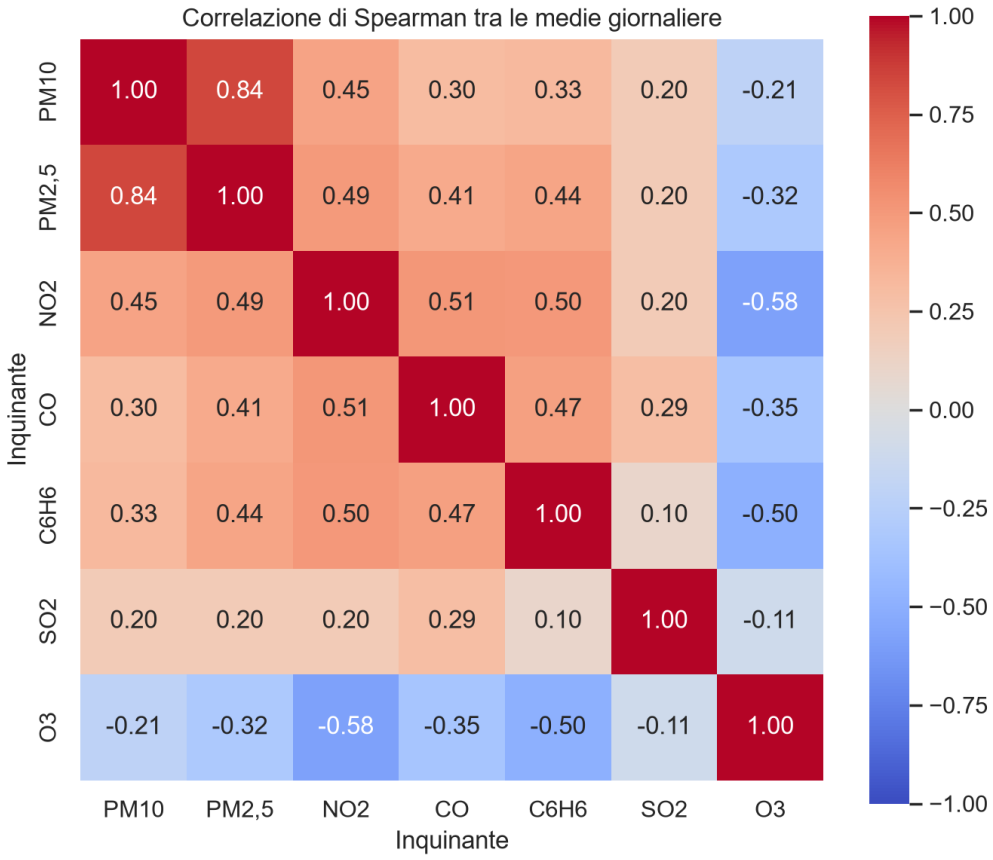


Figura 2.9: *Matrice di correlazione di Spearman tra le medie giornaliere degli inquinanti.*

Le Figure 2.8 e 2.9 riportano le correlazioni tra le medie giornaliere degli inquinanti, calcolate per ogni coppia di stazione e giorno; per ogni coppia di inquinanti sono utilizzate solo le giornate in cui entrambi sono misurati. La correlazione di Pearson misura la relazione lineare tra due variabili, mentre quella di Spearman è calcolata sui ranghi dei valori (la giornata con il valore più basso ha rango 1, la successiva rango 2, e così via) e misura una relazione monotona, è quindi meno sensibile ai valori estremi. Entrambe variano tra -1 (relazione inversa perfetta) e $+1$ (relazione diretta perfetta).

Le due misure concordano per la maggior parte delle coppie. Gli inquinanti legati al traffico (NO_2, CO e benzene) sono correlati positivamente tra loro (circa 0,5), mentre l'ozono è correlato negativamente con tutti gli altri inquinanti, in particolare con l'NO_2 ($-0{,}54$ secondo Pearson, $-0{,}58$ secondo Spearman), in coerenza con l'andamento opposto osservato su scala stagionale, settimanale e giornaliera. L'SO_2 risulta quasi indipendente dagli altri inquinanti (correlazioni comprese tra 0,1 e 0,3), a conferma di sorgenti specifiche, industriali e portuali.

La differenza più marcata riguarda la coppia PM10–PM2,5: la correlazione di Pearson è pari a 0,48, quella di Spearman a 0,84. Poiché il PM2,5 è una frazione del PM10, la seconda descrive meglio il legame tra le due variabili, la correlazione di Pearson è abbassata da pochi valori estremi di PM10 senza corrispondente aumento del PM2,5, come le giornate anomale

della stazione IT1486A conservate nel dataset. Per la coppia benzene–PM2,5 avviene il contrario, la correlazione di Pearson (0,62) è superiore a quella di Spearman (0,44), perché poche giornate in cui entrambi gli inquinanti sono molto elevati ne accentuano la relazione lineare. Data l'asimmetria delle distribuzioni e la presenza di valori estremi, la correlazione di Spearman è la misura più affidabile per questi dati.

2.8 Conclusioni

L'analisi descrittiva ha evidenziato i seguenti risultati principali:

- gli inquinanti presentano una forte **stagionalità**: l'ozono è massimo in estate, mentre NO_2 e PM2,5 sono massimi in inverno; il PM10 presenta anche un secondo massimo estivo, dovuto alle particelle più grossolane;
- il **traffico** è una sorgente importante: gli inquinanti a esso legati diminuiscono nel fine settimana e presentano due massimi giornalieri in corrispondenza delle ore di punta;
- l'**ozono** si comporta in modo opposto all'NO_2 su tutte le scale temporali, come confermato dalla correlazione negativa;
- le **differenze tra stazioni** sono marcate: le medie di PM10 vanno da circa 17 a circa $40\,\mu g/m^3$, con i valori più alti nell'area a nord-est di Napoli;
- alcuni **episodi** (Capodanno, evento di inizio aprile 2024) producono valori molto superiori alla norma.

Questi risultati ci aiutano a comprendere le caratteristiche dei dati e a guidare le scelte metodologiche per i capitoli successivi, in particolare per la classificazione, il clustering e il forecasting.

3 CLASSIFICAZIONE

4 CLUSTERING

5 FORECASTING

6 CONCLUSIONI

Bibliografia

[1] Corte di giustizia dell'Unione europea, "Sentenza del 10 novembre 2020, Commissione europea contro Repubblica italiana, causa C-644/18," 2020.

[2] ARPA Campania, "Dati RQA orari validati." Portale Open Data ARPAC, `https://dati.arpacampania.it/dataset/dati-rqa-giornalieri-validati`, 2026. Licenza CC BY 4.0, consultato il 29/10/2026.

[3] Parlamento europeo e Consiglio dell'Unione europea, "Direttiva 2008/50/CE relativa alla qualità dell'aria ambiente e per un'aria più pulita in Europa." Gazzetta ufficiale dell'Unione europea, 2008. Recepita in Italia con il D.Lgs. 155/2010.

[4] Parlamento europeo e Consiglio dell'Unione europea, "Direttiva (UE) 2024/2881 relativa alla qualità dell'aria ambiente e per un'aria più pulita in Europa (rifusione)." Gazzetta ufficiale dell'Unione europea, 2024.