Università Politecnica delle Marche

Ingegneria Informatica e dell'Automazione

Tecniche di Data Science per l'Analisi della Qualità dell'aria in Campania



Corso di

DATA SCIENCE

Anno accademico 2026-2027

Studenti:

TOYEM TEZEM RYAN PARFAIT

SIMONE MURAZZO

ANDREA SCALZI

MAICOL LANNI

Professore:

DOMENICO URSINO

Dottorando:

BURATTI CHRISTOPHER

Dipartimento di Ingegneria dell'Informazione

Indice

1 Introduzione e dataset **4**
- 1.1 Contesto e obiettivi del progetto . . . 4
- 1.2 Il dataset . . . 5
- 1.3 Struttura dei dati . . . 5
  - 1.3.1 Gli inquinanti . . . 6
  - 1.3.2 I valori limite . . . 6
- 1.4 Pre-processing . . . 7
  - 1.4.1 Colonne eliminate . . . 7
  - 1.4.2 Conversione delle date . . . 7
  - 1.4.3 Valori mancanti codificati . . . 8
  - 1.4.4 Esclusione delle stazioni . . . 8
  - 1.4.5 Valori anomali . . . 9
  - 1.4.6 Il particolato su base giornaliera . . . 10
  - 1.4.7 Dataset finale . . . 10
- 1.5 Qualità e continuità dei dati . . . 10

2 Analisi descrittiva **12**
- 2.1 Introduzione . . . 12
  - 2.1.1 Librerie utilizzate . . . 12
  - 2.1.2 Scala temporale . . . 12
- 2.2 Statistiche descrittive per inquinante . . . 13
- 2.3 Distribuzione dei valori . . . 14
- 2.4 Andamento temporale . . . 15
  - 2.4.1 Andamento complessivo 2023–2026 . . . 15
  - 2.4.2 Stagionalità . . . 16
  - 2.4.3 Ciclo settimanale . . . 17
  - 2.4.4 Ciclo giornaliero . . . 18
- 2.5 Confronto tra stazioni . . . 19
- 2.6 Eventi particolari . . . 20
  - 2.6.1 La notte di Capodanno . . . 20
  - 2.6.2 L'episodio del 31 marzo – 1 aprile 2024 . . . 21
- 2.7 Correlazioni tra inquinanti . . . 21
- 2.8 Conclusioni . . . 23

3 CLASSIFICAZIONE **24**

4 CLUSTERING **25**

5 FORECASTING **26**
5.1 Introduzione . . . 26
5.1.1 Librerie utilizzate . . . 26
5.2 Il problema di forecasting . . . 26
5.3 Preparazione dei dati . . . 28
5.4 Valutazione dei modelli . . . 29
5.4.1 Previsione a un passo con parametri fissi . . . 29
5.4.2 Campione comune . . . 29
5.4.3 Metriche . . . 29
5.5 Baseline . . . 30
5.6 ARIMA . . . 30
5.6.1 Il modello . . . 30
5.6.2 ACF e PACF . . . 31
5.6.3 Scelta dell'ordine . . . 31
5.6.4 Limiti . . . 32
5.7 SARIMAX . . . 32
5.7.1 Componente stagionale . . . 32
5.7.2 Regressori esogeni . . . 32
5.7.3 Risultato . . . 33
5.8 Prophet . . . 33
5.8.1 Il modello . . . 33
5.8.2 Limiti di Prophet . . . 34
5.8.3 Prophet con valori ritardati . . . 34
5.9 XGBoost . . . 34
5.9.1 Il modello . . . 34
5.9.2 Feature utilizzate . . . 35
5.9.3 Un modello globale per inquinante . . . 35
5.9.4 Controllo dell'overfitting . . . 35
5.9.5 Importanza delle feature . . . 36
5.10 Risultati per il PM10 . . . 36
5.10.1 Risultati complessivi . . . 36
5.10.2 Previsioni sul periodo di test . . . 38
5.10.3 Dettaglio: Acerra, gennaio–marzo 2026 . . . 39
5.10.4 Risultati per stazione . . . 40
5.11 Perché i modelli sbagliano i giorni più inquinati . . . 41
5.11.1 Le evidenze . . . 41
5.11.2 Le cause . . . 42
5.12 Gli altri inquinanti . . . 43
5.12.1 Impostazione . . . 43
5.12.2 Quanto si riesce a prevedere . . . 45
5.12.3 I superamenti . . . 48
5.12.4 Cosa guida la previsione . . . 49
5.13 Previsione a sette giorni . . . 50
5.13.1 Previsione a h giorni . . . 50
5.13.2 Come cresce l'errore . . . 51

5.13.3 L'effetto dell'orizzonte sulla previsione 52
5.13.4 I superamenti con anticipo 53
5.13.5 Previsione per il periodo 27 ottobre – 2 novembre 2026 54
5.14 Conclusioni 55
5.14.1 Sviluppi futuri 56
5.15 Riproducibilità 57

6 CONCLUSIONI **58**

1 Introduzione e dataset

1.1 Contesto e obiettivi del progetto

L'inquinamento atmosferico è uno dei principali rischi ambientali per la salute umana. Le particelle sospese e i gas inquinanti, come il biossido di azoto NO_2 e l'ozono (O_3), sono associati a malattie respiratorie e cardiovascolari, e la loro concentrazione nell'aria è per questo regolata da limiti di legge a livello europeo. L'Italia è uno dei Paesi in cui questi limiti vengono superati con maggiore frequenza: nel 2020 la Corte di giustizia dell'Unione europea l'ha condannata per il superamento sistematico e continuato dei valori limite del PM10 in diverse zone del territorio [1]. Il monitoraggio della qualità dell'aria è affidato alle Agenzie regionali per la protezione ambientale (ARPA), che gestiscono reti di stazioni di misura distribuite sul territorio.

In questo progetto analizziamo le misure orarie della rete di monitoraggio della Regione Campania, gestita da ARPA Campania (ARPAC), con l'obiettivo di estrarre conoscenza da dati reali e recenti attraverso le tecniche viste nel corso. Il lavoro si articola in quattro parti:

- **Analisi descrittiva:** esplorare le distribuzioni degli inquinanti, il loro andamento nel tempo, le differenze tra stazioni e le relazioni tra inquinanti;
- **Classificazione:** DA FARE;
- **Clustering:** DA FARE;
- **Forecasting:** DA FARE.

Questo primo capitolo presenta il dataset, la sua struttura e le operazioni di pre-processing che hanno permesso di ottenere i dati puliti utilizzati in tutti i capitoli successivi.



Figura 1.1: *Esempio di stazione di monitoraggio.*

1.2 Il dataset

I dati provengono dal portale Open Data di ARPA Campania [2], che pubblica mensilmente le misure orarie di tutte le stazioni della rete regionale di monitoraggio della qualità dell'aria. Abbiamo scelto questa fonte perché offre dati reali, recenti e pubblicati da un ente istituzionale, con una frequenza di misura (oraria) e una durata (oltre tre anni) adatte sia all'analisi delle serie temporali sia alle tecniche di classificazione e di clustering.

Il portale mette a disposizione due versioni dei dati: i dati *grezzi* (*near real time*), pubblicati quasi in tempo reale, e i dati *validati*, sottoposti ai controlli di qualità dell'agenzia. Abbiamo scelto i dati validati, più affidabili, tenendo conto di qualche lacune nella valutazione della continuità dei dati (Sezione 1.5).

I 44 file mensili, da marzo 2023 a ottobre 2026, sono stati scaricati il 29/10/2026 e concatenati in un unico file. La Tabella 1.1 ne riassume le caratteristiche.

Tabella 1.1: *Caratteristiche del dataset utilizzato.*

Fonte	Portale Open Data ARPA Campania [2]
Dataset	*Dati RQA Orari Validati*
Licenza	CC BY 4.0
Periodo	20/03/2023 – 26/10/2026
File	44 file mensili CSV, concatenati in un unico file (395 MB)
Data del download	29/10/2026
Righe	4.905.168
Codici di stazione	57
Inquinanti	7

1.3 Struttura dei dati

I dati sono organizzati in formato *lungo*: ogni riga corrisponde alla misura di un inquinante, in una stazione, in una determinata ora. La Tabella 1.2 descrive le sette colonne del file.

Tabella 1.2: *Colonne del dataset originale.*

Colonna	**Tipo**	**Descrizione**	**Esempio**
`_id`	intero	numero di riga interno al file mensile	1
`Stazione`	testo	codice europeo (EEA) della stazione	IT2211A
`Descrizione`	testo	nome della stazione	Acerra Zona Industriale
`Inquinante`	testo	inquinante misurato	PM10
`Data_ora`	testo	data, ora e fuso orario	01-09-2023 00:00:00 +01:00
`Valore`	testo	concentrazione misurata	27.1
`Um`	testo	unità di misura	$\mu g/m^3$

Il codice della stazione segue la nomenclatura dell'Agenzia europea dell'ambiente (EEA): le stazioni fisse della rete hanno codici della forma `IT`, seguito da quattro cifre e dalla lettera `A`. Il nome della stazione indica in genere il comune e il luogo di installazione (una scuola, un parco, una zona industriale).

1.3.1 Gli inquinanti

Il dataset contiene le misure di sette inquinanti:

- **PM10 e PM2,5**: particelle sospese con diametro inferiore rispettivamente a 10 µm e a 2,5 µm. **Derivano dal traffico** (gas di scarico, ma anche usura di freni, pneumatici e asfalto), dal riscaldamento domestico, dall'industria e da fonti naturali come la sabbia sahariana. Le PM2,5, più fini, penetrano più in profondità nell'apparato respiratorio;
- **NO_2** (biossido di azoto): gas prodotto dai processi di combustione, in ambito urbano soprattutto dal traffico veicolare;
- **O_3** (ozono): inquinante *secondario*, non emesso direttamente ma formato in atmosfera per effetto della radiazione solare a partire da altri inquinanti; raggiunge per questo i valori più alti in estate;
- **CO** (monossido di carbonio): gas prodotto dalla combustione incompleta, in particolare dei motori dei veicoli;
- **SO_2** (biossido di zolfo): gas legato alla combustione di combustibili contenenti zolfo, in ambito industriale e portuale;
- **C_6H_6** (benzene): composto organico cancerogeno, emesso principalmente dai carburanti e dal traffico.

1.3.2 I valori limite

La Direttiva 2008/50/CE [3], recepita in Italia dal D.Lgs. 155/2010, fissa per ogni inquinante dei *valori limite*: una concentrazione da non superare, calcolata come media su un determinato *periodo di mediazione* (un'ora, un giorno, otto ore o un anno). Per alcuni limiti è consentito un numero massimo di superamenti per anno civile: ad esempio, la media giornaliera del PM10 può superare 50 µg/m^3 al massimo 35 volte all'anno. Per l'ozono la norma fissa invece un *valore obiettivo*, cioè un livello da raggiungere, meno vincolante di un valore limite. La Tabella 1.3 riporta, per ogni inquinante, l'unità di misura, il numero di misure presenti nel dataset e i principali limiti di legge. Questi valori costituiscono un riferimento per interpretare le concentrazioni misurate e definiscono la variabile da prevedere nel capitolo di classificazione. La nuova Direttiva (UE) 2024/2881 prevede limiti più stringenti a partire dal 2030 [4].

Tabella 1.3: *Inquinanti presenti nel dataset e principali valori limite (Direttiva 2008/50/CE).*

Inquinante	Unità	Misure	Periodo di mediazione	Limite	Superamenti/anno
NO_2	µg/m^3	995.793	1 ora	200	18
			anno civile	40	–
PM10	µg/m^3	894.611	24 ore	50	35
			anno civile	40	–
PM2,5	µg/m^3	890.014	anno civile	25	–
C_6H_6	µg/m^3	627.446	anno civile	5	–
O_3	µg/m^3	562.616	massima media mobile su 8 ore	120*	25**
CO	mg/m^3	558.442	massima media mobile su 8 ore	10	–
SO_2	µg/m^3	376.246	1 ora	350	24
			24 ore	125	3

* Valore obiettivo. ** Media su tre anni.

1.4 Pre-processing

L'obiettivo del pre-processing è fornire ai capitoli successivi dati puliti e affidabili, documentando ogni scelta effettuata. Le operazioni sono state svolte in Python con la libreria pandas, in un notebook Jupyter dedicato.

1.4.1 Colonne eliminate

La colonna `_id` è stata eliminata: non identifica le misure, ma è un numero di riga interno a ciascun file mensile, che riparte da 1 ogni mese. Nel file concatenato assume infatti solo 140.415 valori distinti su 4.905.168 righe, esattamente il numero di righe del file più grande, quello di luglio 2026.

La colonna `Um` è costante per ogni inquinante: tutte le concentrazioni sono espresse in µg/m^3, **tranne quelle del CO, espresse in** mg/m^3**(un milligrammo equivale a mille microgrammi)**. La colonna è stata mantenuta per completezza. Questa differenza va considerata quando si confrontano gli inquinanti tra loro: i valori del CO risultano numericamente molto più piccoli degli altri.

1.4.2 Conversione delle date

Il controllo della colonna `Data_ora` ha rivelato la presenza di due formati diversi (Tabella 1.4), il secondo formato riguarda solo le misure dal 7 al 10 ottobre 2025, probabilmente a causa di un cambiamento temporaneo nel sistema di pubblicazione dell'agenzia.

Tabella 1.4: *Formati della colonna* `Data_ora`.

Formato	Esempio	Righe
`gg-mm-aaaa hh:mm:ss +01:00`	26-10-2026 23:00:00 +01:00	4.881.186
`aaaa-mm-gg hh:mm:ss+01`	2025-10-07 01:00:00+01	23.982

Lasciare che pandas riconosca automaticamente il formato avrebbe portato a convertire correttamente solo una parte delle date. Abbiamo quindi letto i due formati in modo esplicito, indicando a pandas la struttura di ciascuno, e unito i risultati, tutte le date sono state convertite in datetime.

Tutte le misure riportano lo stesso fuso orario (UTC+1), le date sono state quindi espresse in ora fissa UTC+1, senza passaggio all'ora legale dunque abbiamo deciso che l'indicazione del fuso doveva essere rimossa. Il periodo coperto va **dal 20/03/2023 alle 00:00 al 26/10/2026 alle 23:00**.

NOTA : La documentazione di ARPAC non specifica se l'orario indichi l'inizio o la fine dell'intervallo di misura. Poiché ogni file mensile inizia alle 00:00 del primo giorno del mese, abbiamo assunto che l'orario indichi l'inizio dell'intervallo, senza applicare correzioni. Segnaliamo tuttavia che il 31/03/2024, giorno del passaggio all'ora legale, alcune stazioni presentano solo 23 ore di misure: ciò suggerisce che gli orari possano seguire in realtà l'ora locale italiana, nonostante l'indicazione UTC+1.

1.4.3 Valori mancanti codificati

Il dataset non contiene celle vuote, ma questo non significa che sia completo, per due motivi.

In primo luogo, le ore in cui una stazione non ha misurato un inquinante non compaiono affatto nel file, l'assenza di una misura corrisponde all'assenza di una riga.

In secondo luogo, una volta convertiti in numeri, i valori della colonna `Valore` hanno rivelato misure non valide codificate con valori negativi:

- 202.303 valori pari a -9999 (circa il 4% delle righe), codice convenzionale di valore mancante;
- 224 altri valori negativi, fisicamente impossibili per una concentrazione: in parte piccoli valori vicini allo zero, dovuti al rumore degli strumenti, in parte valori chiaramente errati (fino a $-104{,}1\ \mu g/m^3$ per l'O_3).

Lasciati nel dataset, questi valori avrebbero falsato qualsiasi media, **un solo -9999 in una giornata basterebbe a rendere fortemente negativa la media giornaliera**. I 202.527 valori negativi sono stati quindi sostituiti con `NaN`, il valore mancante di pandas, che viene ignorato automaticamente nel calcolo delle medie. Le righe sono state invece conservate, per non interrompere la struttura delle serie temporali.

1.4.4 Esclusione delle stazioni

Dei 57 codici di stazione presenti, 21 non sono adatti alle analisi del progetto (Tabella 1.5).

Tabella 1.5: *Stazioni escluse dall'analisi.*

Stazioni	Motivo
Laboratori mobili (LM01, LM03, MMA61, MMB62), impianti STIR, EDI01, EDI02	stazioni non fisse, presenti solo dal 7 al 18 ottobre 2025
IT2220A, IT2222A, IT2224A, IT2225A, IT2342A	installate a marzo 2026: circa 7 mesi di dati, senza un inverno completo
IT2269A (Salerno Parco Mercatello)	dismessa ad agosto 2023, meno di 5 mesi di dati

Le stazioni installate nel 2026 meritano una precisione. Le loro misure non sono errate e, nel periodo marzo-ottobre 2026, sono confrontabili con quelle delle altre stazioni. Tuttavia, poiché gli inquinanti hanno un forte andamento stagionale (il particolato e l'NO_2 raggiungono i valori massimi in inverno, l'ozono in estate), stazioni prive di dati invernali avrebbero medie non confrontabili con quelle delle stazioni attive per più anni. Abbiamo escluso anche la stazione IT2269A, dismessa dopo pochi mesi, e mantenuto invece la stazione IT2272A (Pozzuoli), attiva da giugno 2024: la scelta di includerla o meno è lasciata ai singoli capitoli, in base al periodo analizzato.

L'esclusione ha eliminato 134.842 righe; restano **36 stazioni**.

1.4.5 Valori anomali

I valori massimi di alcuni inquinanti sono risultati del tutto irrealistici: fino a 1.437.008 µg/m^{3}per il PM10, mentre anche gli episodi di inquinamento più intensi raramente superano poche centinaia di µg/m^3. Non abbiamo però applicato una soglia automatica, perché alcuni valori estremi corrispondono a fenomeni reali. Per ogni valore sospetto abbiamo invece osservato il contesto, cioè le misure delle ore precedenti e successive nella stessa stazione:

- un valore *isolato*, circondato da valori normali o mancanti, è stato considerato un errore di misura;
- un picco con una salita e una discesa graduali, distribuite su più ore, è stato considerato un episodio reale di inquinamento.

I quattro valori della Tabella 1.6 sono stati sostituiti con `NaN`. In tutti i casi il valore anomalo compare isolato, tra ore senza misure o con valori normali, ad esempio il valore di 1.437.008 µg/m^{3}della stazione IT1504A è l'unica misura di una mattinata in cui lo strumento registra solo -9999, mentre il PM2,5 della stazione IT0934A passa da circa 20 µg/m^3 a 17.792,5 e poi a 101.090 µg/m^3, per tornare a valori normali nel pomeriggio.

Tabella 1.6: *Valori anomali sostituiti con `NaN`.*

Stazione	Inquinante	Data e ora	Valore (µg/m^3)
IT1504A	PM10	01/09/2023 09:00	1.437.008
IT1493A	NO_2	22/11/2024 23:00	4.992,6
IT0934A	PM2,5	13/06/2025 10:00	17.792,5
IT0934A	PM2,5	13/06/2025 12:00	101.090

Al contrario, il picco di PM10 registrato a Napoli nella notte di Capodanno (stazione IT0898A) è stato conservato, la concentrazione sale nel corso della serata, raggiunge 2.721,9 µg/m^3 all'01:00 del 01/01/2025 e torna gradualmente ai valori abituali nel corso della mattinata. Si tratta dell'effetto dei fuochi d'artificio. Anche i valori elevati del PM10 alla stazione IT2226A intorno a mezzogiorno del 01/01/2026 sono stati conservati.

NOTA : Segnaliamo infine la stazione IT1486A, che tra agosto e settembre 2024 registra per alcune giornate intere un valore di PM10 costante e molto elevato (tra 1.596 e 2.453 µg/m^3). **Questi valori non sono stati modificati, ma vanno considerati con cautela nelle analisi**.

1.4.6 Il particolato su base giornaliera

Cercando eventuali strumenti bloccati, abbiamo contato le giornate in cui una stazione registra lo stesso valore per tutte le ore disponibili (almeno 18). Il risultato varia molto da un inquinante all'altro: 5.965 giornate per il PM10 e 6.164 per il PM2,5, contro 2 per l'NO_2 e 2 per l'O_3 (e alcune centinaia per CO, SO_2 e benzene, i cui valori sono spesso bassi e misurati con una precisione limitata). Se si trattasse di guasti, colpirebbero tutti gli inquinanti in modo simile. **La spiegazione più probabile è invece il metodo di misura, sicuramente in molte stazioni il particolato viene misurato su base giornaliera, raccogliendo le particelle su un filtro per 24 ore, e il valore giornaliero viene poi ripetuto per tutte le ore della giornata**.

Queste giornate costanti sono quindi misure valide e sono state conservate. Ne segue però che, per queste stazioni, il PM10 e il PM2,5 non hanno un vero profilo orario: **il particolato verrà analizzato a scala giornaliera**.

1.4.7 Dataset finale

Il dataset pulito è stato salvato in formato Parquet, più compatto e veloce da leggere di un file CSV, che conserva inoltre i tipi delle colonne (date e numeri). Le sue caratteristiche sono:

- file `data/processed/aria_campania_orario.parquet`, in formato lungo e a frequenza oraria;
- 4.770.326 righe, 36 stazioni, 7 inquinanti;
- colonne `Stazione`, `Descrizione`, `Inquinante`, `Data_ora`, `Valore`, `Um`;
- periodo dal 20/03/2023 al 26/10/2026.

Per identificare le stazioni va usato il codice (`Stazione`) e non il nome, la colonna `Descrizione` riporta infatti nomi diversi per la stessa stazione a seconda del mese (ad esempio "Casoria Scuola Palizzi" e "Casoria Scuola Palizzi (CAM)").

1.5 Qualità e continuità dei dati

La Figura 1.2 mostra, per ogni stazione e ogni mese, la quota di giorni in cui è disponibile almeno una misura di PM10. La figura è stata prodotta prima dell'esclusione delle stazioni e include quindi anche le stazioni escluse, visibili come righe quasi interamente rosse.

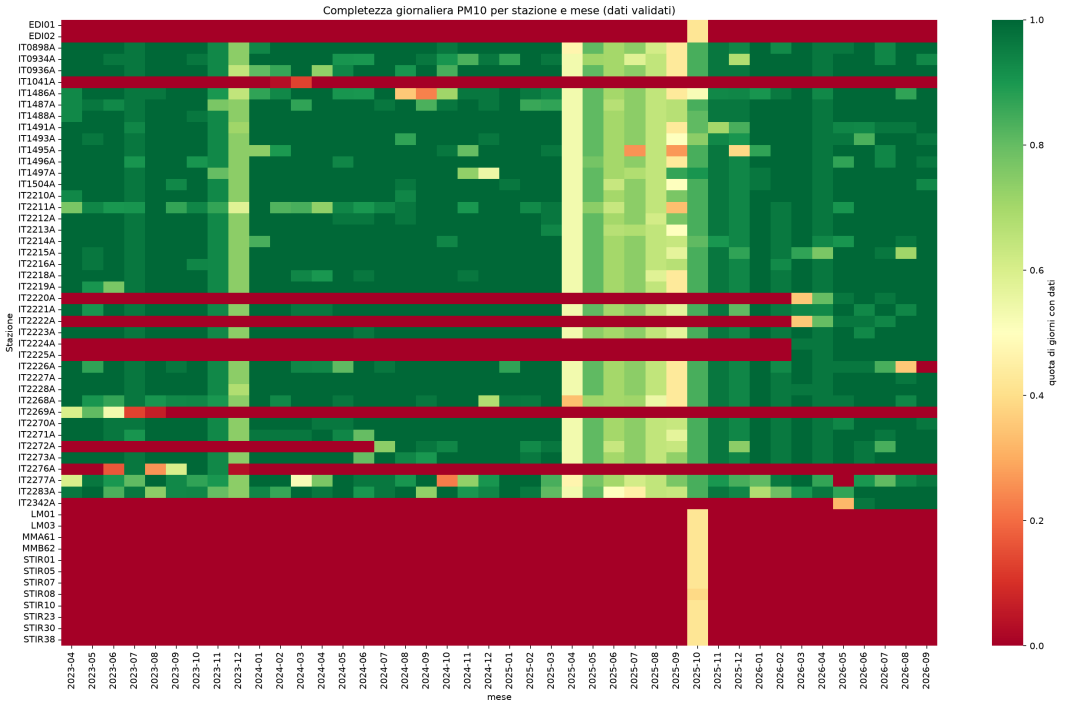


Figura 1.2: *Completezza giornaliera del PM10 per stazione e mese.*

Per la maggior parte delle stazioni la copertura è molto buona, 31 stazioni hanno dati di PM10 per l'86-94% dei giorni. Le lacune più evidenti (dicembre 2023, aprile 2025 e il periodo maggio-ottobre 2025) colpiscono tutte le stazioni contemporaneamente, non sono quindi dovute a guasti dei singoli strumenti, ma alla pubblicazione o alla validazione dei dati da parte dell'agenzia. Per questo motivo non possono essere colmate con le misure delle stazioni vicine.

IMPORTANTE : Non tutte le stazioni misurano tutti gli inquinanti. La Tabella 1.7 riporta, per ogni inquinante, il numero di stazioni con dati disponibili per almeno l'80% dei giorni: il NO_2 e i particolati PM sono misurati in quasi tutte le stazioni, mentre l'ozono e soprattutto il biossido di zolfo solo in una parte della rete.

Tabella 1.7: *Stazioni con almeno l'80% dei giorni con dati (aprile 2023 – settembre 2026).*

	NO_2	PM10	PM2,5	C_6H_6	CO	O_3	SO_2
Stazioni	35	32	32	23	20	19	13

Per l'analisi delle serie temporali, la continuità del periodo aprile 2023 – marzo 2025 è buona, mancano solo 11 giorni su 731 (1,5%) in cui nessuna stazione ha misurato il PM10, con al massimo 3 giorni consecutivi (21–23 dicembre 2023). Si tratta di lacune brevi, che possono essere colmate per interpolazione.

2 Analisi descrittiva

2.1 Introduzione

Questo capitolo esplora i dati puliti ottenuti con il pre-processing (Capitolo 1), con l'obiettivo di descrivere le distribuzioni degli inquinanti, il loro andamento nel tempo, le differenze tra le stazioni e le relazioni tra inquinanti.

2.1.1 Librerie utilizzate

L'analisi è stata svolta in Python, in un notebook Jupyter dedicato, con le seguenti librerie:

- **pandas**: lettura del dataset in formato Parquet, filtri, raggruppamenti e calcolo delle medie giornaliere, mensili e orarie;
- **NumPy**: operazioni numeriche e gestione dei valori mancanti;
- **Matplotlib** e **Seaborn**: realizzazione dei grafici (boxplot, serie temporali, grafici a barre e mappe di calore);
- **SciPy**: utilizzata da pandas per il calcolo della correlazione di Spearman.

2.1.2 Scala temporale

La maggior parte delle analisi utilizza le *medie giornaliere* di ciascun inquinante in ciascuna stazione. Questa è la scala dei valori limite giornalieri ed è l'unica significativa per il particolato, il cui valore in molte stazioni è giornaliero e ripetuto su tutte le ore (Sezione 1.4). Seguendo il criterio adottato dalla normativa europea, una media giornaliera è considerata valida solo se calcolata su almeno 18 ore di misure (75% della giornata). Solo il profilo orario (Sezione 2.4) utilizza i dati orari, e solo per i gas.

Nei grafici che mostrano l'andamento complessivo della regione si utilizza la *media di rete*, cioè la media delle medie giornaliere di tutte le stazioni disponibili in un determinato giorno. Poiché il numero di stazioni attive varia leggermente nel tempo (guasti, attivazione della stazione IT2272A a giugno 2024), la media di rete non è calcolata ogni giorno esattamente sulle stesse stazioni; ciò non altera tuttavia la lettura degli andamenti generali.

2.2 Statistiche descrittive per inquinante

Tabella 2.1: *Statistiche descrittive delle medie giornaliere per inquinante (µg/m³, CO in* mg/m³*).*

Inquinante	N	Media	Dev. std.	Min	25%	Mediana	75%	Max
PM10	35.057	26,1	30,2	0,0	14,8	21,8	31,4	2.453,0
PM2,5	35.186	13,9	12,0	0,0	7,5	11,4	16,8	345,0
NO_2	38.913	23,0	14,8	0,0	12,1	20,3	31,0	212,9
O_3	21.635	56,1	23,0	0,0	39,7	56,5	71,6	529,0
CO	21.678	0,5	0,3	0,0	0,3	0,4	0,6	18,4
SO_2	14.392	2,8	3,5	0,0	1,0	2,2	3,7	289,5
C_6H_6	24.309	1,0	1,0	0,0	0,4	0,7	1,2	22,2

Le colonne della Tabella 2.1 hanno il seguente significato:

- **N**: numero di medie giornaliere valide (coppie stazione-giorno);
- **Media**: media aritmetica delle medie giornaliere;
- **Dev. std.**: deviazione standard, che misura quanto i valori si discostano in media dalla media: più è alta, più le concentrazioni sono variabili;
- **Min** e **Max**: valore minimo e massimo osservati;
- **25%**: primo quartile, cioè il valore al di sotto del quale si trova il 25% delle giornate;
- **Mediana**: valore che divide le giornate in due metà uguali (il 50% delle giornate ha un valore inferiore, il 50% superiore); a differenza della media, non è influenzata dai valori estremi;
- **75%**: terzo quartile, cioè il valore al di sotto del quale si trova il 75% delle giornate.

Quando la media è nettamente superiore alla mediana, la distribuzione è asimmetrica a destra: la maggior parte delle giornate presenta valori bassi, ma alcune giornate con valori molto elevati alzano la media.

Il numero di medie giornaliere varia molto tra gli inquinanti, poiché non tutte le stazioni li misurano tutti: da 38.913 per l'NO_2, misurato in quasi tutta la rete, a 14.392 per l'SO_2. Per tutti gli inquinanti la media è superiore alla mediana, segno di distribuzioni asimmetriche a destra. Il caso più evidente è il PM10: la media (26,1 µg/m³) supera la mediana (21,8 µg/m³) e la deviazione standard (30,2) è superiore alla media stessa, per effetto di pochi valori estremi, come le giornate anomale della stazione IT1486A, che determinano il massimo di 2.453 µg/m³. Al contrario, l'intervallo tra primo e terzo quartile, da 14,8 a 31,4 µg/m³, descrive bene le giornate abituali.

Alcuni valori massimi appaiono poco plausibili anche come medie giornaliere, **in particolare** 529 µg/m³ **per l'ozono e** 289,5 µg/m³ **per l'SO_2**. Questi valori, non individuati durante il pre-processing, riguardano un numero molto limitato di giornate e non modificano mediane e quartili, ma vanno tenuti presenti nei capitoli successivi.

2.3 Distribuzione dei valori

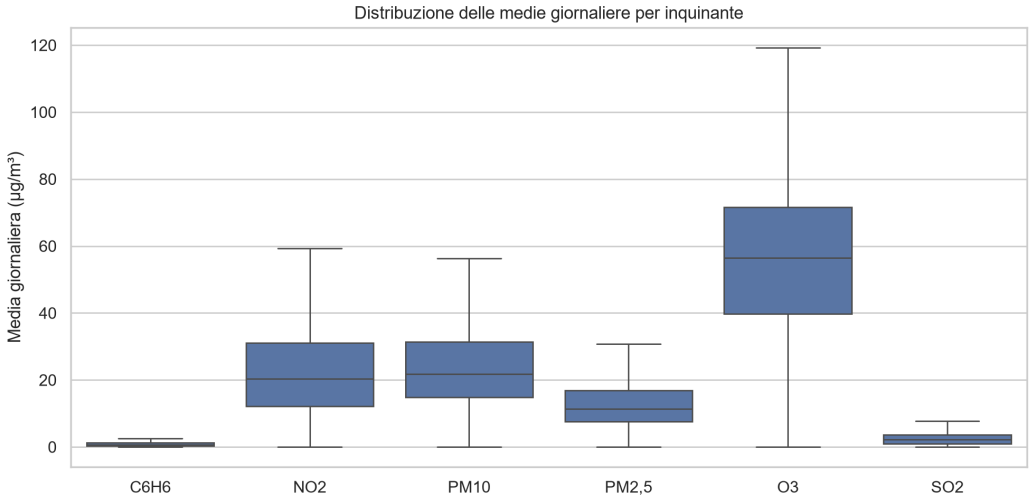


Figura 2.1: *Distribuzione delle medie giornaliere per inquinante (CO escluso, perché misurato in* $\mathrm{mg/m^3}$*; valori estremi non rappresentati).*

La Figura 2.1 confronta le distribuzioni delle medie giornaliere tramite boxplot: la linea interna a ciascun rettangolo indica la mediana, **il rettangolo contiene il 50% centrale delle giornate (dal primo al terzo quartile)** e i segmenti si estendono fino ai valori più lontani non considerati estremi. Per leggibilità, i valori estremi non sono rappresentati; il CO è escluso perché misurato in un'unità diversa ($\mathrm{mg/m^3}$).

L'ozono presenta le concentrazioni più elevate (mediana di circa $56\,\mu\mathrm{g/m^3}$, con metà delle giornate tra 40 e $72\,\mu\mathrm{g/m^3}$) e la dispersione maggiore, coerente con la sua forte stagionalità (Sezione 2.4). L'NO_2 e il PM10 hanno livelli simili, con mediane intorno a 20–$22\,\mu\mathrm{g/m^3}$; il segmento superiore del PM10 supera il limite giornaliero di $50\,\mu\mathrm{g/m^3}$, ma oltre il terzo quartile (circa $31\,\mu\mathrm{g/m^3}$), i superamenti riguardano quindi una minoranza di giornate. Questa informazione è rilevante per la classificazione, perché le due classi (superamento e non superamento) risulteranno sbilanciate. Il PM2,5 vale circa la metà del PM10 (mediana di circa $11\,\mu\mathrm{g/m^3}$), mentre l'SO_2 e il benzene restano su valori molto bassi, lontani dai rispettivi limiti.

2.4 Andamento temporale

2.4.1 Andamento complessivo 2023–2026

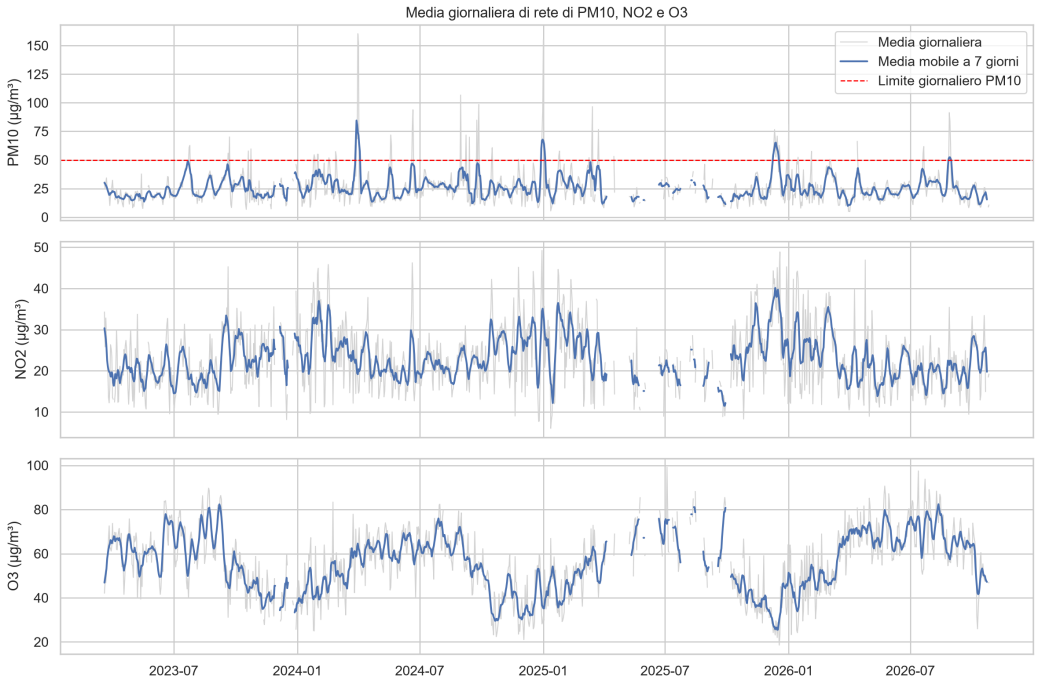


Figura 2.2: *Media giornaliera di rete di PM10, NO_2 e O_3 (in grigio) e media mobile centrata a 7 giorni.*

La Figura 2.2 mostra la media giornaliera di rete di PM10, NO_2 e O_3. Per rendere leggibile l'andamento di lungo periodo, ai valori giornalieri (in grigio) è sovrapposta la media mobile centrata a 7 giorni, in cui ogni giorno è sostituito dalla media dei sette giorni che lo circondano, questa attenua le fluttuazioni giornaliere e il ciclo settimanale, **mettendo in evidenza le variazioni stagionali. I giorni mancanti non sono interpolati, così che le lacune dei dati restino visibili**.

L'ozono (Troposfera: l'ozono "inquinante") presenta una stagionalità molto marcata e regolare, raggiunge 70–80 µg/m^3 in estate e scende intorno a 30 µg/m^3 in inverno, per effetto della radiazione solare che ne favorisce la formazione. L'NO_2 segue l'andamento opposto, con valori massimi in inverno (35–40 µg/m^3) e minimi in estate.

Il PM10 mostra una stagionalità meno evidente, i valori abituali restano tra 15 e 35 µg/m^3, ma emergono alcuni episodi intensi, tra cui l'evento dell'inizio di aprile 2024 e le notti di Capodanno del 2025 e del 2026 (Sezione 2.6). La media di rete supera il limite giornaliero di 50 µg/m^3 solo durante questi episodi, mentre singole stazioni possono superarlo anche quando la media di rete resta inferiore.

Il grafico rende visibili anche le lacune della rete descritte nella Sezione 1.5, in particolare il periodo frammentato tra aprile e ottobre 2025. Il periodo aprile 2023 – marzo 2025 si conferma il più continuo.

2.4.2 Stagionalità

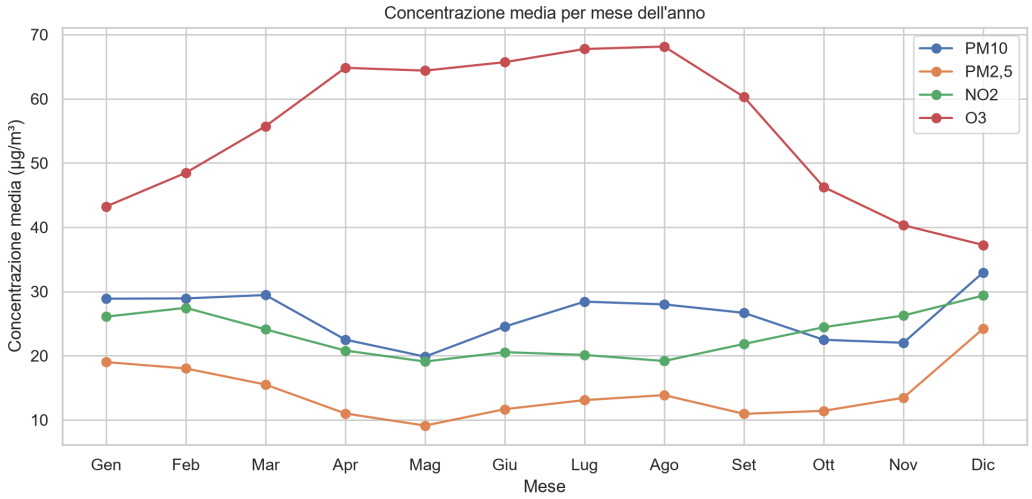


Figura 2.3: *Concentrazione media di PM10, PM2,5, NO_2 e O_3 per mese dell'anno.*

La Figura 2.3 riporta la concentrazione media di ciascun inquinante per mese dell'anno, raggruppando gli stessi mesi di anni diversi. L'ozono raggiunge i valori massimi in luglio e agosto (circa 68 µg/m^3) e i minimi in dicembre (circa 37 µg/m^3), quasi dimezzandosi. L'NO_2 segue l'andamento opposto, con il massimo in dicembre (circa 29 µg/m^3) e i minimi in maggio e agosto (circa 19 µg/m^3), in inverno la maggiore stabilità dell'atmosfera, con frequenti inversioni termiche, ostacola la dispersione degli inquinanti, mentre in estate parte dell'NO_2 è consumata nella formazione dell'ozono.

Il PM2,5 è nettamente più elevato in inverno (circa 24 µg/m^3 in dicembre, contro 9 µg/m^3 in maggio), **in coerenza con il contributo della combustione e del riscaldamento domestico**. Il PM10 presenta invece due massimi: uno invernale, analogo a quello del PM2,5, e uno estivo, in luglio e agosto, assente nel PM2,5. Il rapporto PM2,5/PM10 scende infatti da circa 0,7 in dicembre a circa 0,5 nei mesi estivi, in estate prevalgono le particelle più grossolane, tra 2,5 e 10 µm, riconducibili **ad esempio alle polveri sahariane, alla risospensione del suolo secco e al sale marino**.

Va osservato che i mesi non sono rappresentati in modo uniforme: i dati iniziano a marzo 2023, terminano a ottobre 2026 e presentano ampie lacune tra aprile e ottobre 2025. Alcuni mesi, come dicembre, sono quindi rappresentati da un numero limitato di anni, e un singolo episodio intenso può influenzarne sensibilmente la media.

2.4.3 Ciclo settimanale

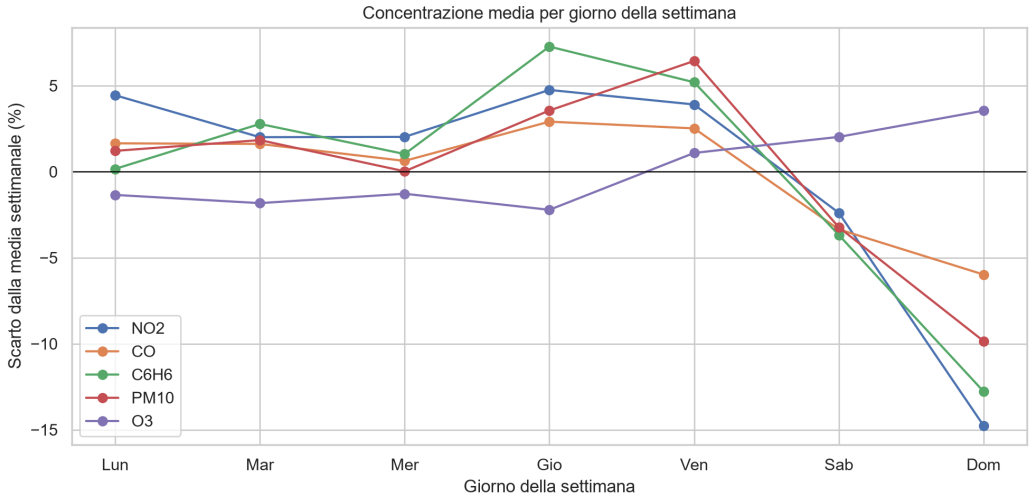


Figura 2.4: *Scarto percentuale della concentrazione media di ciascun giorno della settimana rispetto alla media settimanale.*

La Figura 2.4 riporta, per ogni inquinante, lo scarto percentuale della concentrazione media di ciascun giorno della settimana rispetto alla media settimanale; questa rappresentazione permette di confrontare inquinanti con livelli e unità di misura diversi. Gli inquinanti legati al traffico mostrano un netto calo nel fine settimana, la domenica l'NO_2 è inferiore alla media di circa il 15%, il benzene di circa il 13% e il CO di circa il 6%, mentre nei giorni feriali restano al di sopra della media, con i valori più alti tra giovedì e venerdì. Anche il PM10 diminuisce la domenica (circa -10%), a **conferma del contributo del traffico al particolato (emissioni dei veicoli, usura di freni e pneumatici, risospensione delle polveri stradali)**.

L'ozono segue l'andamento opposto, con valori inferiori alla media nei giorni feriali e superiori nel fine settimana (circa +3,5% la domenica). con meno traffico.

In ambito urbano viene consumato meno ozono dalle emissioni dei veicoli ("effetto weekend").

2.4.4 Ciclo giornaliero

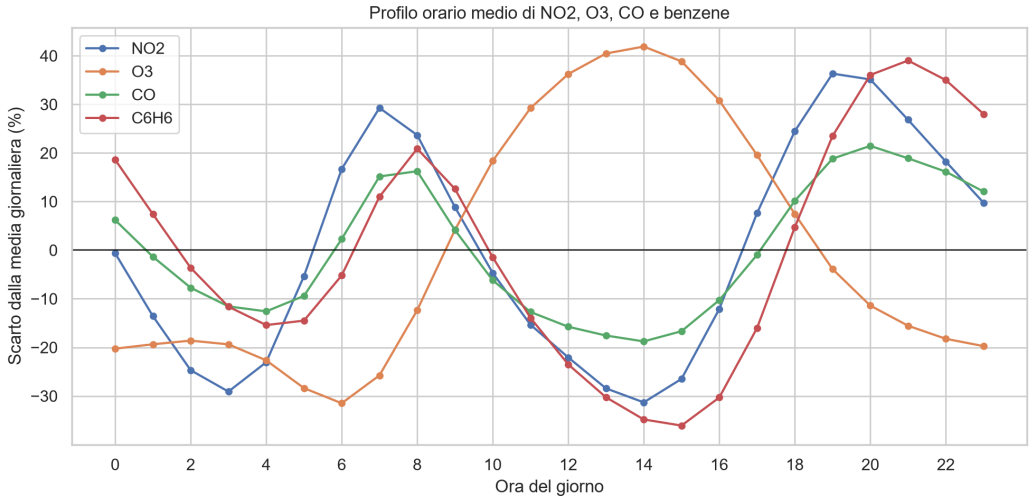


Figura 2.5: *Profilo orario medio di NO_2, O_3, CO e benzene, espresso come scarto percentuale dalla media giornaliera.*

La Figura 2.5 mostra il profilo orario medio dei gas, espresso come scarto percentuale dalla media giornaliera. Il particolato è escluso da questa analisi, poiché in molte stazioni il suo valore è giornaliero e ripetuto su tutte le ore.

L'NO_2, il CO e il benzene presentano due massimi, in corrispondenza delle ore di punta del traffico, il primo al mattino, intorno alle 7–8 (circa +29% per l'NO_2), il secondo, più intenso, in serata, tra le 19 e le 21 (circa +36% per l'NO_2 e +39% per il benzene).

L'ozono segue un andamento opposto: è minimo all'alba (circa −31%) e raggiunge il massimo nel primo pomeriggio (circa +42% intorno alle 14), quando la radiazione solare è più intensa; in serata diminuisce rapidamente, consumato dalle emissioni del traffico.

Poiché la documentazione ARPAC non chiarisce se l'orario indichi l'inizio o la fine dell'intervallo di misura, né se tenga conto dell'ora legale, gli orari dei massimi e dei minimi vanno letti con un'incertezza di circa un'ora.

2.5 Confronto tra stazioni

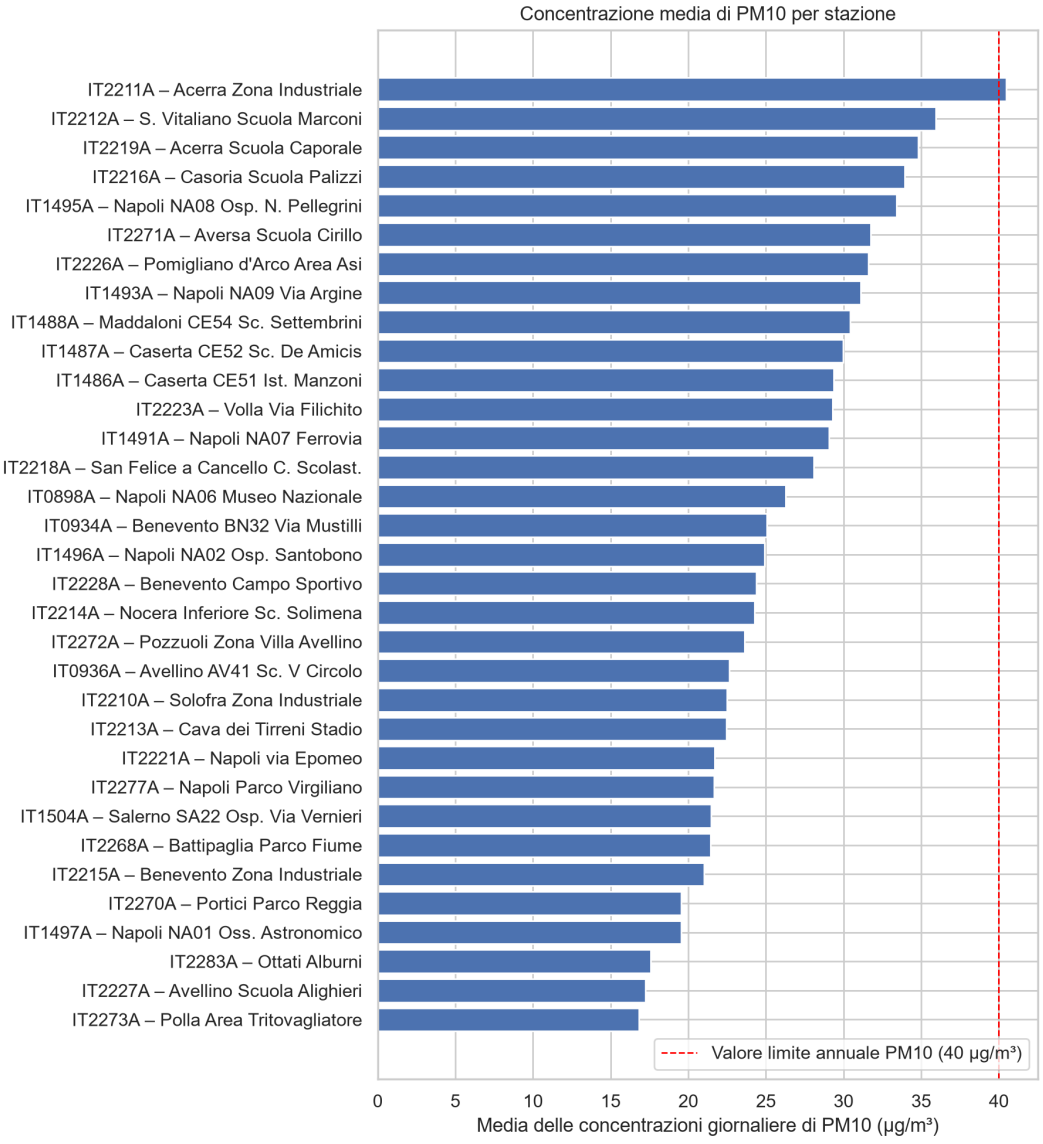


Figura 2.6: *Media delle concentrazioni giornaliere di PM10 per stazione (stazioni con almeno 365 giorni di dati).*

La Figura 2.6 confronta la media delle concentrazioni giornaliere di PM10 delle stazioni con almeno un anno di dati. La linea tratteggiata indica il valore limite annuale di $40\,\mu g/m^3$, riportato come riferimento.

Le differenze tra le stazioni sono marcate, le medie vanno da circa $17\,\mu g/m^3$ a circa $40\,\mu g/m^3$. Le stazioni più inquinate **si concentrano nell'area densamente urbanizzata e industriale a nord-est di Napoli, verso la provincia di Caserta** (Acerra Zona

Industriale) che raggiunge il valore di riferimento di 40 µg/m^3 : San Vitaliano, Acerra Scuola Caporale, Casoria, Aversa e Pomigliano d'Arco.

Le meno inquinate sono le stazioni dell'interno e delle aree rurali (Polla, Ottati Alburni, Avellino Scuola Alighieri) e quelle situate in parchi o in collina (Portici Parco Reggia, Napoli Osservatorio Astronomico).

La presenza di una zona industriale non comporta necessariamente valori elevati: le stazioni di Solofra e Benevento Zona Industriale si collocano nella parte bassa della classifica.

IMPORTANTE: La media della stazione IT1486A (Caserta CE51) è influenzata da alcune giornate dell'agosto–settembre 2024 con valori di PM10 costanti e anomali (tra 1.596 e 2.453 µg/m^3, Sezione 1.4), conservati nel dataset: senza di esse, la sua media scenderebbe a circa 18,9 µg/m^3. La media della stazione IT2272A (Pozzuoli) si riferisce invece a un periodo più breve, a partire da giugno 2024.

2.6 Eventi particolari

2.6.1 La notte di Capodanno

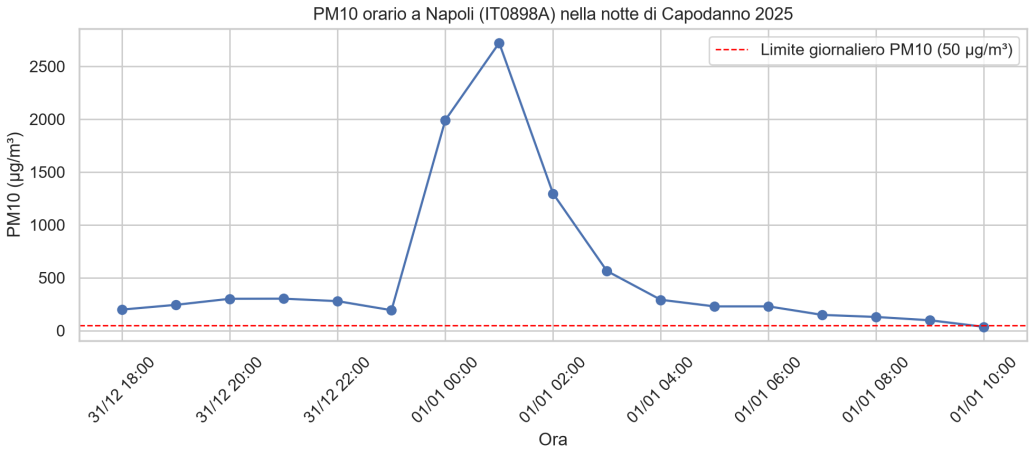


Figura 2.7: *PM10 orario alla stazione IT0898A (Napoli) nella notte di Capodanno 2025. La linea tratteggiata indica il limite giornaliero, riportato come riferimento.*

La Figura 2.7 mostra il PM10 orario alla stazione IT0898A (Napoli, Museo Nazionale) nella notte tra il 31 dicembre 2024 e il 1° gennaio 2025. Già dalle 18:00 del 31 dicembre il PM10 si attesta tra 200 e 300 µg/m^3; sale poi a 1.992 µg/m^3 alle 00:00 e a 2.721,9 µg/m^3 alle 01:00, per tornare gradualmente ai valori abituali, occorrono oltre nove ore perché scenda sotto 50 µg/m^3 (35,8 µg/m^3 alle 10:00). **L'andamento, con una salita e una discesa graduali, è quello tipico di un episodio reale di inquinamento, dovuto ai fuochi d'artificio.** Un episodio analogo, meno intenso, si osserva a Capodanno 2026 alla stazione IT2226A (Pomigliano d'Arco), con un massimo di 793,9 µg/m^3 alle 02:00.

2.6.2 L'episodio del 31 marzo – 1 aprile 2024

Tra il 31 marzo e il 1 aprile 2024 diverse stazioni, anche lontane tra loro, registrano valori giornalieri elevati di PM10 (da 136 a 260 $\mu g/m^3$), che producono il picco più alto della media di rete nell'intero periodo (Figura 2.2). La contemporaneità tra stazioni distanti suggerisce un evento su scala regionale, come un'intrusione di polveri sahariane, frequente in primavera nell'Italia meridionale; **questa ipotesi richiederebbe una verifica con fonti esterne.**

2.7 Correlazioni tra inquinanti

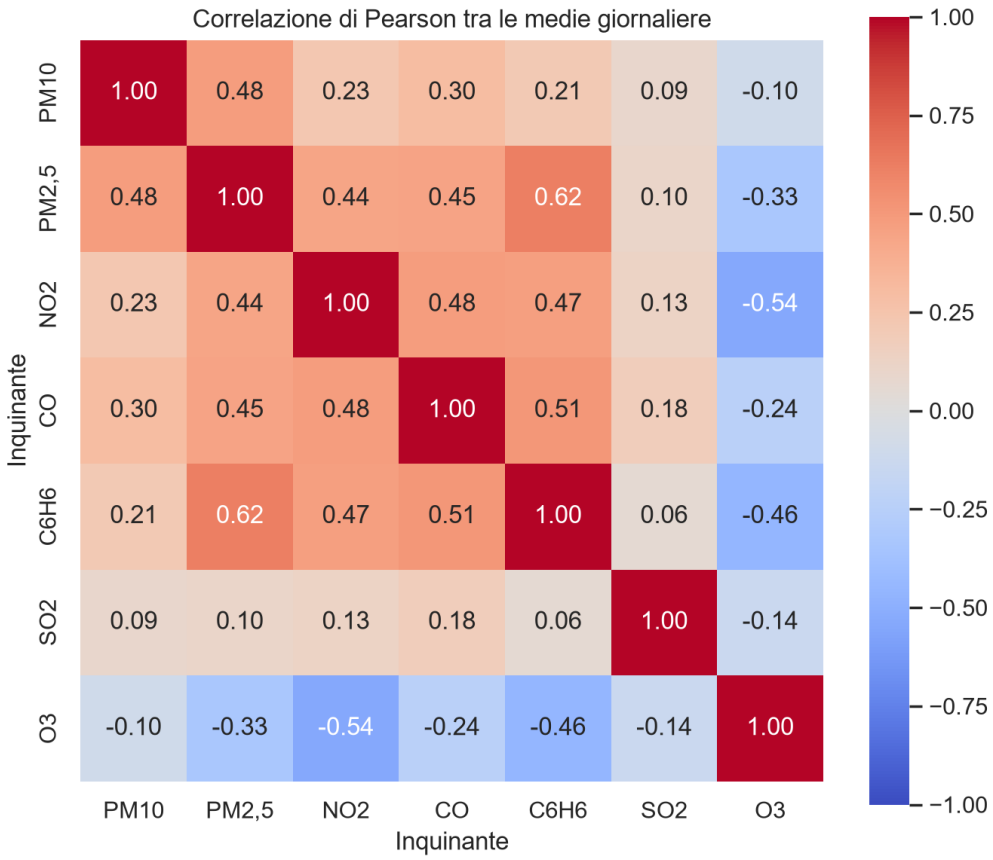


Figura 2.8: *Matrice di correlazione di Pearson tra le medie giornaliere degli inquinanti.*

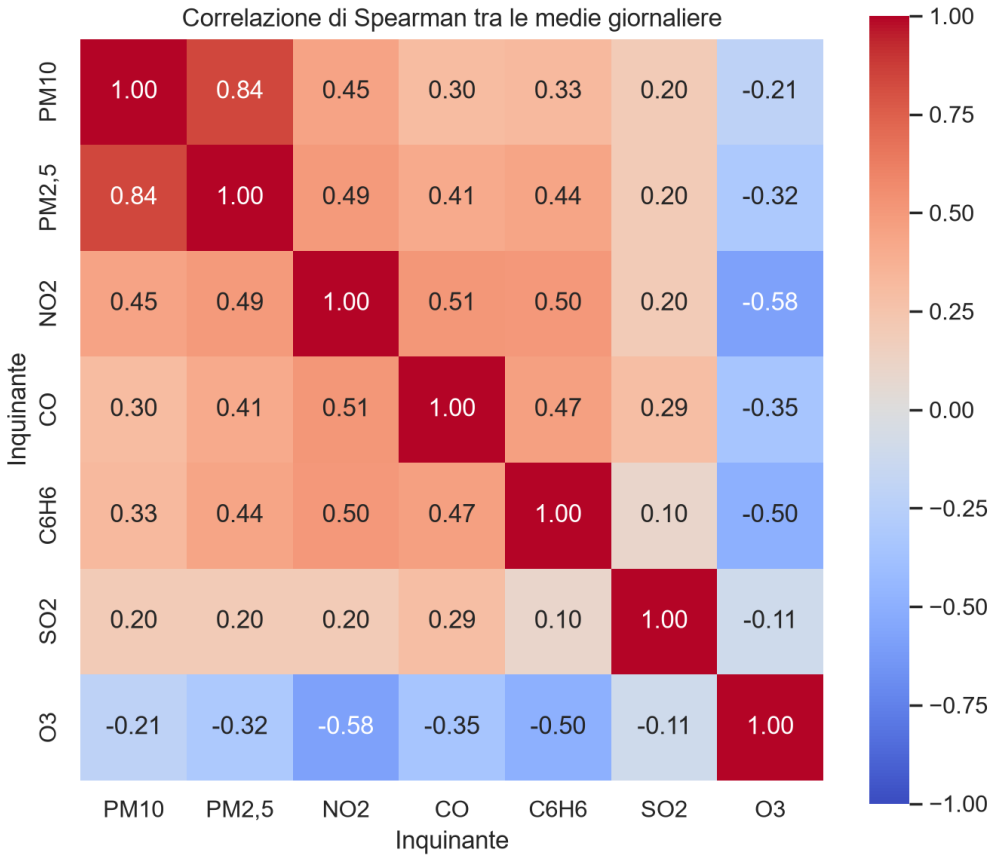


Figura 2.9: *Matrice di correlazione di Spearman tra le medie giornaliere degli inquinanti.*

Le Figure 2.8 e 2.9 riportano le correlazioni tra le medie giornaliere degli inquinanti, calcolate per ogni coppia di stazione e giorno; per ogni coppia di inquinanti sono utilizzate solo le giornate in cui entrambi sono misurati. La correlazione di Pearson misura la relazione lineare tra due variabili, mentre quella di Spearman è calcolata sui ranghi dei valori (la giornata con il valore più basso ha rango 1, la successiva rango 2, e così via) e misura una relazione monotona, è quindi meno sensibile ai valori estremi. Entrambe variano tra -1 (relazione inversa perfetta) e $+1$ (relazione diretta perfetta).

Le due misure concordano per la maggior parte delle coppie. Gli inquinanti legati al traffico (NO_2, CO e benzene) sono correlati positivamente tra loro (circa 0,5), mentre l'ozono è correlato negativamente con tutti gli altri inquinanti, in particolare con l'NO_2 ($-0{,}54$ secondo Pearson, $-0{,}58$ secondo Spearman), in coerenza con l'andamento opposto osservato su scala stagionale, settimanale e giornaliera. L'SO_2 risulta quasi indipendente dagli altri inquinanti (correlazioni comprese tra 0,1 e 0,3), a conferma di sorgenti specifiche, industriali e portuali.

La differenza più marcata riguarda la coppia PM10–PM2,5: la correlazione di Pearson è pari a 0,48, quella di Spearman a 0,84. Poiché il PM2,5 è una frazione del PM10, la seconda descrive meglio il legame tra le due variabili, la correlazione di Pearson è abbassata da pochi valori estremi di PM10 senza corrispondente aumento del PM2,5, come le giornate anomale

della stazione IT1486A conservate nel dataset. Per la coppia benzene–PM2,5 avviene il contrario, la correlazione di Pearson (0,62) è superiore a quella di Spearman (0,44), perché poche giornate in cui entrambi gli inquinanti sono molto elevati ne accentuano la relazione lineare. Data l'asimmetria delle distribuzioni e la presenza di valori estremi, la correlazione di Spearman è la misura più affidabile per questi dati.

2.8 Conclusioni

L'analisi descrittiva ha evidenziato i seguenti risultati principali:

- gli inquinanti presentano una forte **stagionalità**: l'ozono è massimo in estate, mentre NO_2 e PM2,5 sono massimi in inverno; il PM10 presenta anche un secondo massimo estivo, dovuto alle particelle più grossolane;
- il **traffico** è una sorgente importante: gli inquinanti a esso legati diminuiscono nel fine settimana e presentano due massimi giornalieri in corrispondenza delle ore di punta;
- l'**ozono** si comporta in modo opposto all'NO_2 su tutte le scale temporali, come confermato dalla correlazione negativa;
- le **differenze tra stazioni** sono marcate: le medie di PM10 vanno da circa 17 a circa $40\,\mu g/m^3$, con i valori più alti nell'area a nord-est di Napoli;
- alcuni **episodi** (Capodanno, evento di inizio aprile 2024) producono valori molto superiori alla norma.

Questi risultati ci aiutano a comprendere le caratteristiche dei dati e a guidare le scelte metodologiche per i capitoli successivi, in particolare per la classificazione, il clustering e il forecasting.

3 CLASSIFICAZIONE

4 CLUSTERING

5 FORECASTING

5.1 Introduzione

Questo capitolo descrive la previsione (*forecasting*) delle concentrazioni giornaliere degli inquinanti con quattro metodi: **ARIMA**, **SARIMAX**, **Prophet** e **XGBoost**. Per ciascun metodo si illustrano il funzionamento, l'impostazione e la valutazione dei modelli e i risultati ottenuti.

Il PM10 è il caso di studio dettagliato (Sezioni 5.2–5.11): è il principale problema di qualità dell'aria della regione, e su di esso si spiegano i metodi. La stessa procedura è poi applicata agli altri sei inquinanti, PM2,5, NO_2, O_3, SO_2, CO e benzene (Sezione 5.12). La Sezione 5.13 estende l'analisi a una previsione fino a sette giorni e riporta la previsione per la settimana successiva all'ultimo dato del dataset.

5.1.1 Librerie utilizzate

Tutto il codice è contenuto in un unico script Python, `air_quality_forecast.py` (cartella `4_FORECASTING/codice`), che utilizza le seguenti librerie:

- **pandas** e **NumPy**: lettura e pulizia dei dati, calcolo delle medie giornaliere e costruzione delle feature;
- **statsmodels**: stima dei modelli ARIMA e SARIMAX e calcolo di ACF e PACF;
- **Prophet**: stima del modello omonimo;
- **XGBoost**: stima dei modelli *gradient boosting*;
- **holidays**: calendario delle festività italiane;
- **Matplotlib**: realizzazione dei grafici.

Le tabelle numeriche complete, per inquinante e stazione, sono raccolte nel file `forecast_results.md`, prodotto dallo stesso script.

5.2 Il problema di forecasting

La Tabella 5.1 riassume l'impostazione del problema per il PM10.

Tabella 5.1: *Impostazione del problema di forecasting per il PM10.*

Scelta	**Valore**	**Motivazione**
Target	Media giornaliera di PM10 ($\mu g/m^3$)	È il principale problema di qualità dell'aria nella regione, e il limite di legge ($50\,\mu g/m^3$ giornalieri, al massimo 35 giorni l'anno) è definito sulle medie giornaliere
Orizzonte	1 giorno; da 1 a 7 giorni nella Sezione 5.13	"Quanto sarà il PM10 domani?" è la domanda operativa più comune (allerte, misure sul traffico)
Stazioni	Acerra ZI, San Vitaliano, Napoli Ferrovia, Avellino Alighieri	Due delle stazioni più inquinate della regione, una stazione urbana da traffico e una stazione pulita come confronto
Training	20/03/2023 – 31/12/2025	Tutto il periodo che precede il test
Test	01/01/2026 – 26/10/2026	Circa 10 mesi che i modelli non vedono durante il training

Per gli altri inquinanti l'orizzonte, i periodi e i modelli sono gli stessi. Cambiano il target (per l'O_3 si usa il massimo giornaliero della media mobile su 8 ore), la soglia dei superamenti e, dove una stazione non misura l'inquinante, le stazioni di valutazione (Sezione 5.12.1).

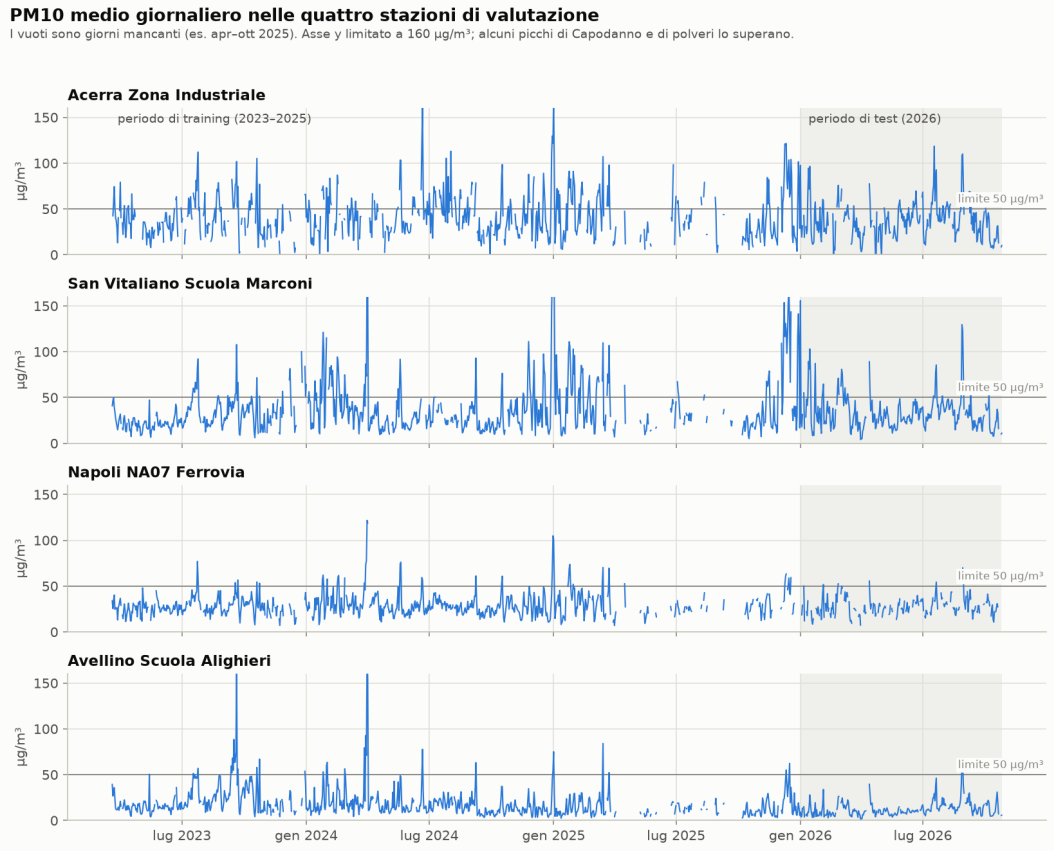


Figura 5.1: *PM10 giornaliero nelle quattro stazioni; il periodo di test 2026 è ombreggiato.*

La Figura 5.1 mostra le quattro serie. Sono evidenti le lacune già descritte nella Sezione 1.5, in particolare tra aprile e ottobre 2025, oltre a singoli giorni mancanti. Le stazioni inquinate (Acerra e San Vitaliano) superano spesso il limite di 50 µg/m^3, Avellino quasi mai.

5.3 Preparazione dei dati

La preparazione dei dati segue quattro passi.

1. **Pulizia dei dati orari**, con le stesse regole del pre-processing (Sezione 1.4): si rimuovono il codice di valore mancante -9999, i valori negativi, i valori fisicamente impossibili, i sensori "bloccati" (lo stesso valore estremo per almeno 6 ore) e le serie stazione $\times$ inquinante $\times$ anno interamente nulle.

2. **Media giornaliera**: un giorno è valido solo se almeno 18 delle sue 24 ore sono valide, secondo la regola del 75% del D.Lgs. 155/2010. I giorni con meno ore valide restano *mancanti* e non vengono riempiti.

3. **Massimo giornaliero della media mobile su 8 ore per l'O_3 (MDA8)**: per ogni ora si calcola la media delle 8 ore precedenti, valida se almeno 6 ore su 8 sono valide; il

massimo del giorno è valido se almeno 18 delle 24 medie sono valide. È l'indicatore su cui è definito il valore obiettivo dell'O_3 ($120\,\mu g/m^3$).

4. **Trasformazione logaritmica**: tutti i modelli lavorano su $\log(1 + y)$ e la previsione viene riconvertita con $e^x - 1$. Le concentrazioni sono fortemente asimmetriche a destra (Sezione 2.2), mentre su scala logaritmica la distribuzione è approssimativamente simmetrica, come assumono ARIMA e Prophet; inoltre la previsione non può mai essere negativa. La trasformazione ha anche un costo, discusso nella Sezione 5.11.

Ogni modello gestisce i giorni mancanti in modo diverso (Tabella 5.2).

Tabella 5.2: *Gestione dei giorni mancanti nei diversi modelli.*

Modello	**Gestione dei giorni mancanti**
ARIMA / SARIMAX	Nativa, tramite il filtro di Kalman: un giorno mancante è semplicemente "non osservato" e il modello continua a prevedere attraverso la lacuna
Prophet	I giorni mancanti vengono scartati, poiché Prophet non richiede una serie regolare
XGBoost	Le feature ritardate diventano mancanti; XGBoost apprende, a ogni divisione dell'albero, una direzione predefinita per i valori mancanti

5.4 Valutazione dei modelli

5.4.1 Previsione a un passo con parametri fissi

Ogni modello viene **stimato una sola volta** sul periodo di training. Per ogni giorno di test t, il modello prevede t utilizzando tutte le osservazioni fino al giorno $t - 1$. I parametri **non vengono ristimati** durante il test: il modello si limita a incorporare le nuove osservazioni man mano che arrivano.

Questo schema simula un contesto operativo, in cui ogni sera si prevede il giorno successivo, ed è equo: nessun modello vede mai il giorno che sta prevedendo.

5.4.2 Campione comune

Le metriche sono calcolate solo sui giorni-stazione in cui l'osservazione è valida e tutti i modelli hanno prodotto una previsione, così che nessun modello sia avvantaggiato dall'essere valutato su giorni "più facili". Per il PM10 si tratta di 1.038 giorni-stazione, di cui 105 sopra $50\,\mu g/m^3$.

5.4.3 Metriche

Le metriche utilizzate sono riportate nella Tabella 5.3.

Tabella 5.3: *Metriche di valutazione.*

Metrica	Cosa misura	Come leggerla
MAE (*mean absolute error*)	Ampiezza media dell'errore, nell'unità dell'inquinante	Metrica principale: in media la previsione sbaglia di X µg/m^3
RMSE (*root mean squared error*)	Come il MAE, ma gli errori grandi pesano di più	Un RMSE alto rispetto al MAE indica errori grandi occasionali
Bias	Media di (previsto − osservato)	Negativo: il modello prevede in media valori troppo bassi
Skill vs persistenza	$1 - \mathrm{MAE}_{\mathrm{modello}}/\mathrm{MAE}_{\mathrm{persistenza}}$	Quanto il modello è migliore di "domani = oggi": 0% indica nessun miglioramento, un valore negativo un peggioramento. Non dipende dall'unità di misura ed è quindi l'unica metrica confrontabile tra inquinanti
Precision (superamenti)	Tra i giorni previsti sopra la soglia, quota di quelli realmente sopra	Alta: pochi falsi allarmi
Recall (superamenti)	Tra i giorni realmente sopra la soglia, quota di quelli previsti sopra	Alta: pochi episodi mancati
F1	Media armonica di precision e recall	Un unico numero che le riassume

Quando un modello non prevede mai un superamento, la precision non è calcolabile e nelle tabelle compare "–". Non si utilizza il MAPE (errore percentuale medio), perché gli errori percentuali esplodono nei giorni puliti, con valori vicini a zero: la metrica sarebbe dominata proprio dai giorni meno importanti.

5.5 Baseline

Un modello è utile solo se fa meglio di una previsione banale. Si utilizzano due *baseline*:

- **persistenza**: domani = oggi (l'ultimo valore osservato). Per la qualità dell'aria è sorprendentemente difficile da battere, perché gli episodi di inquinamento durano diversi giorni;
- **seasonal naive** ($t - 7$): domani = lo stesso giorno della settimana precedente. Verifica se il solo ciclo settimanale ha valore predittivo. Per il PM10 è molto peggiore della persistenza (MAE 13,9 contro 8,6): **il ciclo settimanale è debole rispetto alla persistenza da un giorno all'altro**, in coerenza con quanto osservato nella Sezione 2.4.

5.6 ARIMA

5.6.1 Il modello

Un modello ARIMA(p, d, q) spiega il valore di oggi con tre componenti:

- **AR(p), autoregressiva**: il valore di oggi dipende dai p giorni precedenti,

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t;$$

- **I(d), integrata**: la serie viene differenziata d volte ($y_t - y_{t-1}$) per rimuovere i trend; con $d = 0$ la serie oscilla attorno a una media stabile;

- **MA(q), media mobile**: il valore di oggi dipende anche dagli ultimi q errori di previsione ($\theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$), il che permette al modello di correggersi quando ha sbagliato di recente.

5.6.2 ACF e PACF

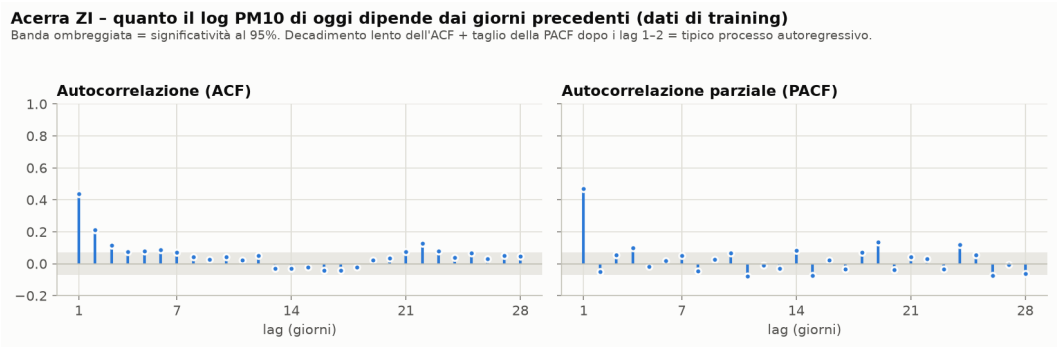


Figura 5.2: *Autocorrelazione (sinistra) e autocorrelazione parziale (destra) del logaritmo del PM10 ad Acerra, dati di training.*

La Figura 5.2 riporta le funzioni di autocorrelazione del logaritmo del PM10 ad Acerra.

- L'**ACF** (correlazione tra oggi e k giorni prima) vale 0,44 al ritardo 1 e 0,21 al ritardo 2, poi decade lentamente verso zero: ieri conta molto, l'altro ieri un po', e la memoria si esaurisce in circa una settimana.

- La **PACF** (correlazione al ritardo k dopo aver rimosso l'effetto dei ritardi più brevi) presenta un unico picco forte al ritardo 1 (0,47) e valori quasi nulli in seguito. È la firma di un **processo di tipo AR(1)**: la maggior parte dell'informazione del passato è contenuta nel valore di ieri.

- I picchi ai ritardi 7, 14 e 21 sono piccoli: il ciclo settimanale esiste ma è debole, coerentemente con lo scarso risultato della seasonal naive.

5.6.3 Scelta dell'ordine

Invece di leggere gli ordini dai grafici, lo script prova ogni combinazione $p \in \{0, \ldots, 3\}$, $d \in \{0, 1\}$, $q \in \{0, \ldots, 3\}$ (32 modelli per stazione) e sceglie quella con l'**AIC** (*Akaike Information Criterion*) più basso, che premia la bontà di adattamento e penalizza la complessità. Gli ordini selezionati per il PM10 sono riportati nella Tabella 5.4.

Tabella 5.4: *Ordini ARIMA selezionati per il PM10.*

Stazione	ARIMA selezionato
Acerra ZI	ARIMA(1, 0, 3)
San Vitaliano	ARIMA(2, 0, 2)
Napoli Ferrovia	ARIMA(1, 0, 1)
Avellino	ARIMA(1, 1, 3)

Il valore $d = 0$ in tre stazioni su quattro conferma che, in questo periodo, il PM10 non presenta un trend che richieda una differenziazione, ma oscilla attorno a un livello stabile.

5.6.4 Limiti

ARIMA conosce solo il passato recente della serie stessa: non ha alcuna nozione di stagione, giorno della settimana, festività o meteo. In inverno "impara" che l'inquinamento è alto solo dopo aver osservato alcuni giorni con valori alti.

5.7 SARIMAX

SARIMAX (*Seasonal ARIMA with eXogenous variables*) aggiunge due elementi al modello ARIMA.

5.7.1 Componente stagionale

La componente stagionale (P, D, Q, s) applica la stessa logica (autoregressione, differenziazione, media mobile) al ritardo s invece che al ritardo 1. Con $s = 7$ il valore di oggi può dipendere anche dallo stesso giorno della settimana precedente. Lo script confronta 12 combinazioni (4 ordini non stagionali $\times$ 3 stagionali) e sceglie quella con l'AIC più basso. Per il PM10, in tre stazioni è stato selezionato il modello **SARIMAX(1,0,1)×(1,0,1,7)**, con un termine AR e uno MA al ritardo 1 e un termine AR e uno MA al ritardo 7. Ad Avellino è stato scelto **SARIMAX(2,1,2)×(1,0,1,7)**, con una differenziazione, coerente con l'ARIMA(1,1,3) della stessa stazione.

5.7.2 Regressori esogeni

I regressori esogeni sono variabili esterne note in anticipo, che entrano nell'equazione come in una regressione lineare:

- **termini di Fourier per il ciclo annuale**, $\sin(2\pi kt/365{,}25)$ e $\cos(2\pi kt/365{,}25)$ per $k = 1, 2$: quattro onde regolari che permettono al modello di rappresentare l'andamento inverno/estate;
- **indicatore di festività**: festività nazionali italiane e 31 dicembre (fuochi d'artificio, Sezione 2.6).

Si utilizzano i termini di Fourier invece di una stagione $s = 365$ perché un ARIMA stagionale annuale richiederebbe centinaia di stati ritardati: sarebbe estremamente lento e

instabile e, con circa 2,8 anni di training, vedrebbe meno di tre cicli. I termini di Fourier descrivono la forma annuale con soli 4 parametri.

5.7.3 Risultato

Per il PM10 SARIMAX migliora ARIMA solo marginalmente (MAE 7,97 contro 8,02). A un giorno di distanza il valore di ieri contiene già l'informazione stagionale ("è inverno, quindi ieri era alto, quindi oggi sarà alto"). Ci si aspetterebbe che la componente stagionale diventi più utile a orizzonti più lunghi, dove il passato recente è meno informativo; la Sezione 5.13.2 mostra che anche a sette giorni il vantaggio su ARIMA resta piccolo.

5.8 Prophet

5.8.1 Il modello

Prophet, sviluppato da Meta, non è un modello autoregressivo, ma un modello di *curve fitting* che scompone la serie in componenti additive:

$$y(t) = \text{trend}(t) + \text{annuale}(t) + \text{settimanale}(t) + \text{festività}(t) + \varepsilon_t$$

dove:

- il **trend** è una spezzata lineare che può cambiare pendenza in punti individuati automaticamente;
- le componenti **annuale** e **settimanale** sono curve periodiche regolari (serie di Fourier);
- le **festività** hanno ciascuna un effetto separato (qui, secondo il calendario italiano).

Poiché si modella il logaritmo della concentrazione, gli effetti additivi diventano **moltiplicativi** sulla concentrazione: +0,2 su scala logaritmica corrisponde a circa il 22% in più.

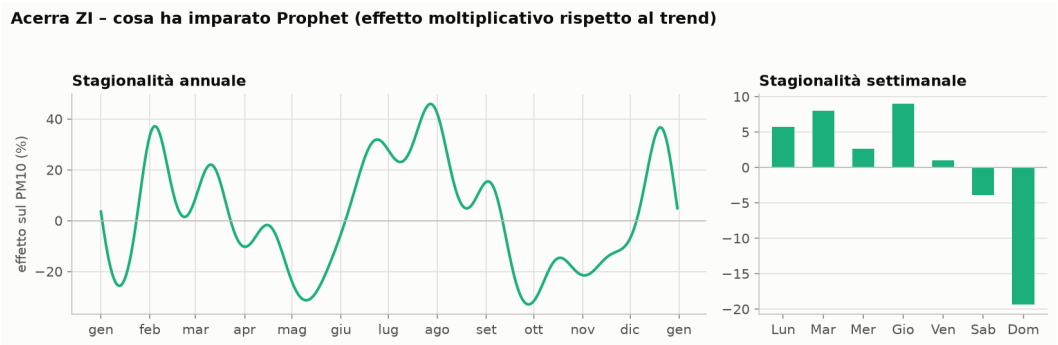


Figura 5.3: *Componenti stimate da Prophet ad Acerra, espresse come effetto percentuale sul PM10 rispetto al trend.*

La Figura 5.3 mostra le componenti apprese ad Acerra.

- **Settimanale**: la domenica è circa il 19% più bassa e il sabato circa il 4% più basso, mentre i giorni feriali sono dall'1 al 9% più alti. È il segnale del traffico già osservato nella Sezione 2.4.
- **Annuale**: la curva è **molto ondulata**, con massimi a febbraio, tra fine luglio e agosto (+45%) e a metà dicembre, e minimi a maggio e ottobre (circa −30%). In parte l'andamento è reale (riscaldamento invernale, polveri estive), ma in buona parte è **overfitting**: con meno di tre anni di dati, la curva annuale flessibile di Prophet memorizza episodi specifici, come le polveri e gli incendi dell'estate 2024, come se si ripetessero ogni anno.
- **Festività**: Prophet ha appreso un forte effetto di Capodanno dai fuochi d'artificio presenti nei dati di training (Sezione 2.6); per questo prevede circa $150\,\mu g/m^3$ a San Vitaliano il 1° gennaio 2026 (Figura 5.5).

5.8.2 Limiti di Prophet

La previsione di Prophet per una certa data **dipende solo dal calendario**, non da ciò che è accaduto il giorno prima. Se inizia un episodio di inquinamento, Prophet non può accorgersene e continua a prevedere la media stagionale. Per questo, sul PM10, Prophet è **peggiore della persistenza del 21%**: perde tutta la dinamica da un giorno all'altro, che contiene la maggior parte della prevedibilità. Per gli altri inquinanti il risultato è ancora peggiore (Sezione 5.12.2).

5.8.3 Prophet con valori ritardati

Prophet permette di aggiungere **regressori** esterni. Aggiungendo l'ultimo valore osservato e la media degli ultimi 7 giorni, entrambi noti la sera del giorno $t-1$, diventa un modello quasi autoregressivo (nel seguito *Prophet + lag*). Con questi regressori Prophet diventa competitivo sul PM10 (MAE 8,01 e il miglior RMSE, 13,04), comportandosi di fatto come una regressione lineare sui valori recenti con una stagionalità regolare.

Prophet descrive quindi bene stagionalità e festività, ma da solo non è uno strumento adatto alla previsione a breve termine di una serie dominata dalla persistenza.

5.9 XGBoost

5.9.1 Il modello

XGBoost non è un modello per serie temporali, ma un modello di *gradient boosting* su alberi decisionali per la regressione. Per utilizzarlo nel forecasting, il problema viene trasformato in una tabella con **una riga per giorno-stazione**, che contiene il target (il logaritmo della concentrazione del giorno) e **feature costruite solo con le informazioni disponibili la sera precedente**.

Il boosting costruisce gli alberi in sequenza: ogni nuovo albero corregge gli errori della somma dei precedenti. Gli alberi possono rappresentare **effetti non lineari e interazioni** (ad esempio "ieri il valore era alto, siamo in inverno e la media regionale sta salendo"), che ARIMA non può cogliere.

5.9.2 Feature utilizzate

Le feature sono riportate nella Tabella 5.5.

Tabella 5.5: *Feature utilizzate dal modello XGBoost.*

Gruppo	**Feature**
Valori recenti del target nella stazione	Valori di 1, 2, 3, 7 e 14 giorni prima; ultimo valore osservato (riportato in avanti sui giorni mancanti); medie a 7 e 30 giorni
Altri inquinanti del giorno precedente	PM10, PM2,5, NO_2 e O_3 della stessa stazione, escluso il target
Segnale regionale	Media del target su tutte le stazioni 1 e 2 giorni prima, per cogliere episodi a scala regionale come le polveri sahariane
Calendario	Giorno della settimana, giorno dell'anno (seno e coseno), mese, indicatore di festività
Stazione	Codice della stazione (categorico), così che un unico modello possa apprendere livelli specifici per stazione

5.9.3 Un modello globale per inquinante

Invece di un modello per stazione, per ogni inquinante XGBoost viene addestrato **una sola volta su tutte le stazioni fisse che lo misurano**. Per il PM10 si tratta di 35 stazioni, cioè circa 26.500 righe di training invece di circa 800. Il modello può così apprendere comportamenti generali (ad esempio come evolve il PM10 dopo un giorno con valori alti) dall'intera rete, e poi specializzarsi per stazione.

5.9.4 Controllo dell'overfitting

Gli ultimi 90 giorni del periodo di training vengono tenuti da parte per determinare il numero di alberi (*early stopping*). Per il PM10 il training si è fermato a 108 alberi; il modello finale viene poi ristimato sull'intero periodo di training con questo numero di alberi.

5.9.5 Importanza delle feature

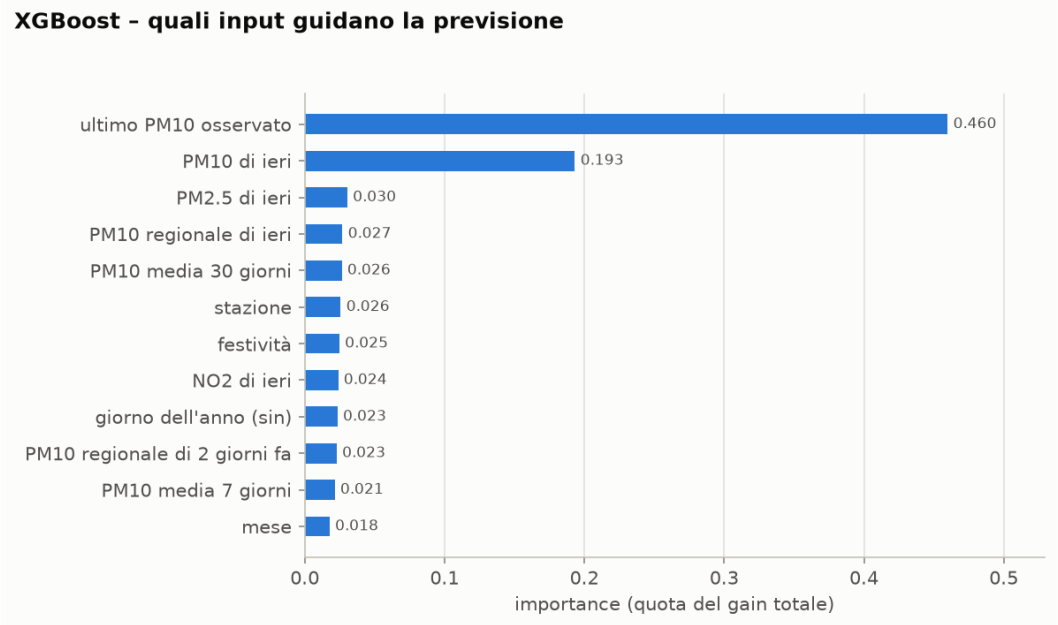


Figura 5.4: *Quota del* gain *totale (riduzione dell'errore) apportata da ciascuna feature nel modello XGBoost per il PM10.*

Come mostra la Figura 5.4, circa il **65%** del potere predittivo proviene da due feature: l'**ultimo PM10 osservato** e il **PM10 del giorno precedente** (esistono entrambe perché il valore di ieri a volte manca, e in quel caso l'informazione è portata dall'ultimo valore osservato). Le altre feature contribuiscono per il 2–3% ciascuna: PM2,5 del giorno precedente, PM10 regionale, livello a 30 giorni, stazione, festività, NO_2 del giorno precedente e posizione stagionale.

Il risultato conferma quanto indicato dall'ACF: **con i soli dati storici di qualità dell'aria, la previsione è essenzialmente "il valore di ieri, corretto"**. La Sezione 5.12.4 mostra che ciò vale per tutti gli inquinanti.

5.10 Risultati per il PM10

5.10.1 Risultati complessivi

La Tabella 5.6 riporta le metriche sulle quattro stazioni aggregate (1.038 giorni di test).

Tabella 5.6: *Risultati della previsione a un giorno per il PM10 (4 stazioni,* 1.038 *giorni-stazione). MAE, RMSE e bias in* µg/m^3*; precision, recall e F1 riferite ai giorni con PM10* > 50 µg/m^3*.*

Modello	**MAE**	**RMSE**	**Bias**	**Prec.**	**Recall**	**F1**	**Skill**
XGBoost	**7,91**	13,25	−2,22	**0,72**	0,22	0,34	+**7,7**%
SARIMAX	7,97	13,61	−1,47	0,71	0,29	0,41	+7,0%
Prophet + lag	8,01	**13,04**	−2,14	0,62	0,25	0,35	+6,5%
ARIMA	8,02	13,73	−1,70	0,65	0,23	0,34	+6,4%
Persistenza	8,57	15,01	+0,04	0,55	**0,55**	**0,55**	0%
Prophet	10,37	15,43	−1,92	0,25	0,06	0,09	−21,1%
Seasonal naive ($t-7$)	13,93	20,98	+0,41	0,24	0,25	0,24	−62,6%

I quattro modelli principali ottengono un MAE quasi identico, circa 8 µg/m^3, e battono la persistenza solo del 6–8%. La persistenza ha il MAE peggiore tra questi modelli, ma l'**F1 migliore** sui superamenti (0,55 contro 0,34–0,41); il motivo è spiegato nella Sezione 5.11.

5.10.2 Previsioni sul periodo di test

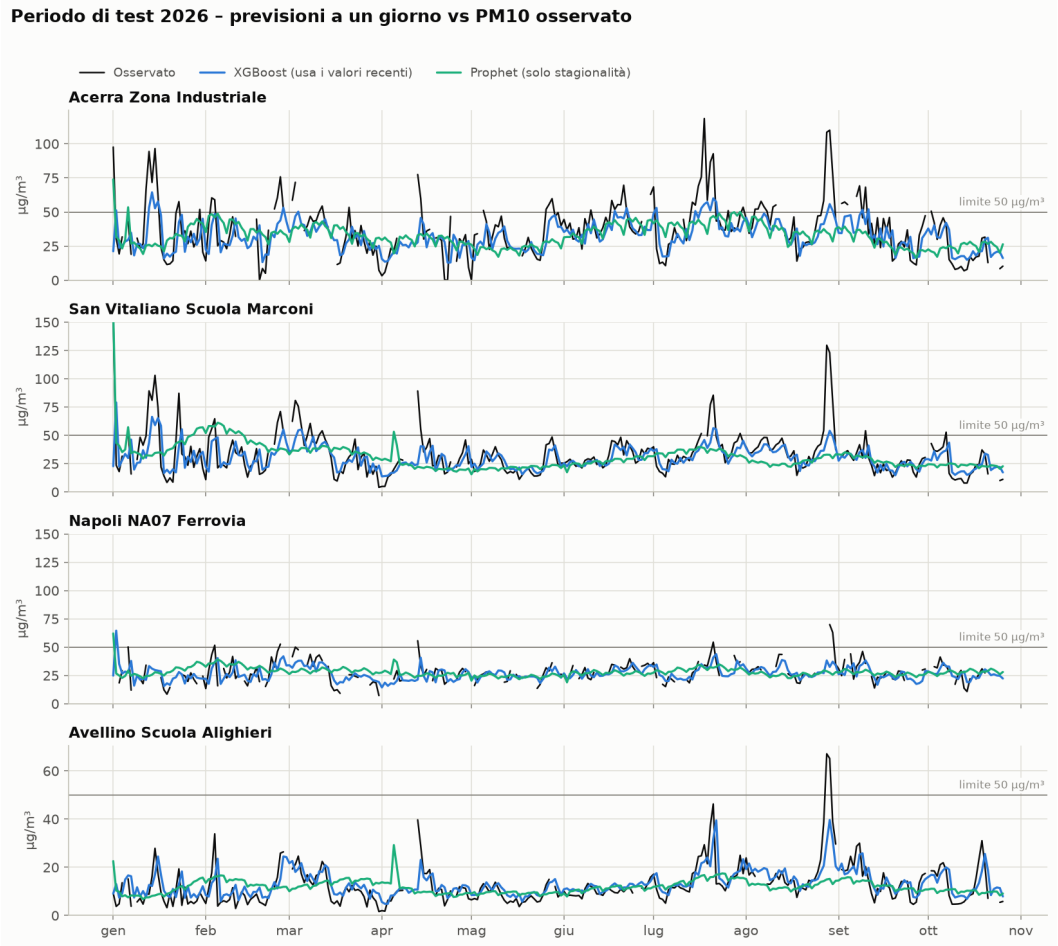


Figura 5.5: *PM10 osservato (nero), previsione XGBoost (blu) e Prophet standard (verde) sul periodo di test 2026.*

Dalla Figura 5.5 emerge che:

- **XGBoost segue le variazioni da un giorno all'altro**, perché è guidato dal valore del giorno precedente, e riproduce bene il livello generale in tutte le stazioni;
- **Prophet produce una curva stagionale regolare**: coglie il livello generale, ma non reagisce agli episodi (ad esempio ad Acerra e San Vitaliano a fine agosto) e presenta l'anomalo picco di Capodanno il 1° gennaio;
- **i picchi più alti sono sottostimati da entrambi i modelli** (fine luglio e fine agosto ad Acerra e San Vitaliano, fine agosto ad Avellino), come discusso nella Sezione 5.11.

5.10.3 Dettaglio: Acerra, gennaio–marzo 2026

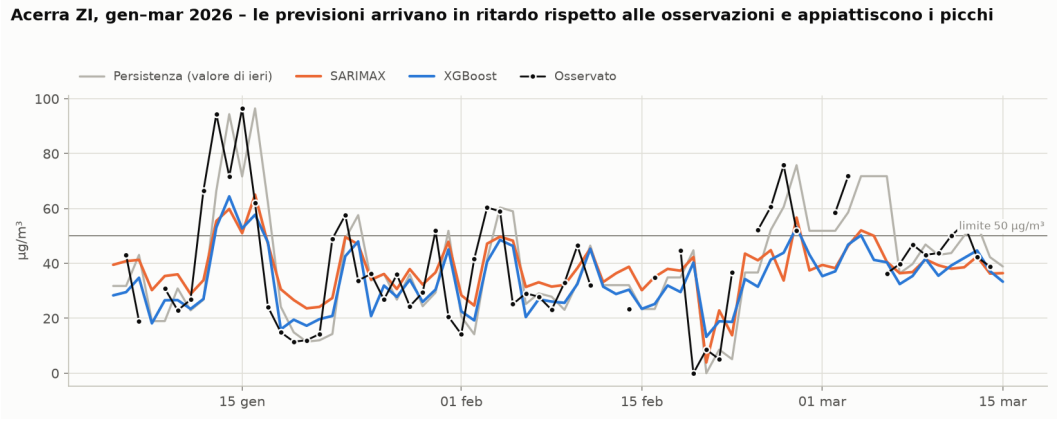


Figura 5.6: *PM10 ad Acerra, gennaio–marzo 2026: valori osservati (punti neri) e previsioni di persistenza (grigio), SARIMAX (arancione) e XGBoost (blu).*

La Figura 5.6 mostra il comportamento tipico di una previsione a un giorno basata sui valori passati:

- **le previsioni sono in ritardo di un giorno**: quando il PM10 passa da 25 a 95 $\mu g/m^3$ (metà gennaio), i modelli salgono solo il giorno *successivo*, perché non hanno modo di sapere che il salto sta per arrivare;
- **i modelli riavvicinano la previsione della persistenza alla media**: dopo un giorno con valori alti la persistenza ripete il valore alto, mentre SARIMAX e XGBoost prevedono un valore intermedio. Questo riduce l'errore medio, perché molti giorni con valori alti sono seguiti da giorni con valori più bassi, ma fa sì che i modelli prevedano raramente valori sopra 50 $\mu g/m^3$.

5.10.4 Risultati per stazione

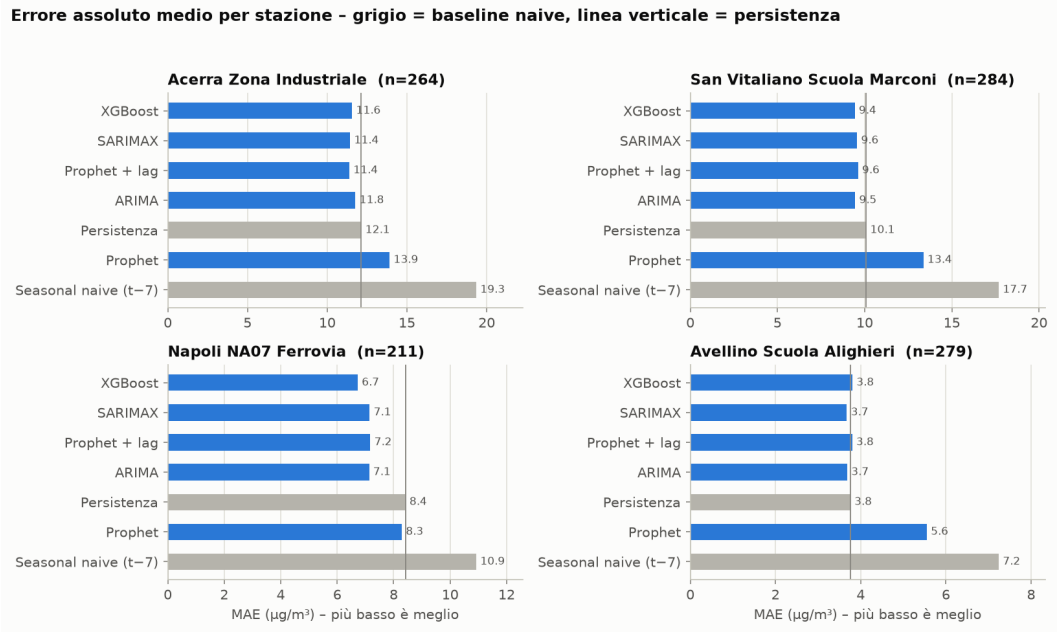


Figura 5.7: *MAE per modello e stazione. Le barre grigie sono le baseline; la linea verticale indica la persistenza.*

Tabella 5.7: *Risultati per stazione, PM10 (MAE in* µg/m^3*). Recall mod.: miglior recall tra i modelli ([a]Prophet, gli altri modelli 0; [b]SARIMAX e XGBoost; [c]SARIMAX).*

Stazione	Giorni	>50	MAE pers.	Miglior modello	Skill	Recall pers.	Recall mod.
Napoli Ferrovia	211	10	8,42	XGBoost (6,73)	+20,1%	0,20	0,10[a]
Acerra ZI	264	62	12,13	Prophet + lag (11,38)	+6,2%	0,63	0,24[b]
San Vitaliano	284	31	10,08	XGBoost (9,43)	+6,4%	0,52	0,48[c]
Avellino	279	2	3,76	SARIMAX (3,68)	+2,1%	0,50	0

Dalla Figura 5.7 e dalla Tabella 5.7 emerge che:

- gli errori crescono con il livello di inquinamento: il MAE è di circa 11–12 µg/m^3 ad Acerra e di circa 3,7 ad Avellino;
- a **Napoli Ferrovia** XGBoost batte la persistenza del 20%, il risultato migliore tra le quattro stazioni; tuttavia ARIMA, SARIMAX, XGBoost e Prophet + lag **non intercettano nessuno** dei 10 superamenti;
- a **San Vitaliano** SARIMAX è l'unico caso in cui un modello batte la persistenza anche sui superamenti (F1 0,57 contro 0,52);

- ad **Avellino**, sito pulito, nessun modello batte la persistenza in modo significativo, perché c'è poco segnale da un giorno all'altro da sfruttare; con soli 2 superamenti, precision e recall non sono significative;
- la **classifica tra ARIMA, SARIMAX, XGBoost e Prophet + lag cambia da stazione a stazione**: le loro differenze, di pochi decimi di µg/m^3, rientrano nella variabilità di un test di 10 mesi, e i quattro modelli vanno considerati **equivalenti**.

5.11 Perché i modelli sbagliano i giorni più inquinati

È il risultato più importante per l'uso pratico della previsione. Vale per il PM10 e, come mostra la Sezione 5.12.3, anche per gli altri inquinanti con superamenti.

5.11.1 Le evidenze

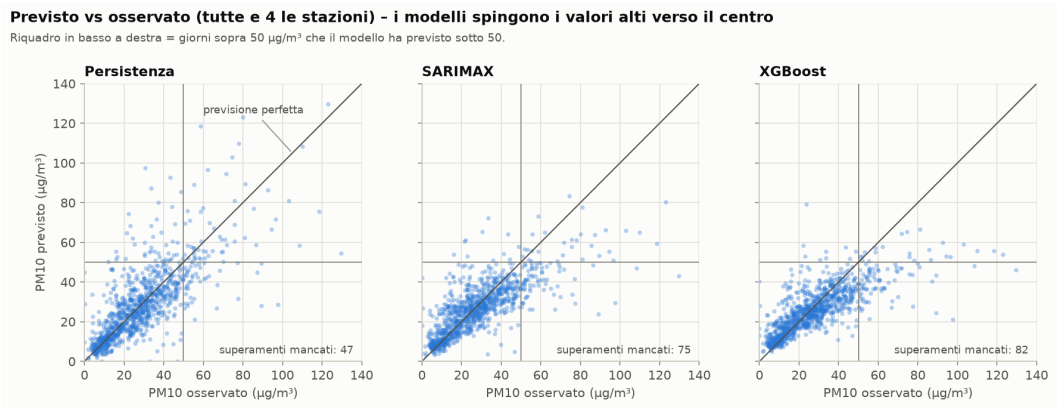


Figura 5.8: *Previsto contro osservato: ogni punto è un giorno-stazione e i punti sulla diagonale sono previsioni perfette. Il riquadro in basso a destra contiene i giorni sopra* 50 µg/m^3 *previsti sotto tale soglia.*

Dei 105 giorni sopra 50 µg/m^3 del periodo di test, la persistenza ne manca 47, SARIMAX 75 e XGBoost 82. Le nuvole di punti dei modelli nella Figura 5.8 sono visibilmente **più piatte della diagonale**: ai valori osservati alti corrispondono previsioni tra 40 e 60 µg/m^3.

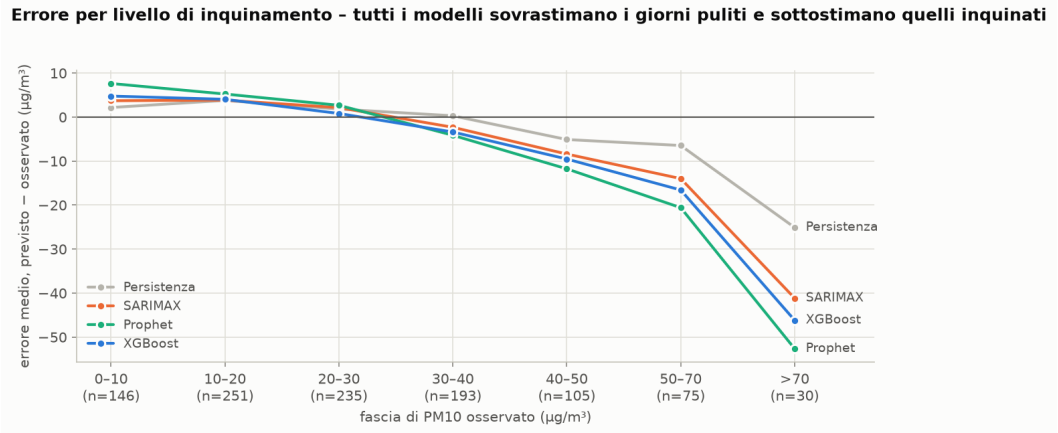


Figura 5.9: *Errore medio per classe di PM10 osservato.*

La Figura 5.9 mostra che nei giorni puliti (0–20 µg/m^3) tutti i modelli prevedono valori **troppo alti** (da +2 a +7 µg/m^3), mentre nei giorni sopra 70 µg/m^3 prevedono valori **molto più bassi** dell'osservato: di circa 25 µg/m^3 la persistenza, 41 SARIMAX, 46 XGBoost e 52 Prophet.

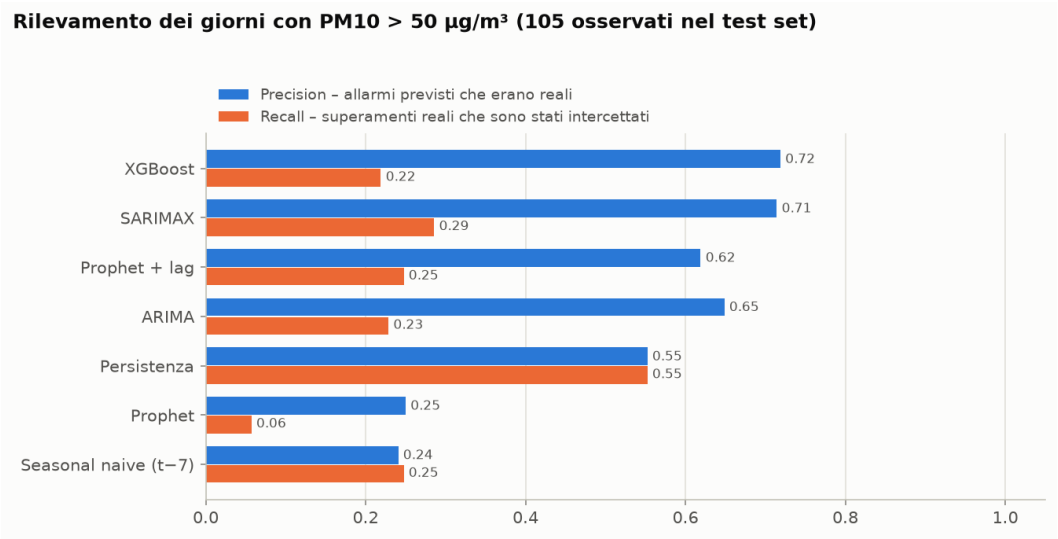


Figura 5.10: *Precision e recall sui giorni con PM10 sopra* 50 µg/m^3.

Come mostra la Figura 5.10, i modelli hanno una **precision più alta** (quando prevedono un superamento, di solito è reale: 62–72%), ma una **recall molto più bassa**: intercettano solo il 22–29% dei superamenti reali, contro il 55% della persistenza.

5.11.2 Le cause

1. **Le previsioni che minimizzano l'errore vengono attirate verso la media** (*regression to the mean*). I modelli sono addestrati a minimizzare l'errore quadratico e, quando il futuro è incerto, la stima che lo minimizza è il valore *atteso*. Dopo un giorno

con valori alti il PM10 a volte resta alto e a volte scende, quindi il valore atteso è inferiore a quello di oggi. Il modello si "copre" correttamente, ed è proprio questa prudenza a ridurre la recall sui superamenti. La persistenza non si copre: per questo ha il MAE peggiore ma la recall migliore.

2. **La riconversione dalla scala logaritmica restituisce la mediana, non la media.** Se la previsione su scala logaritmica è m con incertezza σ, allora e^m è la previsione *mediana* del PM10, mentre la *media* è $e^{m+\sigma^2/2}$, più alta. Poiché il PM10 è asimmetrico a destra, ne deriva un errore sistematico verso il basso che cresce con il livello: è il bias negativo della Tabella 5.6.

3. **Manca l'informazione decisiva.** Gli episodi di inquinamento iniziano per cause **meteorologiche**: aria stagnante, strato limite basso, assenza di pioggia, trasporto di polveri sahariane, incendi. Nessuna di queste informazioni è presente nel dataset. Senza di esse un modello può accorgersi di un episodio solo dopo che è iniziato (il ritardo di un giorno della Figura 5.6). È anche il motivo per cui i quattro metodi ottengono risultati così vicini: utilizzano tutti la stessa informazione limitata.

5.12 Gli altri inquinanti

La procedura del PM10 è stata applicata, senza modifiche ai modelli, agli altri sei inquinanti del dataset. Per ciascuno si utilizzano gli stessi modelli, le stesse griglie di ordini ARIMA e SARIMAX, la stessa trasformazione logaritmica, lo stesso protocollo di previsione a un passo e un modello XGBoost globale dedicato.

5.12.1 Impostazione

Tabella 5.8: *Target, soglia dei superamenti e stazioni di valutazione per inquinante.*

Inquinante	Target	Soglia	Riferimento	Stazioni
PM2,5	media giornaliera	25 µg/m^3	limite giornaliero dal 2030 [4]	Acerra ZI, San Vitaliano, Napoli Ferrovia, Avellino
NO_2	media giornaliera	50 µg/m^3	limite giornaliero dal 2030 [4]	Acerra ZI, San Vitaliano, Napoli Ferrovia, Avellino
O_3	MDA8	120 µg/m^3	valore obiettivo (D.Lgs. 155/2010) [3]	Ariano Irpino, Napoli Parco Virgiliano, San Vitaliano, Volla
SO_2	media giornaliera	50 µg/m^3	limite giornaliero dal 2030 [4]	Acerra ZI, San Vitaliano, Napoli Ferrovia, Polla
CO	media giornaliera	4 mg/m^3	limite giornaliero dal 2030 [4]	Acerra ZI, Napoli NA06 Museo, Napoli Ferrovia, Avellino
C_6H_6	media giornaliera	–	esiste solo un limite annuale (5 µg/m^3)	Acerra ZI, San Vitaliano, Napoli Ferrovia, Avellino

Le stazioni. Dove possibile si utilizzano le stesse quattro stazioni del PM10, così che i risultati siano confrontabili tra inquinanti. Quando una stazione non misura l'inquinante, viene sostituita da una con lo stesso ruolo:

- **O_3**: delle quattro stazioni del PM10 solo San Vitaliano misura l'ozono. L'ozono è un inquinante secondario, che si forma con la radiazione solare a partire da altri inquinanti e raggiunge i valori più alti lontano dalle sorgenti, nelle aree suburbane e collinari. Le altre tre stazioni sono quindi le due più colpite nel 2024, **Ariano Irpino** (74 giorni sopra 120 µg/m^3) e **Napoli Parco Virgiliano** (43 giorni), e **Volla**, la stazione con l'ozono medio più basso, dove le emissioni locali di NO consumano l'ozono;
- **SO_2**: Avellino non lo misura ed è sostituita da **Polla**, il sito più pulito;
- **CO**: San Vitaliano non lo misura ed è sostituita da **Napoli NA06 Museo**, una delle stazioni con il CO più alto.

Le soglie. Per PM2,5 e NO_2 la normativa in vigore non prevede un limite giornaliero (per il PM2,5 esiste solo quello annuale, per l'NO_2 quelli orario e annuale): si utilizzano quindi i limiti giornalieri che entreranno in vigore nel 2030 [4]. Per SO_2 e CO le concentrazioni sono così basse che nel periodo di test **non si verifica alcun superamento**, nemmeno delle soglie 2030; per questi due inquinanti le metriche sui superamenti non sono calcolabili.

L'MDA8 per l'ozono. L'ozono ha un ciclo giornaliero molto marcato, alto nel pomeriggio e basso di notte (Sezione 2.4): la media giornaliera diluirebbe proprio il picco rilevante per la salute e per la normativa.

5.12.2 Quanto si riesce a prevedere

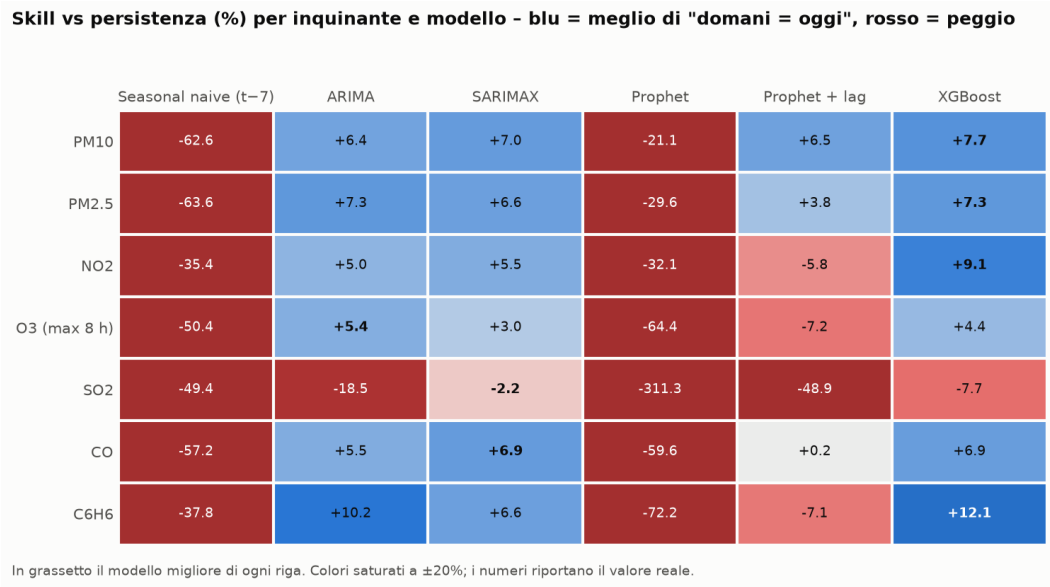


Figura 5.11: *Skill rispetto alla persistenza per inquinante (4 stazioni aggregate) e modello. Blu: meglio di "domani = oggi"; rosso: peggio. In grassetto il modello migliore di ogni riga.*

Tabella 5.9: *Previsione a un giorno per inquinante (4 stazioni aggregate). MAE e media nell'unità dell'inquinante (*µg/m^3*; CO in* mg/m^3*).*

Inquinante	Giorni	Media	MAE pers.	Miglior modello	Skill	Prophet
PM10	1.038	27,9	8,57	XGBoost	+7,7%	−21,1%
PM2,5	1.025	13,8	4,55	XGBoost / ARIMA	+7,3%	−29,6%
NO_2	1.087	34,2	7,70	XGBoost	+9,1%	−32,1%
O_3 (MDA8)	1.018	87,6	9,90	ARIMA	+5,4%	−64,4%
SO_2	1.045	2,7	0,31	nessuno[a]	–	−311,3%
CO	1.064	0,57	0,122	SARIMAX / XGBoost	+6,9%	−59,6%
C_6H_6	997	0,83	0,33	XGBoost	+12,1%	−72,2%

[a] Nessun modello batte la persistenza (il migliore è SARIMAX, −2,2%).

La Figura 5.11 e la Tabella 5.9 mostrano che il quadro del PM10 si ripete quasi identico per tutti gli inquinanti:

- **la persistenza resta difficile da battere**: i modelli migliori fanno dal 5 al 12% meglio di "domani = oggi", e per l'SO_2 nessun modello ci riesce;
- **ARIMA, SARIMAX e XGBoost sono vicini tra loro**: il migliore cambia da inquinante a inquinante e di solito lo scarto tra i primi tre è di 1–3 punti di skill; fanno eccezione NO_2 e benzene, dove XGBoost si distacca un po' di più;

- **Prophet standard è sempre molto peggiore della persistenza** (da −21 a −311%), e per O_3, SO_2, CO e benzene fa peggio anche della seasonal naive. Prophet + lag è competitivo solo per PM10 e PM2,5.

Le differenze tra inquinanti riflettono la loro natura.

- **NO_2 e benzene: la skill più alta (+9 e +12%).** Sono inquinanti legati al traffico, con un ciclo settimanale più marcato (Sezione 2.4): la seasonal naive è meno disastrosa che per gli altri inquinanti (−35 e −38%, contro valori tra −50 e −64%). XGBoost sfrutta il livello recente della stazione (medie a 7 e 30 giorni) e, in misura minore, il giorno della settimana, che ARIMA non utilizza.

- **O_3: la skill più bassa tra gli inquinanti prevedibili (+3/+5%).** L'MDA8 ha un ciclo stagionale fortissimo, ma le variazioni da un giorno all'altro dipendono da radiazione solare e temperatura, cioè dal meteo, che non è nel dataset. Prophet ottiene −64%: la curva annuale sovradattata e il livello appreso negli anni di training non si ripetono nel 2026. Ad Ariano Irpino sovrastima (bias +8,8 µg/m^3), mentre a San Vitaliano e Volla sottostima (bias −10 e −12 µg/m^3); nella Figura 5.12 Prophet resta sopra le osservazioni per tutto giugno e luglio ad Ariano.

- **SO_2: nessun modello batte la persistenza.** Le concentrazioni, di 2–3 µg/m^3, sono vicine al limite di rilevabilità, e le serie sono dominate da cambi di livello irregolari, non stagionali. Ad Acerra, ad esempio, la media semestrale passa da 1,0 µg/m^3 (primo semestre 2023) a 5,1 µg/m^3 (secondo semestre 2026); è plausibile che si tratti in parte di derive strumentali. La persistenza segue questi gradini, mentre i modelli che tornano verso il livello del training (ARIMA con $d = 0$, Prophet) li sbagliano. Prophet, inoltre, estrapola trend e stagionalità inesistenti (−311%).

- **CO e benzene: buona skill, scarsa utilità pratica.** Le concentrazioni sono molto lontane dai limiti (il massimo giornaliero del CO nel test è circa la metà della soglia 2030 di 4 mg/m^3, e il benzene ha solo un limite annuale): la previsione è tecnicamente riuscita, ma non serve per le allerte.

Cambi di livello tra training e test. Diverse serie hanno nel 2026 un livello diverso da quello degli anni di training. A Napoli Ferrovia, ad esempio, l'NO_2 è diminuito (media 2024 52,8 µg/m^3, media 2026 42,6 µg/m^3). I modelli che ricordano il livello del training lo sovrastimano (bias +3,2 µg/m^3 per ARIMA e SARIMAX, +7,5 per Prophet), mentre XGBoost, che utilizza la media degli ultimi 30 giorni, ha un bias di −0,75 ed è il migliore della stazione. È un ulteriore motivo per cui la persistenza e i modelli ancorati ai valori recenti funzionano bene.



Figura 5.12: *Periodo di test 2026: osservato (nero), XGBoost (blu) e Prophet standard (verde), una stazione per inquinante. La linea grigia indica la soglia dei superamenti, quando le concentrazioni le si avvicinano.*

La Figura 5.12 mostra gli stessi comportamenti osservati per il PM10: XGBoost segue le osservazioni con un giorno di ritardo, mentre Prophet disegna una curva stagionale. So-

no visibili anche i problemi specifici: per l'SO_2 ad Acerra Prophet scende a luglio mentre l'osservato resta stabile intorno a 5 µg/m^3, e per il benzene a San Vitaliano Prophet sovrastima a febbraio e sottostima per tutta l'estate, perché la curva annuale e il trend appresi sul 2023–2025 non corrispondono al 2026.

Tra i risultati per stazione si segnalano:

- Napoli Ferrovia, la stazione in cui i modelli guadagnano di più: PM10 +20% (XGBoost), PM2,5 +18% (SARIMAX), benzene +17% (XGBoost), NO_2 +10% (XGBoost);
- NO_2 ad Avellino: SARIMAX +16%;
- CO a Napoli NA06 Museo: SARIMAX +15,5%;
- SO_2 ad Acerra e Polla, CO ad Acerra e PM2,5 ad Avellino: nessun modello batte davvero la persistenza.

5.12.3 I superamenti

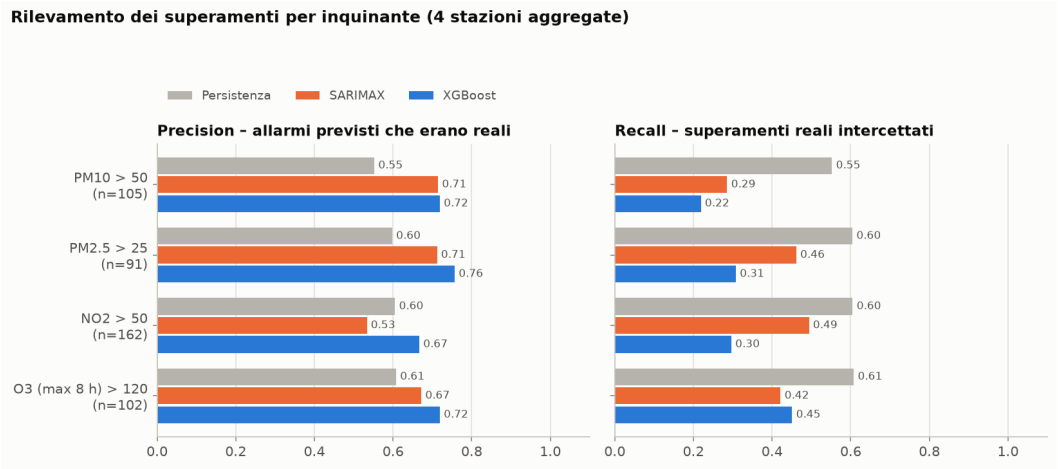


Figura 5.13: *Precision e recall sui superamenti per gli inquinanti con almeno 10 superamenti nel periodo di test (4 stazioni aggregate).*

Tabella 5.10: *Superamenti nel periodo di test: persistenza e miglior F1 tra i modelli.*

Inquinante (soglia)	Superamenti	Persistenza: P / R / F1	Miglior F1 tra i modelli
PM10 (> 50)	105	0,55 / 0,55 / 0,55	0,41 (SARIMAX)
PM2,5 (> 25)	91	0,60 / 0,60 / 0,60	0,56 (SARIMAX, Prophet + lag)
NO_2 (> 50)	162	0,60 / 0,60 / 0,60	0,56 (ARIMA)
O_3 MDA8 (> 120)	102	0,61 / 0,61 / 0,61	0,56 (ARIMA)

La conclusione della Sezione 5.11 vale per tutti gli inquinanti (Figura 5.13 e Tabella 5.10): **i modelli hanno precision più alta ma recall più bassa della persistenza**, e la

persistenza ha l'F1 migliore per ogni inquinante. Le cause sono le stesse: attrazione verso la media, riconversione dalla scala logaritmica e assenza del meteo.

Per PM2,5, NO_2 e O_3 il divario è però più piccolo che per il PM10: la recall di ARIMA e SARIMAX arriva a 0,42–0,49, contro 0,23–0,29 per il PM10, mentre XGBoost, più prudente, resta più basso (0,30–0,45). Per questi inquinanti la soglia è più vicina ai livelli tipici: a Napoli Ferrovia, ad esempio, l'NO_2 supera 50 µg/m^3 in 78 giorni su 269, e ad Ariano Irpino l'O_3 supera 120 µg/m^3 in 33 giorni su 262. Molti superamenti sono quindi giorni "ordinari" e non picchi estremi, e un modello che si mantiene vicino alla media li intercetta comunque.

Con le soglie 2030, il numero di superamenti di PM2,5 e NO_2 costituirebbe già oggi un problema normativo: la nuova direttiva ne ammetterà al massimo 18 all'anno per stazione [4].

5.12.4 Cosa guida la previsione

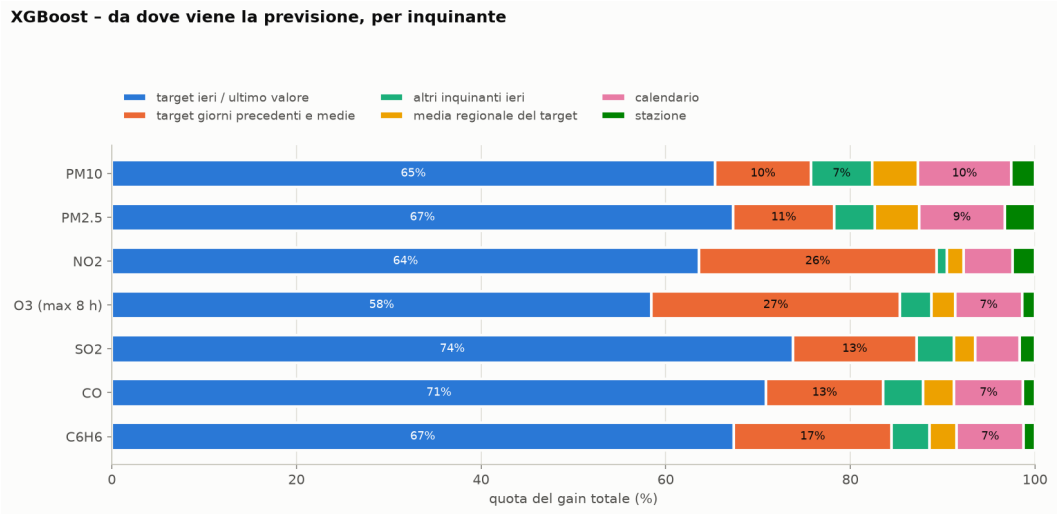


Figura 5.14: *Quota del* gain *totale di XGBoost per gruppo di feature e inquinante.*

Per tutti gli inquinanti (Figura 5.14) dal **75 al 90%** del potere predittivo proviene dai valori recenti del target stesso; il valore del giorno precedente e l'ultimo valore osservato pesano da soli il 58–74%. Gli altri inquinanti, il segnale regionale, il calendario e la stazione contribuiscono per pochi punti ciascuno.

Le differenze riguardano la **memoria** della serie:

- per **NO_2 e O_3** circa un quarto del gain (26–27%) proviene dalle medie a 7 e 30 giorni e dai giorni precedenti: l'NO_2 dipende dal livello tipico della stazione e dal traffico della settimana, l'O_3 da un livello di fondo regionale che varia lentamente con la stagione;
- per gli altri inquinanti i giorni precedenti e le medie pesano solo il 10–17%, e quasi tutto dipende dal giorno precedente (65–74%). Il caso estremo è l'SO_2 (74%): con serie che cambiano livello a gradini, il valore di ieri è la migliore stima del livello attuale.

Il messaggio è lo stesso del PM10: **senza dati meteorologici, la previsione di qualunque inquinante è "il valore di ieri, corretto"**.

5.13 Previsione a sette giorni

Finora la domanda era "quanto sarà domani?". In questa sezione si valuta quanto si riesce a prevedere **fino a una settimana prima**, in due parti:

1. una valutazione su tutto il 2026 a orizzonti da 1 a 7 giorni;
2. una previsione vera e propria per i 7 giorni successivi all'ultimo dato del dataset (27 ottobre – 2 novembre 2026).

5.13.1 Previsione a h giorni

L'**orizzonte** h è il numero di giorni tra l'ultimo dato utilizzato e il giorno previsto: prevedere il giorno t con $h = 7$ significa utilizzare solo i dati fino a $t - 7$, come se la previsione fosse emessa una settimana prima; $h = 1$ è la previsione a un giorno delle sezioni precedenti. Valutazione, periodi e parametri restano quelli della Sezione 5.4: ogni modello è stimato una sola volta sul training e non viene ristimato durante il test. La Tabella 5.11 descrive come ciascun modello produce la previsione a h giorni.

Tabella 5.11: *Previsione a h giorni nei diversi modelli.*

Modello	**Previsione a h giorni**
Persistenza	Ultimo valore noto al giorno $t - h$
Seasonal naive $(t - 7)$	Valore del giorno $t - 7$, noto per ogni $h \leq 7$; a $h = 7$ coincide quindi con la persistenza
ARIMA / SARIMAX	**Ricorsiva**: dal giorno di origine il modello prevede il giorno successivo, utilizza quella previsione come se fosse un dato osservato, e così via per 7 passi, con gli stessi parametri della previsione a un giorno
Prophet	Nessuna modifica: non utilizza i dati recenti, quindi prevede lo stesso valore a qualunque orizzonte
Prophet + lag, XGBoost	**Diretta**: un modello separato per ogni h, con tutte le feature spostate di h giorni. Per $h = 7$ XGBoost utilizza i valori di $t-7$, $t-8$, $t-9$ e $t-14$, le medie a 7 e 30 giorni che terminano a $t - 7$ e gli altri inquinanti di $t - 7$. Le feature di calendario si riferiscono al giorno previsto, noto in anticipo

Per confrontare gli orizzonti in modo equo, le metriche sono calcolate su un **campione comune**: i giorni-stazione con osservazione valida e previsione a tutti e 7 gli orizzonti (per il PM10, gli stessi 1.038 giorni-stazione della Sezione 5.10). La **skill** è sempre calcolata rispetto alla persistenza **allo stesso orizzonte**: la skill a 7 giorni indica quindi quanto un modello batte "fra una settimana = oggi".

5.13.2 Come cresce l'errore

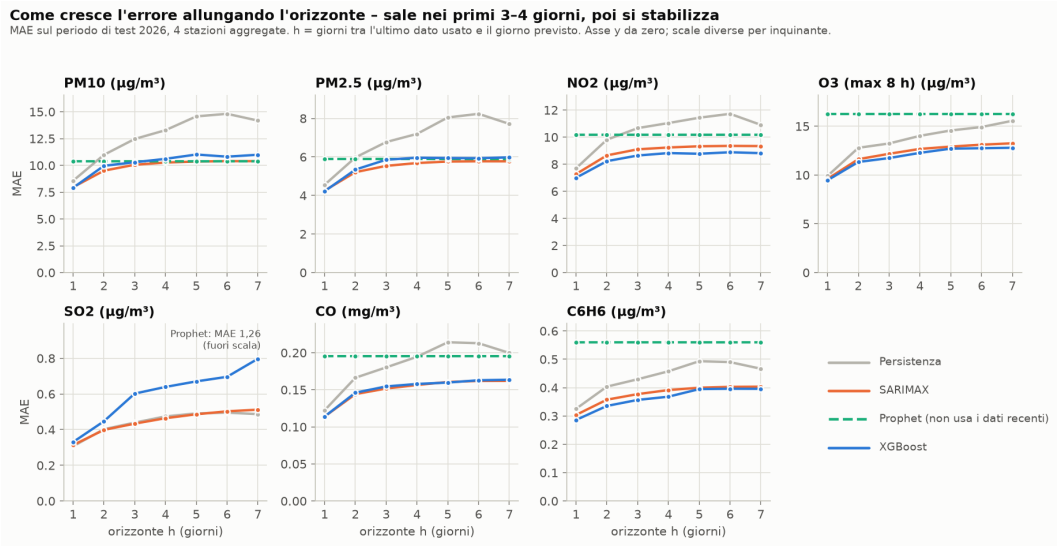


Figura 5.15: *MAE sul periodo di test 2026 (4 stazioni aggregate) in funzione dell'orizzonte, per persistenza, SARIMAX, Prophet (tratteggiato) e XGBoost.*

Tabella 5.12: *MAE della persistenza a $h = 1$ e $h = 7$ e miglior modello a $h = 7$ (µg/m³; CO in mg/m³).*

Inquinante	Pers. h=1	Pers. h=7	Miglior a h=7	MAE	Skill	Prophet
PM10	8,57	14,18	Prophet / SARIMAX	10,37 / 10,40	+26,8 / +26,7%	10,37
PM2,5	4,55	7,71	ARIMA	5,70	+26,1%	5,90
NO_2	7,70	10,91	XGBoost	8,82	+19,2%	10,17
O_3	9,90	15,56	XGBoost	12,80	+17,8%	16,27
SO_2	0,31	0,49	Persistenza	0,49	–	1,26
CO	0,122	0,200	SARIMAX	0,162	+18,9%	0,195
C_6H_6	0,33	0,47	ARIMA	0,36	+23,1%	0,56

Dalla Figura 5.15 e dalla Tabella 5.12 emerge che:

- **l'errore cresce soprattutto nei primi 2–3 giorni, poi si stabilizza**. Per il PM10 il MAE di SARIMAX passa da 7,97 a 10,06 a $h = 3$ e arriva a 10,40 a $h = 7$: l'86% dell'aumento avviene entro il terzo giorno. Per PM2,5 e NO_2 il quadro è lo stesso (88–90%). L'O_3 fa eccezione: il MAE continua a crescere fino al settimo giorno (XGBoost: 9,46, 11,74, 12,80 a $h = 1$, 3 e 7);
- **la persistenza peggiora molto di più**: per il PM10 il suo MAE cresce del 65% (da 8,57 a 14,18), quello di SARIMAX del 30%. Per questo la skill dei modelli **cresce** con l'orizzonte, da +6/+8% a un giorno a +22/+27% a sette giorni. Ciò non significa che i modelli migliorino, ma che "fra una settimana = oggi" è una previsione pessima;
- **per PM10 e PM2,5, dopo 3–4 giorni i modelli non fanno meglio della stagionalità**: da $h = 4$ in poi ARIMA, SARIMAX e XGBoost hanno un errore entro il

5% di quello di Prophet standard, che non utilizza alcun dato recente. A $h = 7$ per il PM10 il migliore è proprio Prophet (10,37), con SARIMAX praticamente pari (10,40). A una settimana, i dati recenti non dicono quasi più nulla sul particolato: resta la media stagionale della stazione;

- **per NO_2, O_3, CO e benzene i dati recenti servono anche a sette giorni**: a $h = 7$ il miglior modello ha un MAE inferiore a quello di Prophet del 13% per l'NO_2, del 17% per il CO, del 21% per l'O_3 e del 36% per il benzene. Prophet sbaglia infatti il *livello* di questi inquinanti nel 2026 (il calo dell'NO_2 a Napoli e l'estrapolazione della curva annuale per O_3 e benzene, Sezione 5.12.2), mentre i modelli che conoscono la media degli ultimi 30 giorni si correggono. XGBoost lo conferma: a $h = 7$ la feature più importante è la media a 30 giorni per 5 inquinanti su 7 (per l'NO_2 è la seconda, dopo la stazione), seguita da stazione e calendario, mentre il valore del giorno precedente, dominante a un giorno, scompare. A una settimana contano **il livello recente e la stagione**, non la dinamica del giorno prima;

- **SARIMAX non ripaga a orizzonti lunghi**: contrariamente a quanto ci si poteva aspettare (Sezione 5.7), a $h = 7$ SARIMAX e ARIMA sono quasi equivalenti per PM10 (10,40 contro 10,43), PM2,5 e O_3; SARIMAX è leggermente migliore per il CO (0,162 contro 0,169) e peggiore per il benzene. Un ciclo settimanale debole e una stagionalità annuale lenta non bastano a ridurre l'errore;

- **per l'SO_2 la persistenza resta il miglior modello a ogni orizzonte**: SARIMAX la eguaglia (entro ±5%), mentre ARIMA e XGBoost peggiorano rapidamente (a $h = 7$ XGBoost ha un MAE di 0,80 contro 0,49). Con serie a gradini, l'ultimo livello osservato è la stima migliore anche una settimana dopo.

5.13.3 L'effetto dell'orizzonte sulla previsione

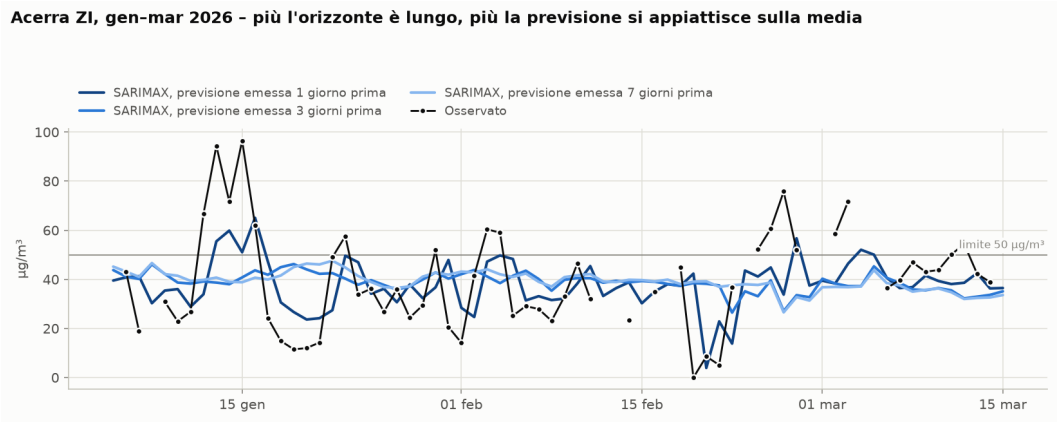


Figura 5.16: *PM10 ad Acerra, gennaio–marzo 2026: osservato (punti neri) e previsione SARIMAX emessa 1 giorno (blu scuro), 3 giorni (blu) e 7 giorni prima (azzurro).*

Nella Figura 5.16 la previsione a un giorno segue le osservazioni con il ritardo di un giorno già visto nella Sezione 5.10. Le previsioni a 3 e 7 giorni sono quasi sovrapposte e quasi piatte, intorno a 35–45 µg/m^3, il livello invernale tipico di Acerra. L'episodio di metà gennaio (oltre 90 µg/m^3) e quello di fine febbraio **non lasciano traccia** nelle previsioni a più giorni, e anche il crollo di metà febbraio (sotto 10 µg/m^3) passa inosservato. È la stessa attrazione verso la media della Sezione 5.11, ma molto più forte: senza informazioni sul meteo dei giorni futuri, l'unica previsione "sicura" a una settimana è la media.

5.13.4 I superamenti con anticipo

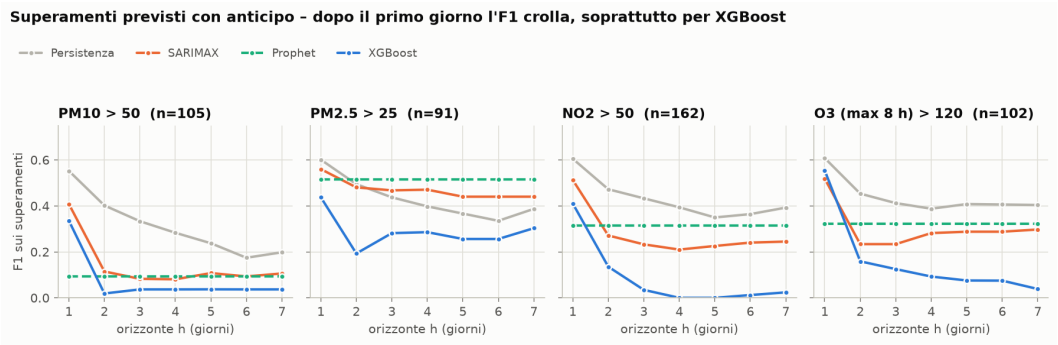


Figura 5.17: *F1 sui superamenti in funzione dell'orizzonte, per i quattro inquinanti con superamenti nel periodo di test (4 stazioni aggregate).*

Già a un giorno i modelli intercettano pochi superamenti (Sezione 5.11); a più giorni la situazione peggiora rapidamente (Figura 5.17):

- **XGBoost e ARIMA non prevedono quasi più superamenti dopo il primo giorno**: per PM10 e NO_2 l'F1 di XGBoost scende sotto 0,05 da $h = 2$ o 3 in poi; quello di ARIMA è già vicino a zero da $h = 2$ per il PM10 e scende fino a 0,01 a $h = 7$ per l'NO_2. Prevedere sempre valori vicini alla media minimizza l'errore assoluto, ma porta a non superare mai la soglia;
- **per PM10, NO_2 e O_3 le baseline restano le migliori a ogni orizzonte**: vince la persistenza o, in alcuni casi, la seasonal naive. Anche le baseline, però, perdono valore: per il PM10 l'F1 della persistenza scende da 0,55 a 0,20 in una settimana;
- **il PM2,5 fa eccezione**: Prophet (0,51) e Prophet + lag (0,49–0,53) battono la persistenza da $h = 2$, SARIMAX (0,44–0,47) da $h = 3$, mentre la persistenza scende a 0,34–0,49. I superamenti di PM2,5 sopra 25 µg/m^3 sono concentrati nei mesi invernali (Sezione 2.4), e una previsione stagionale che resta sopra la soglia per tutto l'inverno ne intercetta una buona parte. Si tratta di un'"allerta di stagione", non di episodio.

Con questi dati, quindi, **non è possibile costruire un'allerta di superamento con alcuni giorni di anticipo**: servono le previsioni meteorologiche (Sezione 5.14).

5.13.5 Previsione per il periodo 27 ottobre – 2 novembre 2026

La previsione è emessa con i dati fino al **26 ottobre 2026**, ultimo giorno del dataset. Per ogni inquinante si utilizza il modello con il MAE medio più basso sui 7 orizzonti nel periodo di test: SARIMAX per PM10 e CO, ARIMA per PM2,5 e benzene, XGBoost per NO_2 e O_3 e la persistenza per l'SO_2.

L'**intervallo all'80%** è empirico: per ogni orizzonte si prendono il 10° e il 90° percentile degli errori commessi dal modello nel 2026 (in scala logaritmica, sulle 4 stazioni insieme) e si applicano alla previsione. L'intervallo è quindi più ampio a $h = 7$ che a $h = 1$, e asimmetrico verso l'alto.

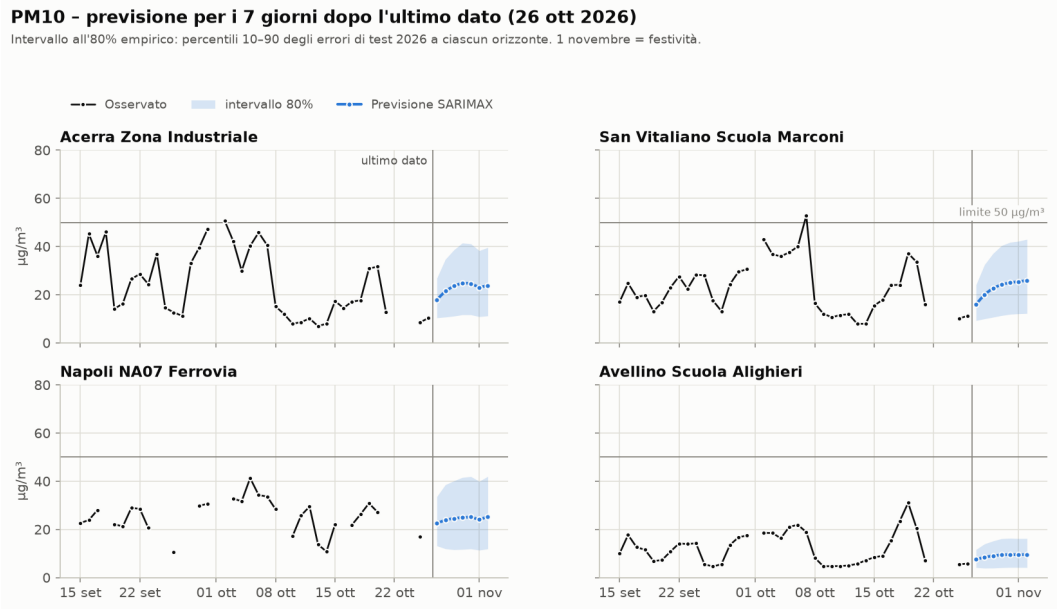


Figura 5.18: *PM10: ultime sei settimane osservate (nero) e previsione SARIMAX per i 7 giorni successivi (blu), con intervallo all'80% (banda azzurra).*

Tabella 5.13: *Previsione SARIMAX del PM10 (µg/m³) per i 7 giorni successivi all'ultimo dato; tra parentesi l'intervallo all'80%.*

Giorno	Acerra ZI	San Vitaliano	Napoli Ferrovia	Avellino
Ultimo dato	10 (26/10)	11 (26/10)	17 (25/10)	6 (26/10)
mar 27 ott	18 (10–27)	16 (9–24)	23 (13–34)	8 (4–12)
mer 28 ott	21 (11–35)	20 (10–32)	24 (12–39)	8 (4–14)
gio 29 ott	24 (11–39)	23 (11–37)	25 (12–40)	9 (4–15)
ven 30 ott	25 (12–41)	24 (11–40)	25 (12–42)	9 (4–16)
sab 31 ott	25 (12–41)	25 (12–42)	25 (12–42)	10 (4–16)
dom 1 nov	23 (11–38)	25 (12–42)	24 (11–40)	10 (4–16)
lun 2 nov	24 (11–40)	26 (12–43)	25 (12–42)	10 (4–16)

PM10. Il 25 e 26 ottobre i valori erano bassi (6–17 µg/m^3). La previsione (Figura 5.18 e Tabella 5.13) risale in 3–4 giorni verso il livello tipico di fine ottobre: circa 25 µg/m^3 nelle tre stazioni dell'area napoletana e circa 10 ad Avellino. Non è previsto alcun superamento: anche l'estremo superiore dell'intervallo (40–43 µg/m^3) resta sotto 50. La risalita verso la media è quella già osservata nella Figura 5.16: il modello non "sa" se l'aria pulita durerà e torna quindi verso il valore stagionale. Il 1° novembre (festivo) si osserva un piccolo calo ad Acerra.

Gli altri inquinanti. Le previsioni sono riassunte nella Tabella 5.14.

Tabella 5.14: *Previsione per gli altri inquinanti, 27 ottobre – 2 novembre 2026.*

Inquinante	Previsione	Soglia
NO_2	Napoli Ferrovia 42–49 µg/m^3 (intervallo fino a 71); Acerra 35–42 µg/m^3	50 µg/m^3: superamento possibile in entrambe
PM2,5	Napoli 15 µg/m^3; altre stazioni 6–11 µg/m^3	25 µg/m^3: sotto la soglia
O_3	61–77 µg/m^3	120 µg/m^3: molto sotto (autunno)
SO_2, CO, benzene	Valori bassi e stabili	–

Al momento della stesura questi sette giorni sono già trascorsi, ma i dati validati non sono ancora disponibili nel dataset: il confronto con le osservazioni sarà la prima verifica da effettuare quando lo saranno.

5.14 Conclusioni

L'analisi di forecasting ha evidenziato i seguenti risultati principali:

- **la scelta dell'algoritmo conta meno dell'informazione disponibile**: per il PM10, ARIMA, SARIMAX, Prophet + lag e XGBoost raggiungono quasi la stessa accuratezza (MAE di circa 8 µg/m^3) e battono "domani = oggi" solo del 6–8%; per gli altri inquinanti il guadagno è tra il 5 e il 12%, e i modelli migliori sono di nuovo vicini tra loro;
- **la persistenza è il segnale dominante** per il giorno successivo, per tutti gli inquinanti: un modello che ignora i valori recenti, come Prophet standard, a un giorno è sempre peggiore della persistenza. A più giorni la persistenza perde valore, e per PM10, PM2,5 e NO_2 Prophet la supera già a 2–3 giorni di anticipo;
- **la stagionalità e il ciclo settimanale sono reali ma secondari** a un orizzonte di un giorno; il ciclo settimanale conta un po' di più per gli inquinanti da traffico (NO_2, benzene);
- **così come sono, i modelli non sono adatti alle allerte per superamento**: hanno una buona precision ma mancano da metà a tre quarti dei superamenti, e per ogni inquinante la persistenza ha un F1 migliore;

- **a più giorni l'errore cresce soprattutto nei primi 2–3 giorni, poi si stabilizza**. La skill rispetto alla persistenza aumenta (da +15 a +27% a sette giorni), ma solo perché la persistenza peggiora molto più rapidamente. Per PM10 e PM2,5, oltre il terzo o quarto giorno i modelli non battono più la sola stagionalità di Prophet; per NO_2, O_3, CO e benzene il livello recente (media a 30 giorni) resta invece utile anche a una settimana;

- **con questi dati non è possibile emettere allerte con alcuni giorni di anticipo**: dopo il primo giorno l'F1 sui superamenti crolla, soprattutto per XGBoost e ARIMA; l'unica eccezione parziale è il PM2,5, i cui superamenti invernali sono in buona parte stagionali;

- **la previsione ha senso pratico** per PM10, PM2,5, NO_2 e O_3, che presentano superamenti frequenti; per SO_2 e CO, con valori molto sotto i limiti, e per il benzene, che ha solo un limite annuale, la previsione giornaliera ha scarsa utilità operativa.

5.14.1 Sviluppi futuri

La Tabella 5.15 riporta i possibili sviluppi, in ordine di impatto atteso.

Tabella 5.15: *Sviluppi futuri, in ordine di impatto atteso.*

#	Sviluppo	Effetto atteso
1	**Aggiungere dati meteorologici** (velocità del vento, altezza dello strato limite, pioggia, temperatura, umidità, radiazione solare) da Open-Meteo o ERA5, utilizzando i valori osservati per il training e quelli previsti in esercizio	Il miglioramento più grande disponibile: aiuta a intercettare gli episodi prima che inizino; per l'O_3 temperatura e radiazione sono essenziali. È l'unico modo per rendere utile la previsione oltre i 2–3 giorni, perché le previsioni meteo a una settimana contengono l'informazione che i dati di qualità dell'aria non hanno
2	**Aggiungere le previsioni di polveri sahariane** (Copernicus CAMS)	Intercettare i principali episodi primaverili ed estivi di PM10 e PM2,5
3	**Correggere le previsioni basse nei giorni alti**: riconvertire con $e^{m+\sigma^2/2}$, abbassare la soglia di allerta (ad esempio sopra 42 µg/m^3 per il PM10) oppure addestrare XGBoost come classificatore "superamento domani"	Recall più alta sui superamenti, al prezzo di più falsi allarmi (scelta da concordare con gli utenti della previsione)
4	**Ridurre la flessibilità annuale di Prophet** (ad esempio con un numero minore di termini di Fourier) e limitarne il trend	Meno overfitting degli episodi isolati e meno estrapolazioni errate (O_3, SO_2, benzene)
5	**Valutazione con ristima periodica** (ad esempio mensile) e ottimizzazione più ampia di XGBoost	Confronto più affidabile e migliore gestione dei cambi di livello tra un anno e l'altro
6	**Verificare la qualità delle serie di SO_2** (cambi di livello, valori vicini al limite di rilevabilità) prima di qualunque uso modellistico	Capire se i gradini sono reali o strumentali

5.15 Riproducibilità

Lo script va eseguito dalla cartella `4_FORECASTING`, con il file CSV grezzo in `data/raw`. Il gestore di pacchetti `uv` crea un ambiente temporaneo Python 3.12 con le librerie necessarie (Prophet non supporta ancora Python 3.14). Le tre fasi possono essere eseguite in sequenza o singolarmente:

- `prep`: pulizia dei dati orari e calcolo delle medie giornaliere e dell'MDA8 (circa 1 minuto);
- `forecast`: stima e valutazione di tutti i modelli; le 28 serie (inquinante × stazione) e i 49 modelli XGBoost (inquinante × orizzonte) sono stimati in parallelo;
- `plots`: realizzazione dei 18 grafici del capitolo.

```
uv run --python 3.12 --with pandas --with pyarrow --with statsmodels \
       --with prophet --with xgboost --with scikit-learn --with tabulate \
       --with matplotlib python codice/air_quality_forecast.py [prep|forecast
           |plots]
```

L'intera procedura richiede circa 4–5 minuti su un processore a 20 core e riproduce esattamente i risultati riportati in questo capitolo.

6 CONCLUSIONI

Bibliografia

[1] Corte di giustizia dell'Unione europea, "Sentenza del 10 novembre 2020, Commissione europea contro Repubblica italiana, causa C-644/18," 2020.

[2] ARPA Campania, "Dati RQA orari validati." Portale Open Data ARPAC, `https://dati.arpacampania.it/dataset/dati-rqa-giornalieri-validati`, 2026. Licenza CC BY 4.0, consultato il 29/10/2026.

[3] Parlamento europeo e Consiglio dell'Unione europea, "Direttiva 2008/50/CE relativa alla qualità dell'aria ambiente e per un'aria più pulita in Europa." Gazzetta ufficiale dell'Unione europea, 2008. Recepita in Italia con il D.Lgs. 155/2010.

[4] Parlamento europeo e Consiglio dell'Unione europea, "Direttiva (UE) 2024/2881 relativa alla qualità dell'aria ambiente e per un'aria più pulita in Europa (rifusione)." Gazzetta ufficiale dell'Unione europea, 2024.